

Pré-processamento e Transformação Estrutural

Prof. Rodrigo

Instituto Federal de Educação, Ciência e Tecnologia de São Paulo - IFSP

Semestre Letivo

Agenda e Objetivos de Aprendizagem

- Compreender a representação matemática da **Distribuição Gaussiana** e como desvios dessa simetria degradam algoritmos preditivos.
- entender o comportamento de baixo nível do **NaN** (IEEE 754) e provar formalmente a **contração de variância** em imputações simples.
- Dominar a detecção de *outliers* (**Tukey, iForest, LOF**) e os impactos de alavancagem em modelos lineares.
- Aprender transformações estabilizadoras de variância (**Yeo-Johnson**) e preparar os dados para os estimadores das próximas aulas.

1. Introdução ao Pré-processamento e Pressupostos Estatísticos

- **O Mito do Dado Pronto:** Em ambientes reais, os dados chegam incompletos, ruidosos e fora dos pressupostos operacionais de algoritmos matemáticos.
- **Gigo (Garbage In, Garbage Out):** Se alimentarmos um modelo preditivo com variáveis desbalanceadas, nulas ou discrepantes, o padrão aprendido será espúrio.
- **Pressupostos Paramétricos:** Modelos de regressão linear, análise de discriminante linear (LDA) e Naive Bayes Gaussiano assumem:
 - ① Normalidade das variáveis independentes e dos resíduos.
 - ② Homocedasticidade (variância constante dos erros).
 - ③ Ausência de multicolinearidade exata.
- **O Objetivo de Hoje:** Estudar como transformar variáveis brutas para preservar e restaurar esses pressupostos operacionais.

2. Distribuição Gaussiana: Definição Matemática

Função Densidade de Probabilidade (FDP)

Dizemos que uma variável contínua X segue uma distribuição normal (ou Gaussiana) com parâmetros de média μ e variância σ^2 (representada por $X \sim \mathcal{N}(\mu, \sigma^2)$) se sua FDP for:

$$f(x|\mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

- **Constante de Normalização:** $\frac{1}{\sigma\sqrt{2\pi}}$ garante que a integral de probabilidade de $-\infty$ a $+\infty$ seja 1.
- **O Expoente Quadrático:** $-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2$ dita o decaimento exponencial simétrico dos dados à medida que nos afastamos do centro μ .
- **Sólida Fundamentação:** Pelo Teorema do Limite Central (TLC), a soma de variáveis independentes tende à uma distribuição normal, justificando seu papel como referencial teórico.

3. Distribuição Gaussiana: Geometria e Regra Empírica

- **Simetria Bilateral Exata:** A média, a mediana e a moda coexistem no ponto exato de simetria vertical μ . O coeficiente de assimetria (skewness) de uma Gaussiana é nulo ($S_k = 0$).
- **Regra Empírica dos Intervalos de Desvio Padrão:**
 - Intervalo 1σ : $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68.27\%$
 - Intervalo 2σ : $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 95.45\%$
 - Intervalo 3σ : $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 99.73\%$

Desvio (σ)	Percentual Acumulado	Probabilidade Fora do Limite
$\pm 1.0\sigma$	68.27%	31.73%
$\pm 2.0\sigma$	95.45%	4.55%
$\pm 3.0\sigma$	99.73%	0.27% (Anomalias teóricas)

4. Z-Score para Detecção de *outlier*: Formulação

A regra empírica da Gaussiana permite formular o primeiro método de detecção de observações discrepantes (*outlier*).

Equação do Z-Score

Mede a distância algébrica padronizada de uma observação individual x_i em relação à média amostral $\bar{x}$, normalizada em termos do desvio padrão σ :

$$Z_i = \frac{x_i - \bar{x}}{\sigma}$$

● Pacing de Decisão Teórico:

- Se $|Z_i| > 3.0$: O registro é classificado como *outlier* paramétrico extremo, pois a probabilidade de ocorrência natural desse ponto na distribuição teórica é inferior a 0.27%.
- Se $|Z_i| \in [2.0, 3.0]$: Zona de transição ou aviso moderado de anomalia.

5. Limitações de Robustez do Z-Score

Por que o Z-Score clássico falha quando os dados brutos possuem múltiplos *outliers*?

- **Efeito de Mascaramento (Masking Effect):** Tanto a média ($\bar{x}$) quanto o desvio padrão (σ) são estimadores estatísticos altamente **sensíveis e não robustos** a *outlier*.

$$\bar{x} = \frac{\sum x_i}{N} \quad ; \quad \sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{N - 1}}$$

- **O Mecanismo de Falha:** Se inserirmos um outlier, ele irá inflar o valor de $\bar{x}$ e, de forma ainda mais forte, o valor de σ (devido ao termo quadrático no desvio padrão).
- **Consequência:** O desvio padrão reduz artificialmente o Z-Score de todos os outros *outliers* menores do conjunto ($Z_i = \frac{x_i - \bar{x}}{\sigma_{inflado}}$), camuflando-os da detecção.

6. Limite de Tukey (IQR): Abordagem Não Paramétrica

Para mitigar o mascaramento do Z-Score, recorremos a medidas de posição robustas baseadas em ordenamento (quantis), imunes a variações extremas.

Equacionamento de Tukey (IQR)

Dada a distância interquartílica ($IQR = Q_3 - Q_1$), onde Q_1 é o percentil 25 e Q_3 o percentil 75, estabelecemos as barreiras internas:

$$\text{Limites} = [Q_1 - 1.5 \times IQR, \quad Q_3 + 1.5 \times IQR]$$

- **Por que é robusto?** A mediana (50%) e os quartis Q_1 e Q_3 são baseados na ordem de posição dos registros. Um *outlier* no infinito desloca os quantis em no máximo $1/N$, mantendo os limites de corte de Tukey estáveis.
- **Extensão de Extremos:** Se multiplicarmos por 3.0 em vez de 1.5 ($Q_3 + 3 \times IQR$), delimitamos *outliers* de categoria "severa".

7. Geometria dos *outliers*: Isolation Forest

Quando saímos do espaço univariado e vamos para múltiplas dimensões colineares, os métodos tradicionais de corte estatístico apresentam problemas. Surge o paradigma geométrico.

- **Paradigma de Isolamento:** Em vez de modelar a densidade normal ou os pontos centrais do conjunto, o Isolation Forest isola anomalias de forma explícita através de árvores de decisão aleatórias (Isolation Trees).
- **O Mecanismo de Particionamento:**
 - 1 Seleciona-se um atributo aleatório do dataset.
 - 2 Escolhe-se um ponto de corte aleatório entre os limites mínimo e máximo observados para aquele atributo.
 - 3 Repete-se o processo de forma recursiva até isolar todos os pontos.

Intuição Teórica

Pontos que residem em regiões densas normais exigem muitos cortes aleatórios no espaço multidimensional para serem isolados (gerando caminhos longos). Pontos raros e discrepantes são isolados nas primeiras ramificações (caminhos curtos).

8. Formulação Matemática do Isolation Forest

Como quantificar matematicamente a "pontuação de anomalia"(s) com base na geometria do comprimento do caminho?

Índice de Anomalia de Caminho Médio

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}}$$

- $h(x)$: Comprimento do caminho para a observação x (número de arestas percorridas da raiz ao nó terminal).
- $E(h(x))$: Valor esperado ou média do comprimento de caminho obtida através de uma floresta de T árvores.
- $c(n)$: Comprimento médio de caminho de uma árvore falha não estruturada com n nós (fator de escala de normalização).
- **Análise do Limite:**
 - Se $E(h(x)) \rightarrow 0 \implies s \rightarrow 1$: O caminho é extremamente curto. Alta probabilidade de anomalia.
 - Se $E(h(x)) \rightarrow c(n) \implies s \rightarrow 0.5$: Comportamento médio esperado. Ponto normal.

9. Geometria dos *outliers*: Local *outlier* Factor (LOF)

- **O Problema de Densidades Variáveis:** Métodos univariados e de distância global falham quando os clusters normais possuem densidades geográficas muito distintas entre si.
- **O Conceito de Densidade Local:** O Local *outlier* Factor (LOF) compara a densidade de vizinhança de um ponto p com a densidade dos seus k vizinhos mais próximos.

Formulação da Distância de Atingibilidade Local (lrd)

$$\text{lrd}_k(p) = \frac{|N_k(p)|}{\sum_{o \in N_k(p)} \text{reach-dist}_k(p, o)}$$

Onde a reach-dist é a maior distância entre a vizinhança k -distância do vizinho o e a distância euclidiana direta de p a o .

- **A Pontuação LOF:**

$$\text{LOF}_k(p) = \frac{\sum_{o \in N_k(p)} \frac{\text{lrd}_k(o)}{\text{lrd}_k(p)}}{|N_k(p)|}$$

Se $\text{LOF} \approx 1$, densidade compatível. Se $\text{LOF} \gg 1$, o ponto p está fora de sua região local de adensamento, sendo rotulado como anomalia local de densidade.

10. Taxonomia de Rubin para Dados Ausentes (Mecanismos)

Valores ausentes não são campos vazios; eles carregam causalidade estatística que mostra se podemos ou não imputar (inserir) as lacunas sem enviesar a amostragem.

MCAR (Missing Completely at Random) A ausência é inteiramente independente de qualquer atributo, seja ele observado (Y_{obs}) ou faltante (Y_{miss}):

$$P(Y_{miss} | Y_{obs}, Y_{miss}) = P(Y_{miss})$$

MAR (Missing at Random) A probabilidade de omissão depende exclusivamente de variáveis observadas no banco, mas não do valor omitido em si:

$$P(Y_{miss} | Y_{obs}, Y_{miss}) = P(Y_{miss} | Y_{obs})$$

MNAR (Missing Not at Random) A probabilidade de omissão depende diretamente do valor oculto que não foi coletado, criando uma correlação invisível e viés sistemático indestrutível.

11. Exemplos Práticos de Mecanismos de Perda no Titanic

Como classificar os registros ausentes de idade no Titanic de forma científica?

- **Cenário MCAR (Ruído Puro):** Um erro mecânico de digitalização rasgou páginas aleatórias do livro de embarque da tripulação. A ausência da idade de um marinheiro é puramente aleatória.
- **Cenário MAR (Omissão Estrutural Observada):** Os dados históricos revelam que a idade de mulheres da terceira classe não foi registrada com precisão devido à triagem rápida de bagagem e imigração no porto de Queenstown.
 - **Implicação:** A ausência de idade correlaciona-se diretamente com atributos conhecidos como Classe de Viagem (Pclass) e Sexo (Sex). A imputação condicional por grupos resolve perfeitamente.
- **Cenário MNAR (Omissão Autocausada):** Passageiros idosos muito debilitados omitiram deliberadamente suas reais condições de idade para evitar inspeções médicas excludentes antes do embarque. O valor ausente correlaciona-se com o fato da pessoa ter idade avançada.

12. O Not-a-Number (NaN) no Hardware

Antes de codificar, o cientista de dados deve compreender como a máquina interpreta a ausência física na memória flutuante de baixo nível.

- **O Padrão IEEE 754 (Ponto Flutuante):** Um valor NaN possui uma assinatura de bits específica no hardware: o campo do expoente (8 bits em precisão simples, 11 bits em precisão dupla) é preenchido inteiramente com bits 1, enquanto a mantissa contém bits mistos não nulos.
- **Consequência do Bitwise de Indeterminação:** O hardware do processador é incapaz de executar operações lógicas ou aritméticas de soma, subtração e produto na presença desse bitwise especial.
- **A Falha de Comparação Universal:** Diferente de qualquer outra variável na computação, NaN viola a lei reflexiva da identidade:

$$\text{NaN} == \text{NaN} \implies \text{False}$$

A busca direta por igualdade falha silenciosamente. O preenchimento ou remoção requer mascaramento booleano analítico de baixo nível.

13. O Colapso Silencioso da Álgebra Computacional

O efeito cascata do NaN na álgebra linear dos estimadores lineares via Equação de Mínimos Quadrados Ordinários (MQO):

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

- **Propagação Aritmética:** Se um único elemento $x_{i,j}$ na matriz de características X for NaN, qualquer produto de matriz intermediário contendo essa linha propagará a indeterminação:

$$[x_{1,1} \times \text{NaN} + x_{1,3} \times x_{3,1}] = \text{NaN}$$

- **Colapso Completo:** A matriz de covariância resultante $(X^T X)$ será inteiramente preenchida por NaNs. O cálculo da matriz inversa se torna impossível.
- **Tratamento Inicial Obrigatório:** Isto prova que realizar imputação ou descarte sistemático não é uma questão estética, mas uma condição de contorno necessária.

14. Imputação Estatística Univariada

Quais os trade-offs matemáticos das estratégias clássicas de preenchimento univariado simples?

Imputação pela Média Global Substitui todos os valores ausentes de uma coluna pela média aritmética simples dos dados válidos.

$$\bar{x} = \frac{1}{N_{\text{valid}}} \sum_{i \in \text{valid}} x_i$$

Vulnerável à distorção por *outlier*. Reduz o desvio real.

Imputação pela Mediana Global Substitui os valores nulos pelo ponto mediano posicional. Estimador robusto a anomalias e outliers.

Imputação pela Moda Utilizada prioritariamente para atributos categóricos discretos (preenchimento pelo valor mais frequente).

O Erro dessas técnicas

Nenhuma dessas técnicas considera o contexto ou as outras variáveis do banco de dados. Elas assumem que o indivíduo ausente é uma réplica exata do comportamento homogêneo médio da população.

15. Prova Algébrica de Contração de Variância

Se preencheremos M valores nulos de uma variável contendo N observações válidas utilizando a média simples $\bar{x}$, a variância amostral gerada após a imputação encolhe artificialmente em termos proporcionais ao volume de dados faltantes.

$$\sigma_{imputada}^2 = \frac{\sum_{i=1}^N (x_i - \bar{x})^2 + \sum_{j=1}^M (\bar{x} - \bar{x})^2}{(N + M) - 1}$$

Como a diferença de qualquer elemento imputado em relação à média é exatamente zero ($\bar{x} - \bar{x} = 0$), o termo somatório da direita colapsa:

$$\sigma_{imputada}^2 = \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N + M - 1}$$

Como o numerador permanece idêntico ao numerador da variância dos dados originais válidos, mas o denominador cresceu de $N - 1$ para $N + M - 1$, a variância encolhe:

$$\sigma_{imputada}^2 = \left(\frac{N - 1}{N + M - 1} \right) \sigma_{valida}^2 \approx \frac{N}{N + M} \sigma_{valida}^2$$

Exemplo Prático: Dados Originais vs. Imputados

1. Dados Originais Válidos ($N = 5$)

Considere a variável com os seguintes valores: **10, 12, 15, 18, 20**

- Média Amostral ($\bar{x}$): $\frac{10+12+15+18+20}{5} = 15$
- Variância ($\sigma_{\text{válida}}^2$): $\frac{(10-15)^2 + \dots + (20-15)^2}{5-1} = \frac{34}{4} = 17,0$

2. Dados Após Imputação de $M = 3$ Valores Nulos

Preenchendo as 3 lacunas faltantes com a média calculada ($\bar{x} = 15$), o novo conjunto passa a ser: **10, 12, 15, 18, 20, 15, 15, 15**

- Nova Média: Permanece exatamente 15
- Nova Variância ($\sigma_{\text{imputada}}^2$): O somatório dos desvios continua sendo 34, mas o tamanho da amostra cresceu para $5 + 3 = 8$.

$$\sigma_{\text{imputada}}^2 = \frac{34}{(5 + 3) - 1} = \frac{34}{7} \approx 4,857$$

Exemplo Prático: Verificação da Fórmula Teórica

Aplicação do Fator de Encolhimento

Pela prova teórica desenvolvida no slide anterior, sabemos que o encolhimento exato da variância é governado pelo fator:

$$\sigma_{\text{imputada}}^2 = \left(\frac{N - 1}{N + M - 1} \right) \sigma_{\text{valida}}^2$$

Substituindo os Valores do Nosso Exemplo ($N = 5, M = 3$)

Multiplicando a nossa variância válida original ($\sigma_{\text{valida}}^2 = 17,0$) pelo fator:

$$\sigma_{\text{imputada}}^2 = \left(\frac{5 - 1}{5 + 3 - 1} \right) \times 17,0$$

$$\sigma_{\text{imputada}}^2 = \left(\frac{4}{7} \right) \times 17,0$$

$$\sigma_{\text{imputada}}^2 = 0,5714 \times 17,0 \approx 4,857$$

A variância real caiu de **17,0** para **4,85** (uma redução de 42,8%), batendo exatamente com a previsão algébrica!

16. Imputação Local Condicional: Split-Apply-Combine

Como neutralizar a contração artificial de variância sem recorrer a modelagem estatística?

- **Estratégia de Agrupamento:** Utilizamos a correlação entre classes de variáveis estruturadas para calcular medidas de centralidade locais muito mais próximas da realidade do registro individual.
- **O Fluxo de Dividir-Aplicar-Combinar:**
 - ❶ **Split (Dividir):** Segmentar o dataset em subconjuntos isolados com base em categorias discretas (ex: classes de passagem do Titanic: 1ª, 2ª e 3ª classe).
 - ❷ **Apply (Aplicar):** Calcular a mediana local de idade de forma isolada para cada classe de viagem.
 - ❸ **Combine (Combinar):** Imputar os NaNs locais de idade com os valores obtidos dos respectivos agrupamentos.

Classe de Viagem (Pclass)	Mediana Local de Idade (Anos)
1ª Classe (Pclass = 1)	37.0 anos (Passageiros seniores)
2ª Classe (Pclass = 2)	29.0 anos
3ª Classe (Pclass = 3)	24.0 anos (Jovens trabalhadores)

17. Métodos Avançados de Imputação: KNN Imputer

Quando a correlação entre múltiplas variáveis contínuas é complexa e não paramétrica, a imputação simples por GroupBy falha. Usamos modelos geométricos locais.

- **KNN Imputer (K-Vizinhos Mais Próximos):** Mapeia as distâncias geométricas entre o registro ausente e todos os outros registros completos do banco de dados.

Formulação da Distância Euclidiana Normalizada

Dado um registro x e um vizinho y , calculamos a distância apenas nas J coordenadas simultaneamente observadas por ambos:

$$d(x, y) = \sqrt{\frac{D}{J} \sum_{j=1}^J (x_j - y_j)^2}$$

Onde D é o número total de dimensões e o fator $\frac{D}{J}$ penaliza a ausência de dimensões comuns.

- **Imputação:** O valor nulo é preenchido através da média ponderada (pelo inverso da distância) dos atributos correspondentes dos k vizinhos mais próximos geométricos selecionados.

18. Métodos Avançados: Imputação Multivariada (MICE)

- **Limitação do KNN:** O KNN Imputer falha se a dimensionalidade dos dados for extremamente alta (maldição da dimensionalidade).
- **MICE (Multivariate Imputation by Chained Equations):** Técnica estatística baseada em modelos de regressões sequenciais e cíclicas encadeadas.

O Processo Iterativo do Algoritmo

- 1 Preenche-se provisoriamente todos os NaNs com a mediana global.
- 2 Para cada variável faltante Y_j :
 - Remove-se a imputação temporária de Y_j , retornando-a a NaN.
 - Ajusta-se uma regressão linear/logística de Y_j sobre todas as outras variáveis do dataset (Y_{-j}):

$$Y_j = \beta_0 + \beta_1 Y_1 + \dots + \beta_k Y_k + \epsilon$$

- Substitui-se os NaNs de Y_j pelas previsões teóricas do modelo.
- 3 Repete-se o processo ciclicamente por C iterações até a convergência e estabilização dos coeficientes e variâncias dos preenchimentos.

19. Sensibilidade Geométrica a *outliers*: MQO

Por que um único *outlier* rotaciona de forma destrutiva uma reta de regressão linear baseada em Mínimos Quadrados Ordinários (MQO)?

A Função de Perda de Erro Quadrático

O estimador de MQO minimiza a Soma dos Erros Quadráticos (SSE):

$$\text{SSE}(\beta) = \sum_{i=1}^M (y_i - x_i^T \beta)^2$$

- **A Penalidade Quadrática do Resíduo:** Se um ponto x_k for um *outlier* extremo cujo resíduo absoluto em relação ao modelo ideal seja 10, sua contribuição individual para a perda é $10^2 = 100$. Se um ponto discrepante possuir resíduo 50, sua perda individual salta para $50^2 = 2500$.
- **A Rotação Forçada:** O estimador prefere sacrificar a acurácia de dezenas de pontos com erros pequenos para reduzir o erro gigantesco de um único ponto distante. Isso força a rotação dos parâmetros β_1 (inclinação) e β_0 (intercepto).

20. O Conceito Matemático de Alavancagem (Leverage)

- **Alavancagem (h_{ii}):** Mede quão afastada uma observação de entrada x_i está da média dos outros dados independentes de entrada.

Matriz de Projeção (Hat Matrix)

A matriz H projeta o vetor observado y nas previsões do modelo ($\hat{y} = Hy$):

$$H = X(X^T X)^{-1} X^T$$

Os elementos da diagonal principal h_{ii} representam a influência geométrica individual de cada ponto no ajuste de sua própria previsão:

$$h_{ii} = \frac{\partial \hat{y}_i}{\partial y_i}$$

- **O Perigo da Alta Alavancagem:** Pontos com alto h_{ii} combinados com grandes resíduos são definidos como **pontos influentes**. Eles ditam a direção do vetor de pesos, invalidando a premissa de homocedasticidade e destruindo a capacidade de generalização do modelo linear ajustado.

21. Escalonamento de Atributos: MinMax vs. StandardScaler

Variáveis contínuas em ordens de grandeza numéricas distintas (ex: Idade variando de 0 a 80 vs. Tarifa variando de 0 a 512) distorcem as distâncias e as taxas de aprendizado.

MinMax Scaling (Normalização) Projeta as características linearmente no intervalo fixo de $[0, 1]$:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Falha Crítica: Se houver um *outlier* discrepante próximo ao infinito, todos os dados válidos normais serão espremidos em uma pequena faixa compacta entre 0.0 e 0.01, destruindo a representatividade da variância da variável.

StandardScaler (Padronização) Mapeia os dados para uma distribuição de média zero e desvio padrão unitário:

$$X_{scaled} = \frac{X - \mu}{\sigma}$$

Não impõe limites fixos, preservando a assinatura geométrica de *outliers* sem achatar artificialmente o restante da distribuição.

22. Escalonamento RobustScaler e MaxAbsScaler

RobustScaler Quando o dataset está intensamente contaminado por anomalias que distorcem o StandardScaler (inflam o μ e σ), aplicamos uma padronização robusta baseada em medidas de posição estáveis:

$$x_{scaled} = \frac{x - \text{mediana}}{\text{IQR}}$$

Onde a mediana e o IQR delimitam o centro e o espalhamento do núcleo populacional sem sofrer perturbações das extremidades.

MaxAbsScaler Mapeia linearmente as variáveis dividindo-as pelo valor absoluto máximo observado no conjunto de dados correspondente:

$$x_{scaled} = \frac{x}{\max(|x|)}$$

Projeta os dados no intervalo $[-1, 1]$. **Aplicações Críticas:** Preservação estrita de dados esparsos. Diferente do StandardScaler, o MaxAbsScaler não desloca o centro da distribuição para zero (μ), impedindo a destruição de estruturas de dados representadas por matrizes esparsas compactas.

23. Transformações para Aproximação da Normalidade

Muitos classificadores paramétricos exigem que os atributos sejam distribuídos de forma estritamente simétrica e normal. Atributos assimétricos (como a Tarifa no Titanic, com cauda longa à direita) necessitam de correções não lineares.

Transformação Logarítmica

$$y = \ln(x + 1)$$

Suaviza variações exponenciais extremas. O termo $+1$ serve de âncora para evitar indeterminação em valores nulos ($\ln(0) = -\infty$).

Transformação de Box-Cox Ajusta uma transformação de potência ideal parametrizada por λ , obtida por estimadores de máxima verossimilhança estatística:

$$y = \begin{cases} \frac{x^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0 \\ \ln(x) & \text{se } \lambda = 0 \end{cases}$$

Restrição Física: Exige dados estritamente maiores que zero ($x_i > 0$).

24. Transformação Yeo-Johnson

Como estender a aproximação Gaussiana de Box-Cox para variáveis contínuas reais contendo valores negativos ou nulos (ex: balanço financeiro negativo, lucros nulos, etc.)?

Formulações Condicionais de Yeo-Johnson

A transformação de Yeo-Johnson altera a equação de potência com base no sinal e no valor do dado individual de entrada:

$$\psi(x, \lambda) = \begin{cases} \frac{(x+1)^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0, x \geq 0 \\ \ln(x + 1) & \text{se } \lambda = 0, x \geq 0 \\ -\frac{(-x+1)^{2-\lambda} - 1}{2-\lambda} & \text{se } \lambda \neq 2, x < 0 \\ -\ln(-x + 1) & \text{se } \lambda = 2, x < 0 \end{cases}$$

- **A Universalização:** Esta técnica permite que qualquer distribuição, independente de conter nulos ou valores negativos, seja esticada ou contraída para se alinhar simetricamente à curva teórica da Gaussiana.

25. Conclusão e Pipeline de Engenharia de Recursos

- **Pré-processamento não é mecânico:** Cada decisão de imputação, escalonamento e remoção de anomalias interfere diretamente na integridade algébrica dos classificadores.
- **Mecanismo de Cascatas:**

Tratamento de NaNs → Tratamento de *outlier* → Escalonamento → Transformações Gaussiana

- **A Espiral de Conhecimento:** A limpeza estruturada realizada nesta semana com o Titanic é importante para a validação do trade-off de Viés-Variância, convergência de Gradiente Descendente e as penalizações de regularização L1/L2 que estudaremos na próxima aula.

Sugestões de Leitura e Referências

Para consolidar a base matemática e apoiar o desenvolvimento do laboratório de terminal, recomendamos o estudo prévio das seguintes obras fundamentais:

- ❶ **GÉRON, Aurélien.** *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn & TensorFlow*. Rio de Janeiro: Alta Books.
 - **Foco:** Capítulo 4 — Treinamento de Modelos (estude as seções de Regressão Linear, Otimização por Gradiente Descendente e regularizações).
- ❷ **FACELI, Katti; LORENA, Ana Carolina; et al.** *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. Rio de Janeiro: LTC.
 - **Foco:** Capítulo dedicado a **Pré-processamento de Dados** (taxonomia de dados ausentes, substituições, normalizações e transformações).
- ❸ **Materiais Técnicos do Módulo (Notebook):**
 - *Estatística Básica* (Seção 8 — Propriedades e formulação da Distribuição Gaussiana).
 - *Ciclo de Vida: Limpeza e Pré-processamento* (Detecção de *Outliers*, Mecanismos de Rubin e o impacto de NaNs no pipeline de ML).