

Regressão teoria

```
[2]: from IPython.display import Image
```

0.1 Como a regressão Linear funciona?

Suponha que nos seja dado um conjunto de dados:

```
[3]: Image(filename='data-8.jpg')
```

[3]:

Experience (X)	Salary (y) (in lakhs)
2	3
6	10
5	4
7	13

O dado é um conjunto de dados de Salário vs Experiência de uma empresa e a tarefa é prever o salário de um funcionário com base em sua experiência de trabalho.

O objetivo é explicar como a regressão linear funciona matematicamente quando usamos uma função predefinida para executar a tarefa de previsão. Vamos explorar como as coisas funcionam quando o algoritmo de regressão linear é treinado.

- **Iteração 1** – No início, os valores θ_0 e θ_1 são escolhidos aleatoriamente. Vamos supor que $\theta_0 = 0$ e $\theta_1 = 0$.

Valores previstos após a iteração 1 com a hipótese de regressão linear.

$$h_0 = [\theta_0 \quad \theta_1] \begin{bmatrix} x_0 & x_0 & x_0 & x_0 \\ x_1 & x_2 & x_3 & x_4 \end{bmatrix} = [0 \quad 0] \begin{bmatrix} 1 & 1 & 1 & 1 \\ 2 & 6 & 5 & 7 \end{bmatrix} = [0 \quad 0 \quad 0 \quad 0]$$

Função de Custo – Erro

$$\begin{aligned}j(\theta) &= \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x_0) - y_i]^2 = \frac{1}{2 \cdot 4} [(0 - 3)^2 + (0 - 10)^2 + (0 - 4)^2 + (0 - 13)^2] \\&= \frac{1}{8} [9 + 100 + 16 + 169] = 36,63\end{aligned}$$

Descida de gradiente – Atualizando o valor θ_0 neste caso temos $j = 0$

$\alpha = 0,001$ -> corresponde ao passo do gradiente descendente

$$\begin{aligned}\theta_j &:= \theta_j - \frac{\alpha}{m} \sum_{i=1}^m [(\theta_0(x_i) - y_i)x_i] = \\&= 0 - \frac{0,001}{4} [(0 - 3)1 + (0 - 10)1 + (0 - 4)1 + (0 - 13)1] = \\&= \frac{0,001}{4} [(-3) + (-10) + (-4) + (-13)] \\&= \frac{0,001}{4} [30] = 0,0075\end{aligned}$$

Descida de gradiente – Atualizando o valor θ_1 neste caso temos $j = 1$

$\alpha = 0,001$ -> corresponde ao passo do gradiente descendente

$$\begin{aligned}\theta_j &:= \theta_j - \frac{\alpha}{m} \sum_{i=1}^m [(\theta_0(x_i) - y_i)x_i] = \\&= 0 - \frac{0,001}{4} [(0 - 3)2 + (0 - 10)6 + (0 - 4)5 + (0 - 13)7] = \\&= \frac{0,001}{4} [(-6) + (-60) + (-20) + (-91)] \\&= \frac{0,001}{4} [177] = 0,04425\end{aligned}$$

- **Iteração 2** - $\theta_0 = 0,0075$ e $\theta_1 = 0,04425$

Valores previstos após a iteração 1 com hipótese de regressão linear.

$$h_0 = [\theta_0 \quad \theta_1] \begin{bmatrix} x_0 & x_0 & x_0 & x_0 \\ x_1 & x_2 & x_3 & x_4 \end{bmatrix} = [0,0075 \quad 0,04425] \begin{bmatrix} 1 & 1 & 1 & 1 \\ 2 & 6 & 5 & 7 \end{bmatrix} = [0,096 \quad 0,273 \quad 0,229 \quad 0,317]$$

$$\begin{aligned}j(\theta) &= \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x_0) - y_i]^2 = \frac{1}{2 \cdot 4} [(0,096 - 3)^2 + (0,273 - 10)^2 + (0,229 - 4)^2 + (0,317 - 13)^2] \\&= \frac{1}{8} [8,433 + 94,614 + 14,220 + 160,858] = 34,766\end{aligned}$$

Agora, de forma semelhante à iteração nº 1 realizada anteriormente, calcularemos novamente a função de custo e atualizaremos os valores de θ_j usando o Gradiente Descendente.

Continuaremos iterando até que a função de custo não reduza mais. Nesse ponto, o modelo atinge os melhores valores de θ .

Usar esses valores de θ na hipótese do modelo fornecerá os melhores resultados de previsão.

[]: