

Amostragem, Métricas Críticas de Classificação e Engenharia de Reamostragem

Aprendizado de Máquina

Prof. Rodrigo

Instituto Federal de São Paulo - IFSP

Semestre Letivo

Objetivos de Aprendizagem

Ao final desta aula, você será capaz de:

- **Compreender** os fundamentos estatísticos de amostragem populacional e sua importância para a generalização de modelos.
- **Distinguir** amostragem aleatória simples de amostragem estratificada, identificando cenários em que cada uma é recomendada.
- **Mapear e interpretar** os erros de classificação (Erros Tipo I e Tipo II) por meio do preenchimento e diagnóstico da Matriz de Confusão.
- **Avaliar** modelos de classificação sob desbalanceamento severo através de métricas assimétricas (*Precisão*, *Sensibilidade*, *F1-Score* e *F-beta*).
- **Analisar** o comportamento dinâmico de limiares de decisão probabilística usando as Curvas ROC/AUC e Precisão-Sensibilidade.
- **Implementar** transformações geométricas de reamostragem (**SMOTE** e **NearMiss**) sem introduzir vazamento de dados (*data leakage*).

O que é uma Amostra? A Foto vs. O Processo Populacional

- **População Estatística (P):** O conjunto universal gerador de dados (infinito ou inacessível).
Exemplo: Todas as transações de cartão de crédito no mundo.
- **Amostra ($S \subset P$):** O subconjunto finito que capturamos para treinar o modelo.

A Hipótese de Generalização (i.i.d.)

Garantimos que um modelo aprenda sobre S e generalize para o mundo real apenas se as observações forem **independentes e identicamente distribuídas** (i.i.d.) em relação à função populacional original.

O Risco Estrutural

Se a amostra S for enviesada e não refletir a população real, o modelo sofrerá **sobreajuste a uma mentira matemática**, falhando miseravelmente em produção.

Estratégias: Aleatória Simples vs. Estratificada

Amostragem Aleatória Simples

Cada elemento da população tem a mesma chance de ser sorteado.

- **Vantagem:** Imparcialidade matemática no limite infinito.
- **Falha Crítica:** Em classes muito raras (ex: fraudes), o sorteio cego pode omitir inteiramente a classe minoritária da amostra, cegando o modelo.

Amostragem Estratificada


A população é segmentada em grupos mutuamente exclusivos (**estratos**) com base no rótulo da classe alvo.

- **Mecânica:** Extraímos elementos proporcionalmente de cada estrato.
- **Aplicação:** É o padrão-ouro obrigatório para gerar bases de Treino e Teste sob desbalanceamento.

A Geometria da Amostragem (O Risco da Busca Cega)

1. Amostragem Aleatória Simples

População Real (90% A, 10% V)



FALHA:

Amostra extraída sem
a correta proporção de
pontos vermelhos

2. Amostragem Estratificada

Estrato Majoritário (Azul)

→ Extrai exatos
90%

Estrato Minoritário (Vermelho)

→ Extrai exatos
10%

Garantia Estrutural: O algoritmo atua de forma forçada em ambos os compartimentos, garantindo a representatividade real.

O Viés de Seleção (Sampling Bias)

Volume de dados não corrige erro metodológico. A qualidade da amostra é mais importante que o seu tamanho bruto.

O Paradoxo da Literary Digest (Eleições de 1936)

Uma pesquisa colossal recolheu **2,4 milhões de questionários** para prever a eleição americana entre Landon e Roosevelt.

- **Previsão da Revista:** Landon (57% dos votos).
- **Resultado Real:** Roosevelt reeleito (62% dos votos).

O Erro de Arquitetura de Dados

As fontes de contato foram catálogos de telefones e registros de carros. Durante a Grande Depressão, isso selecionou exclusivamente a classe alta americana, ignorando sumariamente a base populacional pobre que elegeu Roosevelt.

O Desbalanceamento como Fato Populacional Legítimo

- É fundamental entender que o desbalanceamento não é um erro de coleta. Ele reflete a verdadeira densidade marginal da população $P(Y)$ do fenômeno real.

Cenários Críticos de Desbalanceamento Extremo

Domínio	Classe Negativa (Trivial)	Classe Positiva (Alvo)
Segurança Financeira	Transações legítimas (99.9%)	Fraude de cartão (0.1%)
Medicina Diagnóstica	Pacientes saudáveis (99.5%)	Câncer inicial (0.5%)
Engenharia Industrial	Operação normal (99.8%)	Falha de turbina (0.2%)

A Fricção Prática: O evento que gera o maior prejuízo ou lucro para o negócio é justamente o que possui a menor densidade no banco de dados.

A Ilusão Matemática da Acurácia Global

Suponha um banco de dados com 10.000 transações: 9.900 legítimas e 100 fraudes.

O Classificador “Preguiçoso”

Se criarmos um código que considera como “Legítimo” ($Y = 0$) para 100% dos casos sem processar padrão algum:

$$\text{Acurácia} = \frac{\text{Acertos}}{\text{Total}} = \frac{9.900}{10.000} = \mathbf{99.0\%}$$

O Colapso da Otimização

- O número reporta 99% de sucesso, mas **todas as fraudes foram ignoradas**.
- Os otimizadores de Aprendizado de Máquina baseados em função de perda global são atraídos para essa saída fácil. Eles aprendem a ignorar a classe minoritária para minimizar o erro algébrico.

Desconstruindo a Falha: A Matriz de Confusão Teórica

Para expor as falhas de otimizadores, desmembramos os resultados em uma Matriz de Confusão, isolando a origem do erro.

	Previu Negativo (0)	Previu Positivo (1)
Real (0)	VN (Verd. Negativo)	FP (Falso Positivo) <i>Erro Tipo I</i>
Real (1)	FN (Falso Negativo) <i>Erro Tipo II</i>	VP (Verd. Positivo)

Definição dos Quadrantes Críticos

- **FP (Erro Tipo I):** O Alarme Falso. O sistema apontou perigo onde não havia.
- **FN (Erro Tipo II):** A Omissão. O sistema considerou seguro algo que era fraudulento ou fatal.

Matriz de Confusão na Prática

Uma visão aplicada: o classificador busca maximizar os acertos da diagonal verde, mas o custo de negócio é determinado pelos erros da diagonal vermelha.

Predição do Otimizador (Saída Algorítmica)

		Previu Negativo (0)	Previu Positivo (1)
Status Real (Dataset)	Real (0)	VN Verdadeiro Negativo <i>Acerto Trivial</i> Ex: Legítima aprovada	FP Falso Positivo <i>Erro Tipo I (Alarme Falso)</i> Ex: Cliente bloqueado
	Real (1)	FN Falso Negativo <i>Erro Tipo II (Omissão)</i> Ex: Fraude consumada	VP Verdadeiro Positivo <i>Acerto Crítico (Alvo)</i> Ex: Fraude interceptada

A Gangorra Crítica: Precisão vs. Sensibilidade

Isolamos a análise estritamente sobre a classe Positiva (O Alvo), ignorando o volume da classe Negativa para combater o viés.

Precisão (Precision)

Avalia a confiabilidade do sinal. Dos alertas disparados, quantos eram reais?

$$\text{Precisão} = \frac{VP}{VP + \mathbf{FP}}$$

Quando priorizar? Quando o Alarme Falso causa prejuízo grave (ex: Filtro de Spam arquivando contrato corporativo legítimo).

Sensibilidade (Recall)

Avalia o poder de varredura. Dos perigos que existiam, quantos foram contidos?

$$\text{Sensibilidade} = \frac{VP}{VP + \mathbf{FN}}$$

Quando priorizar? Quando a omissão do sistema é fatal (ex: Omitir um câncer operável no exame preventivo do paciente).


A Física do Trade-off: O Limiar de Decisão (δ)

Modelos geram probabilidades brutas $P(Y = 1|X) \in [0, 1]$. Nós parametrizamos o sistema definindo o limiar de corte δ que aciona o alarme.

- **Aumentar Limiar ($\delta \rightarrow 1$):** O modelo exige certeza quase absoluta antes de disparar o alerta de anomalia.
 - **Resultado:** Alarmes falsos despencam (**Precisão sobe**), mas muitas fraudes passam abaixo do radar (**Sensibilidade desaba**).
- **Reduzir Limiar ($\delta \rightarrow 0$):** O sistema torna-se paranoico, atirando a qualquer suspeita milimétrica.
 - **Resultado:** Captura quase todas as fraudes (**Sensibilidade sobe**), mas bloqueia clientes legítimos em massa (**Precisão desaba**).

A Geometria do Limiar de Decisão (δ)

Visualizando o espaço amostral: por que é impossível maximizar ambas as métricas ao mesmo tempo? Porque as populações físicas quase sempre se interpenetram.



A Generalização da Métrica: O F-beta Score (F_β)

Em cenários reais de negócio, o custo de um Alarme Falso (Falso Positivo) e de uma Omissão (Falso Negativo) raramente é simétrico. O parâmetro β permite “dimensionar” a Média Harmônica a favor da Precisão ou da Sensibilidade.

$$F_\beta = (1 + \beta^2) \frac{\text{Precisão} \times \text{Sensibilidade}}{(\beta^2 \times \text{Precisão}) + \text{Sensibilidade}}$$

$\beta = 0.5$ (Precisão)

Dá o dobro de peso à Precisão em relação à Sensibilidade.

- **Uso:** O custo do Alarme Falso é inaceitável.
- **Ex:** Filtro de Spam corporativo.

$\beta = 1.0$ (F1-Score)

Pesos matematicamente simétricos.

- **Uso:** Cenário base, custos equivalentes.
- **Ex:** Classificação genérica de anomalias.

$\beta = 2.0$ (Sensibilidade)

Dá o dobro de peso à Sensibilidade em relação à Precisão.

- **Uso:** A Omissão é **fatal** ou muito cara.
- **Ex:** Diagnóstico médico ou Fraudes críticas.

A Síntese Algébrica: Por que a Média Harmônica (F1-Score)?

Para automatizar a otimização de hiperparâmetros, precisamos de um único valor numérico.

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}$$

A Força Punitiva da Média Harmônica

Ao invés de aceitar o meio termo passivo da média aritmética, a média harmônica **ancora o resultado no pior componente**, punindo modelos desequilibrados.

- Modelo chuta classe Positiva para 100% da rede: Sensibilidade = 1.0 e Precisão = 0.01.
- **Média Aritmética Ingênua:** $(1.0 + 0.01)/2 = 50,5\%$ (Aprova o erro).
- **F1-Score:** $2 \times (1.0 \times 0.01)/(1.01) = 1,98\%$ (Maneja a anomalia e emite o diagnóstico falho real).

Avaliação Paramétrica Contínua: A Curva ROC

Em engenharia de Aprendizado de Máquina, não testamos um único limiar. A Curva ROC submete o otimizador a uma varredura contínua de $\delta \in [0.0, 1.0]$.

Eixos da Estrutura

- **Eixo Y:** Verdadeiros Positivos (TPR/Sensibilidade).
- **Eixo X:** Falsos Positivos (FPR).
- $FPR(\text{Taxa de Falsos Positivos}) = \frac{FP}{FP+VN}$

A Métrica AUC (Área Sob a Curva)


Mede a ordenação estrita. Se $AUC = 1.0$, as funções de densidade de probabilidade estão separadas por um hiperplano limpo.

O Efeito do Desbalanceamento no FPR

Deve-se ter cautela com o termo **Verdadeiros Negativos (VN)** no denominador da Taxa de Falsos Positivos (FPR). Em bases de dados altamente desbalanceadas (ex: 99,9% de classe negativa), a magnitude de VN infla o denominador. Matematicamente, isso força o FPR a permanecer próximo de zero, mascarando a ocorrência de alarmes falsos e distorcendo a percepção de desempenho do modelo no gráfico.

Visualizando a Estrutura da Curva ROC e AUC

A curva força a aproximação ideal ao quadrante superior esquerdo (Sensibilidade perfeita sem emissão de nenhum Alarme Falso).



O Classificador Perfeito

O gráfico ilustra visualmente a capacidade de separabilidade do modelo. Enquanto o classificador aleatório (chute randômico) é representado pela linha diagonal, modelos com desempenho superior flexionam a curva agressivamente em direção ao vértice superior esquerdo.

O Significado da AUC: Teorema da Ordenação

A Área Sob a Curva (AUC) não é apenas um valor geométrico solto. Ela possui uma **interpretação probabilística** que determina a capacidade do modelo de ordenar (*rankear*) riscos.

O Teorema Estatístico da AUC

A AUC é a probabilidade de que uma amostra positiva aleatória receba um *score* preditivo maior do que uma amostra negativa aleatória.

$$\text{AUC} = P(\hat{p}(x_i) > \hat{p}(x_j) \mid y_i = 1 \text{ e } y_j = 0)$$

Tradução Prática para o Negócio

Se o seu modelo de detecção de fraudes obteve **AUC = 0.92**, isso significa que:

- Se sortearmos aleatoriamente 1 cliente fraudador e 1 cliente honesto do banco de dados...
- Existe exatamente **92% de chance** do algoritmo atribuir um score de risco maior para o fraudador do que para o cliente legítimo.

O Antídoto Analítico: Curva Precisão-Sensibilidade (PR)

Nos casos de desbalanceamento severo (ex: 0.1% de fraudes), a Curva ROC deve ser ignorada em favor da Curva Precisão-Sensibilidade.

O Descarte do Ruído Estrutural

- A curva PR desenha **Precisão** (Eixo Y) contra **Sensibilidade** (Eixo X).
- **A Vantagem Algébrica:** Note que nem a fórmula da Precisão nem a da Sensibilidade contêm o termo *VN* (Verdadeiros Negativos).
- O impacto da classe majoritária é eliminado da equação, forçando o cientista de dados a avaliar o modelo **exclusivamente pela sua competência em detectar e rotular corretamente a classe alvo**.

Manipulação de Memória: Como Evitar a Abordagem Ingênua

Como as funções de custo usadas em regressão logística (Log-Loss, Cross-Entropy) tem o objetivo de reduzir erro global, intervimos fisicamente na geometria da matriz de dados de treino para equilibrar os pesos.

Sobreamostragem Trivial (Erro)

Consiste em criar clones idênticos dos dados da classe minoritária.

- **Resultado:** Causa *overfitting*. O otimizador vicia-se nas coordenadas pontuais dos clones, formando picos de confiança falsos.

Subamostragem Trivial (Erro)

Consiste em expurgar dados majoritários de maneira estocástica.

- **Resultado:** Destruição da variância. O modelo perde a representatividade estrutural da classe legítima e falha em produção por perda de massa de dados.

O Motor do SMOTE: Sobreamostragem Sintética

O **SMOTE** (*Synthetic Minority Oversampling Technique*) evita o sobreajuste gerando novas instâncias sintéticas por meio da interpolação linear no hiperespaço das características.

O Mecanismo Vetorial

Para uma instância minoritária X_i :

- 1 Identificam-se seus k vizinhos mais próximos da mesma classe.
- 2 Seleciona-se aleatoriamente um vizinho âncora (X_{viz}).
- 3 Interpola-se o novo ponto X_{novo} no vetor de conexão:

$$X_{novo} = X_i + \lambda \times (X_{viz} - X_i)$$


Onde $\lambda \in [0, 1]$ é um fator aleatório.

Impacto na Fronteira de Decisão

- **Generalização:** Cria regiões de decisão contínuas em vez de replicar pontos isolados.
- **Robustez:** Fortalece o posicionamento do hiperplano separador.
- **Mitigação de Overfitting:** Reduz o risco de o algoritmo apenas memorizar os dados existentes.

A Geometria Vetorial do Algoritmo SMOTE na Prática

Representação da álgebra vetorial. O modelo estica os polígonos de decisão.



Impacto Geométrico

- A estrela amarela (X_{novo}) nunca existiu na base bruta, mas é matematicamente coesa no domínio das fraudes.
- A malha adquire solidez em áreas anteriormente desérticas, facilitando a convergência do hiperplano (ex: SVM ou Softmax).

O Motor do NearMiss: Subamostragem Baseada em KNN


Em vez de eliminar dados aleatoriamente, o **NearMiss** utiliza distâncias euclidianas para selecionar estrategicamente quais instâncias da classe majoritária serão mantidas na fronteira de decisão.

As 3 Variantes do Algoritmo

- **NearMiss-1 (Fronteira Próxima):** Seleciona os pontos da classe majoritária com a **menor distância média** em relação aos k vizinhos mais próximos da classe minoritária.
- **NearMiss-2 (Centro de Massa):** Seleciona os pontos da classe majoritária com a **menor distância média** em relação aos k vizinhos mais distantes da classe minoritária.
- **NearMiss-3 (Poda Local):** Para cada instância minoritária, são mantidos apenas os seus k vizinhos mais próximos da classe majoritária, garantindo sobreposição controlada.

A Mecânica Espacial de Poda do Algoritmo NearMiss-1

O algoritmo limpa a matriz descartando registros redundantes e distantes, reduzindo o custo computacional do treinamento enquanto assegura a resolução na fronteira.



As 3 Arquiteturas do Algoritmo NearMiss

A seleção das instâncias da classe majoritária baseia-se em critérios geométricos distintos, definidos pelo parâmetro de versão do algoritmo:

NearMiss-1 (Fronteira)

Seleciona pontos majoritários com a **menor distância média** aos k -vizinhos minoritários mais **próximos**.

- **Foco:** Região de sobreposição de classes (*overlapping*).

NearMiss-2 (Estrutura Global)

Seleciona pontos majoritários com a **menor distância média** aos k -vizinhos minoritários mais **distantes**.

- **Foco:** Centro geométrico e distribuição global dos dados.

NearMiss-3 (Poda Local)

Isola cada instância **minoritária** e retém exclusivamente seus k -vizinhos **majoritários** mais próximos.

- **Foco:** Eliminação de ruídos e isolamento local.

O Lab Prático de Produção: Fraudes em Cartão

Estrutura do experimento com o dataset financeiro `creditcard.csv`.

- **Topologia Analítica:** 284.807 registros em RAM com 492 vetores anômalos (taxa de 0.17% de falsificação).

O Framework de Otimização em Python

- 1 **Isolamento de Base:** Declarar o split (80-20) com controle estrito `stratify=y`.
- 2 **Aferição Nominal (Baseline):** Executar a Regressão Logística inicial nas submatrizes brutas. Registrar a Sensibilidade e F1-Score primários.
- 3 **Injeção Geométrica:** Submeter os arrays iterados unicamente do grupo de Treino às sub-rotinas da biblioteca `imblearn` (SMOTE).
- 4 **Validação Crítica:** Testar o novo otimizador nos 20% isolados.

O Paradoxo do Aprendizado: Vazamento de Dados (Data Leakage)

O Erro Metodológico

Aplicar técnicas de sobreamostragem (SMOTE) ou redimensionamento (*Scaling*) no conjunto de dados completo **antes** da separação entre treino e teste (`train_test_split`).

A Contaminação Estatística dos Dados

- **Mecanismo de Falha:** A interpolação do SMOTE utiliza informações de pontos que farão parte do teste. Ao dividir os dados a posteriori, o conjunto de teste conterá informações sintéticas geradas a partir de si mesmo.
- **Impacto no Laboratório:** Métricas artificialmente infladas (ex: F1-Score de 99,9%), causadas pelo sobreajuste (*overfitting*) às informações vazadas.
- **Impacto em Produção (*Deploy*):** Queda drástica no desempenho real do modelo, devido à incapacidade de generalizar para dados verdadeiramente inéditos.

Isolamento do Vazamento de Dados (Data Leakage)


Fluxograma arquitetural da validação cruzada: isolamento estrito do conjunto de teste durante a reamostragem.

ARQUITETURA FALHA (Leakage)



Validação Corrompida:
Os nós de Teste foram empregados para gerar os nós de Treino.

ARQUITETURA DE PRODUÇÃO



Mundo Real:
Desbalanceamento
(Intocado)

Diretrizes para Validação de Modelos Desbalanceados

- ❶ **Rejeição da Acurácia Global:** Em cenários de alta assimetria (fraudes, diagnósticos, falhas), a acurácia isolada é uma métrica enganosa e inválida para homologação.
- ❷ **Otimização via Trade-off:** Avalie e aprove o modelo com base no equilíbrio entre Precisão e Sensibilidade, utilizando o **F1-Score** ou as **Curvas Precisão-Sensibilidade**.
- ❸ **Divisão Estratificada:** Aplique `stratify=y` no `train_test_split` antes de qualquer transformação ou reamostragem, preservando as proporções das classes.
- ❹ **Isolamento do SMOTE:** Restrinja o uso do `imblearn.SMOTE` exclusivamente ao conjunto de treino (X_{train}, y_{train}), mitigando o vazamento de dados (*data leakage*).
- ❺ **Validação em Cenário Real:** Avalie o conjunto de teste mantendo a distribuição e a rarefação estatística original das classes, garantindo a capacidade de generalização.

Materiais de Apoio e Referências

- **GÉRON, Aurélien.** *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn & TensorFlow.* Capítulo 3: Classificação (Métricas de desempenho, Trade-off precisão/sensibilidade, Curva ROC).
- **FACELI, Katti et al.** *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina.* Capítulo de Avaliação de Modelos e Técnicas de Reamostragem.