

Lista de Exercícios

Cálculo de Entropia e Ganho de Informação

Árvores de Decisão (Aula 12)

Disciplina: Aprendizado de Máquina

Semestre Letivo

Formulário

Para uma variável alvo categórica y com C classes e N amostras totais no nó S :

1. **Proporção da Classe i (p_i):** $p_i = \frac{N_i}{N}$, onde $\sum_{i=1}^C p_i = 1,0$.

2. **Entropia de Shannon (em bits):**

$$H(S) = - \sum_{i=1}^C p_i \log_2(p_i) = - \sum_{i=1}^C p_i \frac{\ln(p_i)}{\ln(2)} \quad (\text{Convenção: } 0 \log_2 0 = 0)$$

3. **Índice de Gini:**

$$Gini(S) = 1 - \sum_{i=1}^C p_i^2$$

4. **Média Ponderada da Impureza dos Filhos (após divisão pelo atributo A):**

$$H_{\text{ponderada}}(S, A) = \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad \text{e} \quad Gini_{\text{ponderado}}(S, A) = \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} Gini(S_v)$$

5. **Ganho de Informação (IG) e Redução do Índice de Gini ($\Delta Gini$):**

$$IG(S, A) = H(S) - H_{\text{ponderada}}(S, A) \quad \text{e} \quad \Delta Gini(S, A) = Gini(S) - Gini_{\text{ponderado}}(S, A)$$

Exemplo (Decisão de Jogar Tênis)

Considere o conjunto de dados simplificado com $N = 10$ amostras para prever se um atleta irá jogar tênis ($y \in \{\text{Sim}, \text{Não}\}$) com base na condição do **Clima** ($X_1 \in \{\text{Sol}, \text{Chuva}\}$):

Amostra	Atributo X_1 (Clima)	Classe Alvo y (Jogar)
1	Sol	Não
2	Sol	Sim
3	Sol	Sim
4	Sol	Sim
5	Sol	Sim
6	Sol	Sim
7	Chuva	Não
8	Chuva	Não
9	Chuva	Não
10	Chuva	Sim

PASSO 1: Cálculo da Impureza do Nó Pai (S)

• **1.1. Frequências e Proporções:** Total $N = 10$.

- Classe $y = \text{Sim}$: $N_{\text{Sim}} = 6 \implies p_1 = \frac{6}{10} = 0,6000$.
- Classe $y = \text{Não}$: $N_{\text{Não}} = 4 \implies p_0 = \frac{4}{10} = 0,4000$.

• **1.2. Cálculo Detalhado da Entropia de Shannon $H(S)$:**

- Logaritmos na base 2: $\log_2(0,6000) = \frac{\ln(0,6000)}{\ln(2)} = \frac{-0,5108256}{0,6931472} = -0,7369656 \approx -0,7370$.
 $\log_2(0,4000) = \frac{\ln(0,4000)}{\ln(2)} = \frac{-0,9162907}{0,6931472} = -1,3219281 \approx -1,3219$.
- Produtos $p_i \cdot \log_2(p_i)$:
 Termo (Sim): $0,6000 \times (-0,7369656) = -0,4421794 \approx -0,4422$.
 Termo (Não): $0,4000 \times (-1,3219281) = -0,5287712 \approx -0,5288$.
- Somatório e Inversão de Sinal:

$$H(S) = - [(-0,4421794) + (-0,5287712)] = - [-0,9709506] = \mathbf{0,9710 \text{ bits}}$$

• **1.3. Cálculo Detalhado do Índice de Gini $Gini(S)$:**

- Quadrados das proporções: $p_1^2 = (0,6000)^2 = 0,3600$ e $p_0^2 = (0,4000)^2 = 0,1600$.
- Soma dos quadrados: $p_1^2 + p_0^2 = 0,3600 + 0,1600 = 0,5200$.
- Subtração da unidade:

$$Gini(S) = 1 - 0,5200 = \mathbf{0,4800}$$

PASSO 2: Impureza dos Sub-Nós Filhos após a Divisão por X_1 (Clima)

• **2.1. Sub-Nó Clima = Sol ($N_{\text{Sol}} = 6$):**

- Contagem: 5 "Sim" ($p_1 = \frac{5}{6} \approx 0,8333333$) e 1 "Não" ($p_0 = \frac{1}{6} \approx 0,1666667$).
- **Entropia $H(\text{Sol})$:**
 $\log_2(5/6) = -0,2630344 \implies \frac{5}{6} \times (-0,2630344) = -0,2191953$.
 $\log_2(1/6) = -2,5849625 \implies \frac{1}{6} \times (-2,5849625) = -0,4308271$.
 $H(\text{Sol}) = - [-0,2191953 + (-0,4308271)] = - [-0,6500224] = \mathbf{0,6500 \text{ bits}}$.
- **Índice de Gini $Gini(\text{Sol})$:**
 $p_1^2 = (5/6)^2 = \frac{25}{36} \approx 0,6944444$ e $p_0^2 = (1/6)^2 = \frac{1}{36} \approx 0,0277778$.
 $Gini(\text{Sol}) = 1 - (\frac{25}{36} + \frac{1}{36}) = 1 - \frac{26}{36} = \frac{10}{36} = \mathbf{0,2778}$.

• **2.2. Sub-Nó Clima = Chuva ($N_{\text{Chuva}} = 4$):**

- Contagem: 1 "Sim" ($p_1 = \frac{1}{4} = 0,2500$) e 3 "Não" ($p_0 = \frac{3}{4} = 0,7500$).
- **Entropia $H(\text{Chuva})$:**
 $\log_2(0,25) = -2,0000 \implies 0,25 \times (-2,0000) = -0,5000$.
 $\log_2(0,75) = -0,4150375 \implies 0,75 \times (-0,4150375) = -0,3112781$.
 $H(\text{Chuva}) = - [-0,5000 + (-0,3112781)] = - [-0,8112781] = \mathbf{0,8113 \text{ bits}}$.
- **Índice de Gini $Gini(\text{Chuva})$:**
 $p_1^2 = 0,25^2 = 0,0625$ e $p_0^2 = 0,75^2 = 0,5625$.
 $Gini(\text{Chuva}) = 1 - (0,0625 + 0,5625) = 1 - 0,6250 = \mathbf{0,3750}$.

PASSO 3: Médias Ponderadas e Ganhos de Impureza

- **3.1. Proporções de Ponderação dos Ramos:**

Ramo Sol: $w_{\text{Sol}} = \frac{6}{10} = 0,6000$. Ramo Chuva: $w_{\text{Chuva}} = \frac{4}{10} = 0,4000$.

- **3.2. Entropia Ponderada e Ganho de Informação (IG):**

$$H_{\text{pond}}(S, \text{Clima}) = 0,6000 \times 0,6500224 + 0,4000 \times 0,8112781 = 0,3900134 + 0,3245112 = \mathbf{0,7145} \text{ bits}$$

$$IG(S, \text{Clima}) = H(S) - H_{\text{pond}}(S, \text{Clima}) = 0,9709506 - 0,7145246 = \mathbf{0,2564} \text{ bits}$$

- **3.3. Gini Ponderado e Redução de Gini ($\Delta Gini$):**

$$Gini_{\text{pond}}(S, \text{Clima}) = 0,6000 \times \frac{10}{36} + 0,4000 \times 0,3750 = \frac{6}{10} \times \frac{5}{18} + 0,1500$$

$$Gini_{\text{pond}}(S, \text{Clima}) = \frac{1}{6} + 0,1500 = 0,1666667 + 0,1500000 = \mathbf{0,3167}$$

$$\Delta Gini(S, \text{Clima}) = Gini(S) - Gini_{\text{pond}}(S, \text{Clima}) = 0,4800 - 0,3166667 = \mathbf{0,1633}$$

Exercício 1: Análise de Risco de Crédito Bancário

Uma instituição financeira avalia $N = 8$ clientes para aprovação de empréstimo ($y \in \{\text{Sim}, \text{Não}\}$) com base na **Renda** ($X \in \{\text{Alta}, \text{Baixa}\}$):

Cliente	Renda (X)	Empréstimo Aprovado (y)
1	Alta	Sim
2	Alta	Sim
3	Alta	Sim
4	Alta	Sim
5	Baixa	Sim
6	Baixa	Não
7	Baixa	Não
8	Baixa	Não

- Calcule a Entropia $H(S)$ e o Índice de Gini $Gini(S)$ do nó pai.
- Calcule a Entropia e o Gini para cada sub-nó filho (Renda = Alta e Renda = Baixa).
- Determine o Ganho de Informação $IG(S, \text{Renda})$ e a Redução do Índice de Gini $\Delta Gini(S, \text{Renda})$.

Exercício 2: Diagnóstico de Falha em Equipamento Industrial

Uma equipe de manutenção monitora $N = 10$ máquinas industriais para diagnosticar **Falha no Equipamento** ($y \in \{\text{Sim}, \text{Não}\}$) a partir da **Temperatura** ($X \in \{\text{Alta}, \text{Normal}\}$):

Máquina	Temperatura (X)	Ocorreu Falha? (y)
1	Alta	Sim
2	Alta	Sim
3	Alta	Sim
4	Alta	Sim
5	Alta	Não
6	Normal	Sim
7	Normal	Não
8	Normal	Não
9	Normal	Não
10	Normal	Não

- Calcule a Entropia $H(S)$ e o Índice de Gini $Gini(S)$ do nó pai.
- Calcule a Entropia e o Gini para cada sub-nó filho (Temperatura = Alta e Temperatura = Normal).
- Determine o Ganho de Informação $IG(S, \text{Temperatura})$ e a Redução do Índice de Gini $\Delta Gini(S, \text{Temperatura})$.

Exercício 3: Filtro de Detecção de Spam em E-mails

Um servidor de e-mails analisa $N = 12$ mensagens para classificação em **Spam** ($y \in \{\text{Sim}, \text{Não}\}$) com base na presença da palavra-chave **"Oferta"** ($X \in \{\text{Sim}, \text{Não}\}$):

E-mail	Contém “Oferta”? (X)	É Spam? (y)
1	Sim	Sim
2	Sim	Sim
3	Sim	Sim
4	Sim	Sim
5	Sim	Sim
6	Sim	Não
7	Não	Sim
8	Não	Sim
9	Não	Não
10	Não	Não
11	Não	Não
12	Não	Não

- Calcule a Entropia $H(S)$ e o Índice de Gini $Gini(S)$ do nó pai.
- Calcule a Entropia e o Gini para cada sub-nó filho (Oferta = Sim e Oferta = Não).
- Determine o Ganho de Informação $IG(S, \text{Oferta})$ e a Redução do Índice de Gini $\Delta Gini(S, \text{Oferta})$.

Exercício 4: Predição de Churn (Cancelamento de Clientes)

Uma empresa de SaaS analisa $N = 10$ clientes para prever o **Cancelamento da Assinatura (Churn)** ($y \in \{\text{Sim}, \text{Não}\}$) com base no tempo de **Fidelidade** ($X \in \{\text{Alta}, \text{Baixa}\}$):

Cliente	Fidelidade (X)	Cancelou Assinatura? (y)
1	Alta	Não
2	Alta	Não
3	Alta	Não
4	Alta	Não
5	Alta	Não
6	Baixa	Sim
7	Baixa	Sim
8	Baixa	Sim
9	Baixa	Sim
10	Baixa	Não

- Calcule a Entropia $H(S)$ e o Índice de Gini $Gini(S)$ do nó pai.
- Calcule a Entropia e o Gini para cada sub-nó filho (Fidelidade = Alta e Fidelidade = Baixa).
- Determine o Ganho de Informação $IG(S, \text{Fidelidade})$ e a Redução do Índice de Gini $\Delta Gini(S, \text{Fidelidade})$.