Métodos de Conjunto — Parte I

Paradigma de Comitês, Amostragem Bootstrap e Agregação Bagging

Prof. Rodrigo

Instituto Federal de São Paulo - IFSP Campus Guarulhos
Disciplina de Aprendizado de Máquina

Semestre Letivo

Objetivos de Aprendizagem — Parte I

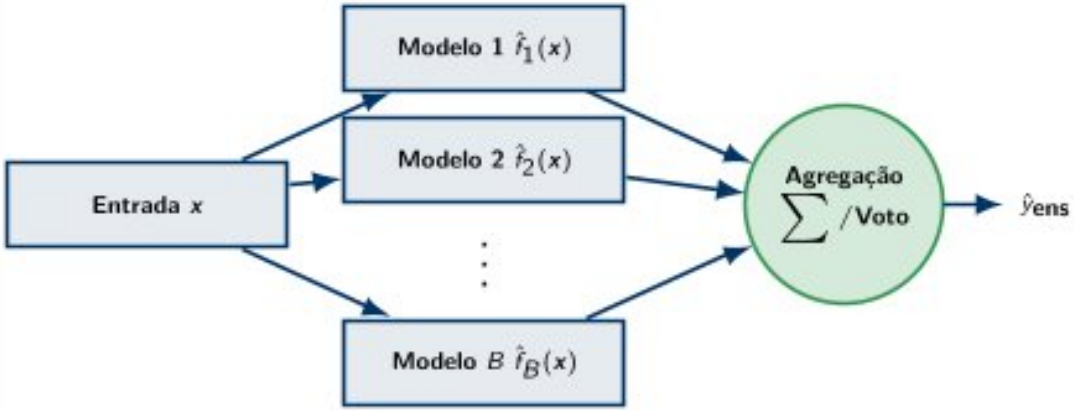
Ao final desta primeira parte, o aluno será capaz de:

1. **Entender o Teorema de Condorcet e o Paradigma de Ensemble:** Compreender como comitês de aprendizes fracos superam preditores individuais e distinguir ensembles paralelos de sequenciais.
2. **Mapear a Decomposição Viés-Variância e a Desigualdade de Jensen:** Provar analítica e geometricamente que a agregação reduz estritamente o *MSE* ($MSE(f_A) \leq MSE(\hat{f})$).
3. **Derivar a Amostragem Bootstrap e a Probabilidade OOB:** Demonstrar o limite assintótico $P(\text{OOB}) = (1 - 1/N)^N \to 1/e \approx 36{,}8\%$ e diferenciar Bagging, Pasting, Random Subspaces e Random Patches.
4. **Dominar a Agregação e Provar o Piso de Variância no Bagging:** Contrastar Votação Rígida (*Hard*) e Suave (*Soft*) e derivar $\text{Var}(\hat{f}_{\text{bag}}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$, identificando o limite de correlação $\rho\sigma^2$.

O Paradigma de Ensemble e o Princípio do Comitê

Sabedoria das Multidões

- **Aprendizes Fracos (*Weak Learners*):** Modelos individuais com desempenho ligeiramente superior ao chute aleatório ($> 50\%$ de acurácia em problemas binários).
- **Preditor Forte (*Strong Learner*):** A combinação das predições de um comitê diversificado reduz a taxa de erro global.
- **Requisito Fundamental:** Os erros dos estimadores individuais devem ser **descorrelacionados** entre si (errar em amostras diferentes).



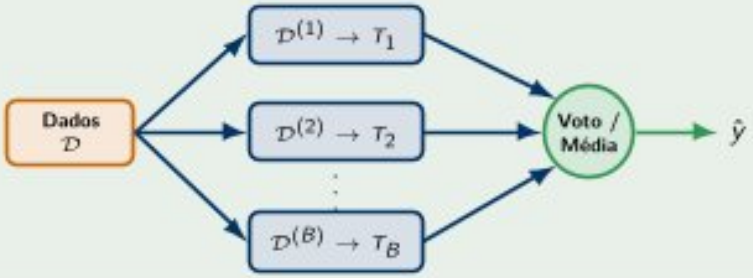
Fonte: Adaptado de Faceli & Lorena (2021) e Géron (2021).

Taxonomia dos Ensembles: Paralelos vs. Sequenciais

Antes de aprofundarmos no *Bagging*, é fundamental situar as duas grandes famílias de métodos de conjunto na literatura:

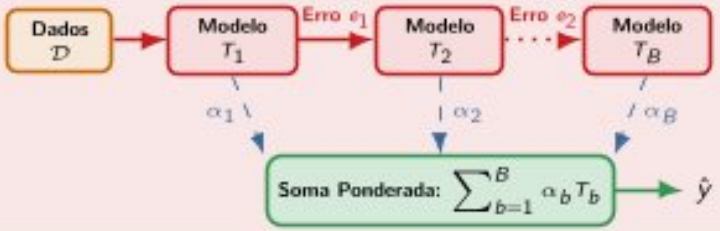
1. Ensembles Paralelos

- **Exemplos:** Bagging, Pasting, Random Forests, Extra-Trees.
- **Como funcionam:** Treinam modelos **independentemente em paralelo** sobre subamostras dos dados.
- **Alvo estatístico: Reduzir a Variância** (estabilizar modelos profundos e complexos que sofrem de *overfitting*, como árvores não-podadas).



2. Ensembles Sequenciais

- **Exemplos:** AdaBoost, Gradient Boosting, XGBoost.
- **Como funcionam:** Treinam modelos **em fila (sequencialmente)**, onde o modelo b foca em corrigir os erros residuais cometidos pelo modelo $b-1$.
- **Alvo estatístico: Reduzir o Viés** (combinar modelos rasos e fracos que sofrem de *underfitting*, como *stumps* de 1 nível).



O Teorema do Júri de Condorcet (1785)

Formulação Teórica do Voto Majoritário

Se um comitê é composto por B jurados/modelos **independentes**, onde cada um tem probabilidade $p > 0{,}5$ de tomar a decisão correta, a probabilidade P_{maj} de o voto majoritário acertar é dada pelo somatório da distribuição binomial:

$$P_{\text{maj}} = \sum_{k=\lfloor B/2 \rfloor + 1}^{B} \binom{B}{k} p^k (1-p)^{B-k}$$

Tabela: Probabilidade do Voto Majoritário P_{maj} em Função da Acurácia Individual p e do Tamanho do Comitê B

Tamanho do Comitê (B)	$p = 0{,}51$ **(Inseguro)**	$p = 0{,}60$ **(Moderado)**	$p = 0{,}70$ **(Bom)**	$p = 0{,}80$ **(Forte)**
$B = 1$ (Individual)	51,00%	60,00%	70,00%	80,00%
$B = 11$	52,60%	73,34%	91,15%	98,83%
$B = 101$	57,96%	97,92%	99,99%	100,00%
$B = 1000$	**73,00%**	**100,00%**	**100,00%**	**100,00%**

Conclusão: Se os modelos forem independentes e melhores que o chute aleatório ($p > 0{,}5$), aumentar B garante convergência para 100% de acurácia!

Intuição de Condorcet: O Papel da Independência

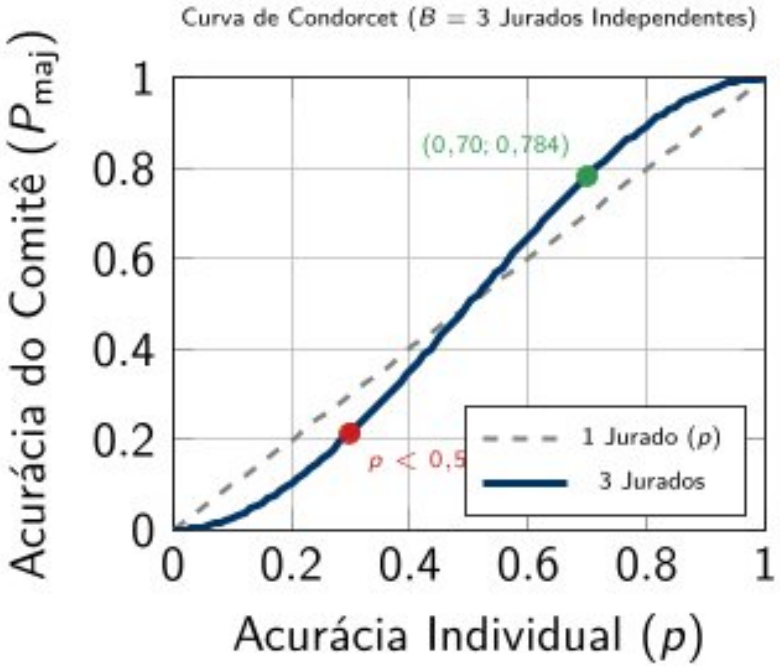
Cálculo para $B = 3$ Jurados Independentes ($p = 0{,}7$)

A maioria vence se **exatamente 2** acertarem OU se **todos os 3** acertarem:

- $P(\text{3 acertos}) = 0{,}7^3 = 0{,}343$ (34,3%)
- $P(\text{2 acertos e 1 erro}) = \binom{3}{2}(0{,}7)^2(0{,}3)^1 = 3 \times 0{,}147 = 0{,}441$ (44,1%)
- $\mathbf{P_{maj} = 0{,}343 + 0{,}441 = 0{,}784}$ **(78,4% > 70%)**

E se os 3 modelos forem clones idênticos?

Se treinarmos a mesma árvore 3 vezes sobre os mesmos dados, elas serão 100% correlacionadas: quando uma acerta, todas acertam; quando uma erra, todas erram juntas. A acurácia do comitê continua estagnada em **70%**!



Atenção: Se $p < 0{,}5$, a votação amplifica o erro ($P_{maj} \to 0$).

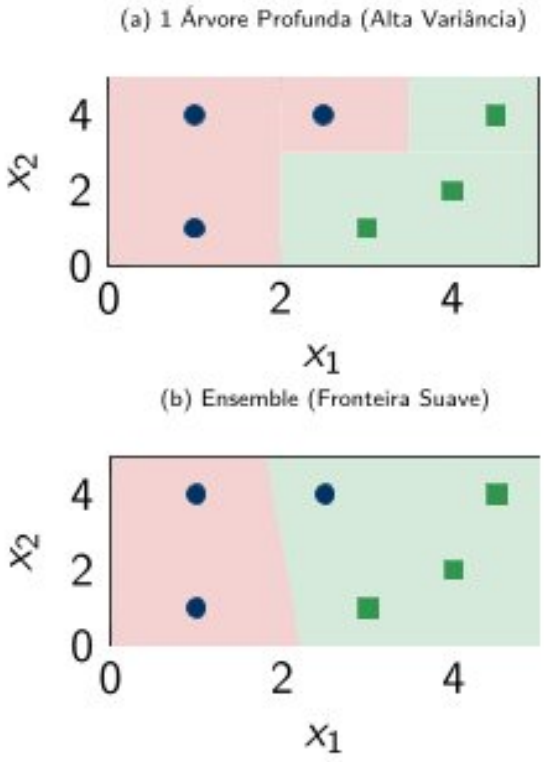
Decomposição Viés-Variância e Instabilidade em Árvores

Decomposição Formal do Erro Quadrático Médio

$$E\left[(y-\hat{f}(x))^2\right] = \underbrace{\left(f(x)-E[\hat{f}(x)]\right)^2}_{\text{Viés}^2} + \underbrace{E\left[(\hat{f}(x)-E[\hat{f}(x)])^2\right]}_{\text{Variância}} + \sigma^2$$

Diagnóstico das Árvores Não-Podadas

- **Baixo Viés:** Árvores profundas particionam o espaço em retângulos minúsculos, adaptando-se a fronteiras complexas.
- **Alta Variância:** Pequenas alterações nos dados de treino mudam totalmente os nós de corte.
- **Objetivo do Bagging:** Tomar modelos de **baixo viés e alta variância** e reduzir sua variância sem elevar o viés.



Fundamentação Matemática: A Desigualdade de Jensen

Prova de Breiman (1996a) para a Redução do Erro de Agregação

Seja $\hat{f}(\boldsymbol{x} \mid \mathcal{D})$ um estimador treinado sobre o dataset aleatório $\mathcal{D}$, e seja $f_A(\boldsymbol{x}) = E_{\mathcal{D}}[\hat{f}(\boldsymbol{x} \mid \mathcal{D})]$ o estimador ideal agregado pela média sobre todas as possíveis amostragens.

Aplicação da Desigualdade de Jensen para Funções Convexas

A função de perda quadrática $g(u) = u^2$ é estritamente convexa ($g''(u) = 2 > 0$). Pela **Desigualdade de Jensen** ($E[g(U)] \geq g(E[U])$):

$$E_{\mathcal{D}}\left[\left(y - \hat{f}(\boldsymbol{x} \mid \mathcal{D})\right)^2\right] \geq \left(E_{\mathcal{D}}\left[y - \hat{f}(\boldsymbol{x} \mid \mathcal{D})\right]\right)^2 = (y - f_A(\boldsymbol{x}))^2$$

Conclusão Teórica Fundamental

Tomando a esperança em relação a y, o Erro Quadrático Médio do modelo agregado $f_A(\boldsymbol{x})$ é **estritamente menor ou igual** ao erro esperado de um modelo individual $\hat{f}$:

$$\mathbf{MSE}(\mathbf{f_A}(\boldsymbol{x})) \leq \mathbf{MSE}(\widehat{\mathbf{f}}(\boldsymbol{x}))$$

Intuição Visual e Numérica da Desigualdade de Jensen

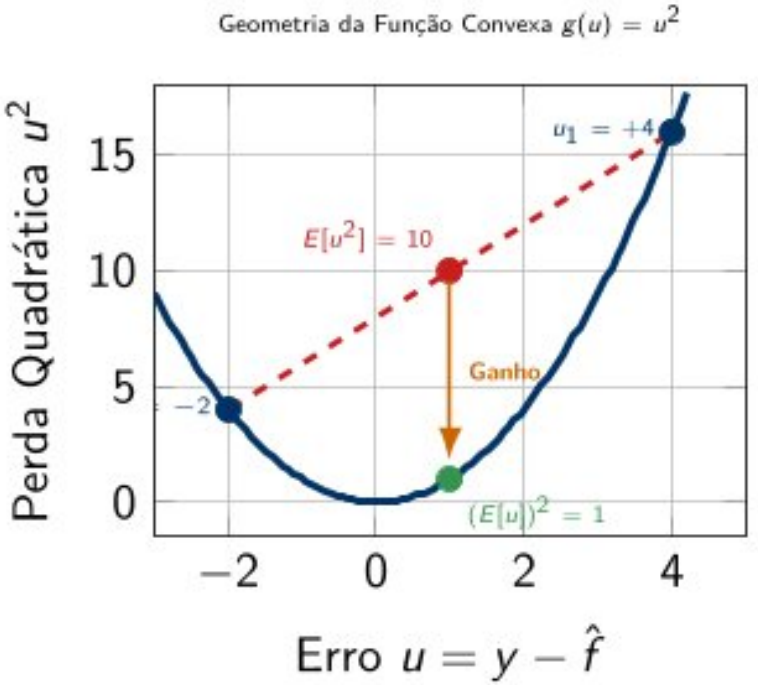
Exemplo Numérico Concreto

Suponha que o valor real seja $y = 10$. Temos 2 árvores instáveis:

- **Árvore 1:** prevê
  $\hat{f}_1 = 6 \implies$ Erro $u_1 = 10 - 6 = +4 \implies u_1^2 = 16$.
- **Árvore 2:** prevê
  $\hat{f}_2 = 12 \implies$ Erro $u_2 = 10 - 12 = -2 \implies u_2^2 = 4$.

Comparando Erro Médio vs. Erro da Média:

- **Média dos Erros Individuais ($E[u^2]$):** $\frac{16+4}{2} = \mathbf{10{,}0}$.
- **Predição do Ensemble (f_A):**
  $\frac{6+12}{2} = 9 \implies$ Erro $E[u] = 10 - 9 = +1$.
- **Erro Quadrático do Ensemble ($(E[u])^2$):**
  $1^2 = \mathbf{1{,}0} \ll \mathbf{10{,}0}$!



Erros positivos $(+4)$ e negativos (-2) cancelam-se parcialmente antes de serem elevados ao quadrado!

Amostragem Bootstrap

Conceito e Procedimento

Dada a base original
$\mathcal{D} = \{(\boldsymbol{x}^{(1)}, y^{(1)}), \ldots, (\boldsymbol{x}^{(N)}, y^{(N)})\}$ com N amostras:

- Geram-se B amostras bootstrap $\mathcal{D}^{(1)}, \ldots, \mathcal{D}^{(B)}$.
- Cada amostra bootstrap é formada por N **sorteios aleatórios com reposição** (*with replacement*).
- A cada sorteio, qualquer exemplo de $\mathcal{D}$ tem probabilidade constante $1/N$ de ser escolhido.

Consequência da Reposição

Em uma amostra bootstrap $\mathcal{D}^{(b)}$, alguns exemplos originais aparecem duplicados/triplicados, enquanto outros ficam de fora (amostras Out-of-Bag).

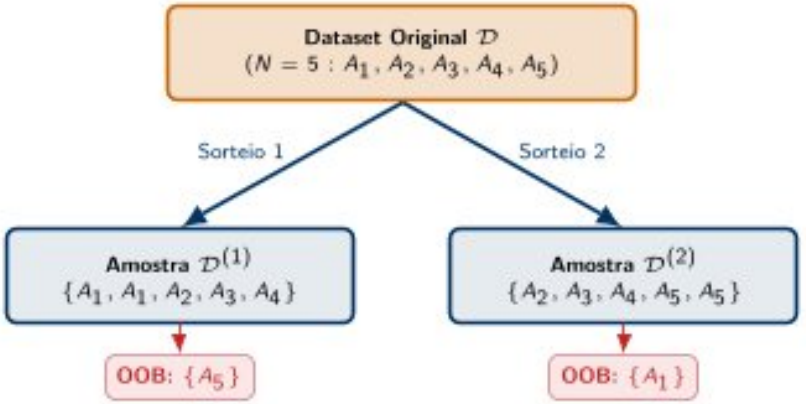


Figura: Geração de amostras bootstrap com reposição.

Dedução Matemática da Probabilidade Out-of-Bag (OOB)

Passo a Passo da Derivação do Limite OOB

Para um dataset com N exemplos:

1. **Probabilidade de NÃO ser sorteada em 1 tentativa:** $P(\text{não sorteada}) = 1 - \frac{1}{N}$.
2. **Probabilidade de NÃO ser sorteada nas N tentativas independentes:**

$$P(\text{amostra é OOB}) = \left(1 - \frac{1}{N}\right)^N$$

3. **Limite Assintótico quando $N \to \infty$ (Definição do Número de Euler e):**

$$\lim_{N \to \infty} \left(1 - \frac{1}{N}\right)^N = e^{-1} = \frac{1}{e} \approx 0{,}367879... \quad (\approx \mathbf{36{,}8\%})$$

Interpretação Prática

- Em média, cada amostra bootstrap contém aproximadamente 63,2% dos exemplos únicos de treino.
- Os 36,8% exemplos restantes nunca participam do treino daquela árvore e formam um conjunto de validação **Out-of-Bag (OOB)** totalmente gratuito e sem viés de contaminação.

Convergência da Probabilidade OOB para N Finito

Sensibilidade ao Tamanho do Dataset (N)

A fórmula $(1 - 1/N)^N$ converge extremamente rápido para $1/e \approx 0{,}36788$. Mesmo para datasets minúsculos, a porcentagem de amostras OOB estabiliza em cerca de 36,8%.

Tabela: Evolução da Probabilidade OOB em Função do Número de Amostras (N)

Tamanho do Dataset (N)	$P(\textbf{OOB}) = (1 - 1/N)^N$	**% OOB**	**% Treino (Bootstrap)**
$N = 2$	$(1/2)^2 = 0{,}25000$	25,00%	75,00%
$N = 3$	$(2/3)^3 \approx 0{,}29630$	29,63%	70,37%
$N = 5$	$(4/5)^5 = 0{,}32768$	32,77%	67,23%
$N = 10$	$(9/10)^{10} \approx 0{,}34868$	34,87%	65,13%
$N = 100$	$(99/100)^{100} \approx 0{,}36603$	36,60%	63,40%
$N = 1000$	$(999/1000)^{1000} \approx 0{,}36770$	36,77%	63,23%
$N \to \infty$	$\mathbf{1/e \approx 0{,}36788}$	**36,79%**	**63,21%**

Modalidades de Amostragem em Comitês

Dependendo de **como** sorteamos as linhas (amostras) e as colunas (atributos) antes de treinar cada estimador base no `BaggingClassifier`, a literatura define quatro arquiteturas:

Nomenclatura	Amostras (Linhas)	Atributos (Colunas)	Configuração no Scikit-Learn
Bagging (*Bootstrap Aggregating*)	Com reposição (100%)	Todos (100%)	`bootstrap=True, max_features=1.0`
Pasting (Colagem)	Sem reposição ($< 100\%$)	Todos (100%)	`bootstrap=False, max_samples=0.8`
Random Subspaces (Subespaços Aleatórios)	Todas (100% fixo)	Subconjunto sorteado para a árvore toda	`bootstrap=False, max_samples=1.0, max_features=0.5`
Random Patches (Retalhos Aleatórios)	Com reposição	Subconjunto sorteado para a árvore toda	`bootstrap=True, max_features=0.5`

Diferença: Random Subspaces vs. Random Forest

No *Random Subspaces*, os atributos são sorteados **uma única vez para a árvore inteira**. Na **Random Forest**, um novo subconjunto de $m = \sqrt{d}$ atributos é sorteado **independentemente a cada nó interno**!

Formalização dos Mecanismos de Agregação

Dada uma coleção de B estimadores $\hat{f}^{(1)}, \hat{f}^{(2)}, \ldots, \hat{f}^{(B)}$ treinados sobre suas respectivas amostras bootstrap $\mathcal{D}^{(1)}, \ldots, \mathcal{D}^{(B)}$:

1. Regressão (Média Aritmética)

$$\hat{f}_{\text{bag}}(\boldsymbol{x}) = \frac{1}{B} \sum_{b=1}^{B} \hat{f}^{(b)}(\boldsymbol{x})$$

2. Classificação: Votação Rígida / Majoritária (*Hard Voting*)

$$\hat{y}_{\text{bag}}(\boldsymbol{x}) = \arg\max_{c \in \mathcal{C}} \sum_{b=1}^{B} \mathbf{1}\left(\hat{f}^{(b)}(\boldsymbol{x}) == c\right)$$

3. Classificação: Votação Suave (*Soft Voting*)

$$P_{\text{bag}}(y = c \mid \boldsymbol{x}) = \frac{1}{B} \sum_{b=1}^{B} P^{(b)}(y = c \mid \boldsymbol{x})$$

$$\hat{y}_{\text{bag}}(\boldsymbol{x}) = \arg\max_{c \in \mathcal{C}} P_{\text{bag}}(y = c \mid \boldsymbol{x})$$

Vantagem da Votação Suave (*Soft Voting*)

Pondera a certeza de cada árvore pela média das probabilidades, sendo superior à Votação Rígida quando as árvores fornecem probabilidades bem calibradas.

Hard Voting vs. Soft Voting: Por que o Soft Voting Inverte Decisões?

Considere um comitê com $B = 3$ árvores prevendo a probabilidade da **Classe 1** para uma amostra $\boldsymbol{x}$:

Predições de Probabilidade das Árvores

- **Árvore** T_1: $P^{(1)}(y = 1) = \mathbf{0{,}99}$ (Alta Confiança em C1)
- **Árvore** T_2: $P^{(2)}(y = 1) = \mathbf{0{,}45}$ (Ligeira Tendência C0)
- **Árvore** T_3: $P^{(3)}(y = 1) = \mathbf{0{,}45}$ (Ligeira Tendência C0)

Comparativo dos Resultados

- **Hard Voting (Decisões Discretas):**
  - $T_1 \rightarrow$ Classe 1, $T_2 \rightarrow$ Classe 0, $T_3 \rightarrow$ Classe 0.
  - **Decisão Hard Voting:** Classe **0** (2 votos contra 1).
- **Soft Voting (Média das Probabilidades):**
  - $P_{\text{méd}} = \frac{0{,}99+0{,}45+0{,}45}{3} = \frac{1{,}89}{3} = \mathbf{0{,}63} > 0{,}5$.
  - **Decisão Soft Voting:** Classe **1**.

Conclusão: O Soft Voting evita que duas árvores "inseguras" ganhem de uma árvore "convicta". No Scikit-Learn, o `RandomForestClassifier` usa *Soft Voting* por padrão!

Prova Algébrica da Redução de Variância (Caso Ideal i.i.d.)

Teorema: Variância da Média de Estimadores i.i.d.

Sejam $\hat{f}^{(1)}, \ldots, \hat{f}^{(B)}$ B estimadores **independentes e identicamente distribuídos** (i.i.d.), cada um com variância $\text{Var}(\hat{f}^{(b)}) = \sigma^2$.

Demonstração.

Pelas propriedades do operador variância para variáveis independentes ($\text{Var}(cX) = c^2\text{Var}(X)$) e como todas as B árvores possuem a mesma variância σ^2:

$$\text{Var}(\hat{f}_{\text{bag}}) = \text{Var}\left(\frac{1}{B}\sum_{b=1}^{B}\hat{f}^{(b)}\right) = \frac{1}{B^2}\sum_{b=1}^{B}\text{Var}(\hat{f}^{(b)}) = \frac{1}{B^2}\cdot\left(B\sigma^2\right) = \frac{\sigma^2}{\mathbf{B}}$$

□

Conclusão do Caso Ideal

Se as árvores do comitê fossem totalmente independentes entre si, a variância do conjunto **decaeria a zero** à medida que $B \to \infty$.

De Onde Vem a Covariância? A Matriz $B \times B$ de Estimadores

Quando os estimadores **não são independentes**, a variância da soma exige somar todos os pares (i, j) da Matriz de Covariância de dimensão $B \times B$:

$$\begin{bmatrix} \sigma^2 & \rho\sigma^2 & \cdots & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 & \cdots & \rho\sigma^2 \\ \vdots & \vdots & \ddots & \vdots \\ \rho\sigma^2 & \rho\sigma^2 & \cdots & \sigma^2 \end{bmatrix}$$

- **Total de células na matriz:** $B \times B = B^2$.
- **Diagonal Principal (Azul):** B termos de variância pura $\text{Cov}(\hat{f}^{(i)}, \hat{f}^{(i)}) = \sigma^2$.
- **Fora da Diagonal (Vermelho):** $B^2 - B = \mathbf{B(B-1)}$ termos de covariância $\text{Cov}(\hat{f}^{(i)}, \hat{f}^{(j)}) = \rho\sigma^2$.

Somando Todas as Células e Dividindo por B^2

$$\begin{aligned} \text{Var}\left(\frac{1}{B}\sum_{b=1}^{B}\hat{f}^{(b)}\right) &= \frac{1}{B^2}\Big[\underbrace{B\sigma^2}_{\text{Diagonal}} + \underbrace{B(B-1)\rho\sigma^2}_{\text{Fora da Diagonal}}\Big] \\ &= \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2 \\ &= \frac{\sigma^2}{B} + \rho\sigma^2 - \frac{\rho\sigma^2}{B} \\ &= \rho\sigma^2 + \frac{\mathbf{1}-\rho}{\mathbf{B}}\sigma^2 \end{aligned}$$

O Piso de Variância ($\rho\sigma^2$) em Estimadores Correlacionados

Caso Real: Estimadores com Correlação $\rho > 0$

Como as amostras bootstrap são extraídas do mesmo dataset original $\mathcal{D}$ (compartilhando cerca de $63{,}2\% \times 63{,}2\% \approx 40\%$ de exemplos em comum), as árvores $\hat{f}^{(b)}$ não são independentes; possuem correlação par a par $\rho = \text{Corr}(\hat{f}^{(i)}, \hat{f}^{(j)}) > 0$.

Dedução Analítica da Variância Correlacionada

Expandindo a variância da soma com B termos diagonais e $B(B-1)$ termos de covariância $\text{Cov}(X_i, X_j) = \rho\sigma^2$:

$$\text{Var}(\hat{f}_{\text{bag}}) = \frac{1}{B^2}\left[B\sigma^2 + B(B-1)\rho\sigma^2\right] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

Tomando o limite quando o número de árvores cresce ($B \to \infty$):

$$\lim_{B\to\infty} \text{Var}(\hat{f}_{\text{bag}}) = \rho\sigma^2$$

Síntese da Parte I e o Desafio para a Parte II

O que conquistamos com o Bagging?

- Provamos via **Desigualdade de Jensen** que agregar árvores instáveis reduz o Erro Quadrático Médio sem elevar o viés.
- Vimos que a amostragem **Bootstrap** retém 63,2% de exemplos únicos e deixa 36,8% de fora (*Out-of-Bag*).
- Eliminamos a parcela $\frac{1-\rho}{B}\sigma^2$ da variância aumentando o número de árvores B.

O Limite Estrutural do Bagging (Ponte para a Parte II)

Mesmo com $B \to \infty$, a variância do Bagging trava no piso $\rho\sigma^2$. Na **Parte II**, veremos como as **Florestas Aleatórias (*Random Forests*)** quebram a correlação $\rho \to 0$ sorteando $m = \sqrt{d}$ atributos por nó, além de formalizarmos a validação OOB, a importância de variáveis (MDI vs. Permutação) e um exemplo manual completo.

Referências Bibliográficas

- **GÉRON, Aurélien.** *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow*. 2. ed. Alta Books, 2021.
- **FACELI, K. et al.** *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. 2. ed. LTC, 2021.
- **MORETTIN, P. A.; SINGER, J. M.** *Estatística e Ciência de Dados*. LTC, 2022.
- **LUGER, George F.** *Inteligência Artificial*. 6. ed. Pearson, 2013.