Lista de Exercícios
Método de Conjuntos
Bagging, Florestas Aleatórias e Avaliação Out-of-Bag (OOB)

Disciplina: Aprendizado de Máquina

Semestre Letivo

Exemplo 1 (Dedução da Probabilidade OOB e Limite Assintótico)

Considere um conjunto de dados de treino $\mathcal{D}$ com $N = 5$ amostras distintas.

a) Calcule a probabilidade exata de uma amostra específica $x^{(i)}$ **não ser sorteada** em uma única tentativa de amostragem.

b) Calcule a probabilidade exata de $x^{(i)}$ **não fazer parte** de um lote bootstrap de tamanho $N = 5$ (ou seja, ser uma amostra *Out-of-Bag* - OOB).

c) Determine a proporção esperada de dados de treino que compõem o lote bootstrap para $N = 5$.

d) Deduza o limite assintótico da probabilidade OOB quando $N \to \infty$ utilizando a definição do número de Euler e, e calcule o erro relativo da aproximação assintótica para $N = 5$.

Lembre-se de que a amostragem bootstrap realiza N sorteios **com reposição** (independentes e identicamente distribuídos), onde cada amostra tem probabilidade constante $1/N$ de ser selecionada em cada sorteio individual.

Resolução do Exemplo 1

a) Probabilidade em 1 tentativa: Como existem $N = 5$ amostras e o sorteio é uniforme:

$$P(\text{sortear } x^{(i)} \text{ em 1 tentativa}) = \frac{1}{N} = \frac{1}{5} = 0{,}20 \quad (20\%)$$

A probabilidade complementar de **não** sortear $x^{(i)}$ em 1 tentativa é:

$$P(\text{não sortear } x^{(i)} \text{ em 1 tentativa}) = 1 - \frac{1}{N} = 1 - \frac{1}{5} = \frac{4}{5} = 0{,}80 \quad (80\%)$$

b) Probabilidade OOB em $N = 5$ sorteios independentes: Como os $N = 5$ sorteios são independentes e com reposição:

$$P(x^{(i)} \text{ é OOB}) = P(\text{não ser sorteada nas 5 tentativas}) = \left(1 - \frac{1}{5}\right)^5 = \left(\frac{4}{5}\right)^5 = (0{,}8)^5$$

Efetuando a potência:

$$(0{,}8)^5 = 0{,}32768 \quad (\mathbf{32{,}77}\%)$$

c) Proporção de dados no lote bootstrap: A proporção de dados originais que entram no lote bootstrap é o evento complementar:

$$P(x^{(i)} \in \mathcal{D}_{\text{boot}}) = 1 - P(x^{(i)} \text{ é OOB}) = 1 - 0{,}32768 = 0{,}67232 \quad (\mathbf{67{,}23}\%)$$

d) Limite assintótico $N \to \infty$ e Erro Relativo: Pela definição do número de Euler $e = \lim_{n\to\infty}\left(1+\frac{1}{n}\right)^n$:

$$\lim_{N\to\infty} P(\text{OOB}) = \lim_{N\to\infty}\left(1-\frac{1}{N}\right)^N = e^{-1} = \frac{1}{e} \approx 0{,}367879 \quad (\approx \mathbf{36{,}79}\%)$$

O Erro Relativo da aproximação assintótica para $N = 5$ é dado por:

$$\text{Erro Relativo} = \frac{|P_{\text{exato}}(5) - P_{\text{assintótico}}|}{P_{\text{assintótico}}} = \frac{|0{,}32768 - 0{,}367879|}{0{,}367879} = \frac{0{,}040199}{0{,}367879} \approx 0{,}10927 \quad (\mathbf{10{,}93}\%)$$

Exemplo 2 (Demonstração e Aplicação da Desigualdade de Jensen)

Seja $\hat{f}(\boldsymbol{x} \mid \mathcal{D})$ um estimador treinado sobre um dataset aleatório $\mathcal{D}$, e seja $f_A(\boldsymbol{x}) = E_{\mathcal{D}}[\hat{f}(\boldsymbol{x} \mid \mathcal{D})]$ o estimador ideal agregado pela média.

a) Prove analiticamente, usando a **Desigualdade de Jensen** para funções convexas, que o Erro Quadrático Médio do modelo agregado é estritamente menor ou igual ao erro quadrático médio esperado de um modelo individual: $\text{MSE}(f_A) \leq E_{\mathcal{D}}[\text{MSE}(\hat{f})]$.

b) Considere um exemplo numérico pontual onde a resposta real é $y = 10{,}0$. Três modelos individuais treinados em lotes bootstrap fornecem as seguintes predições para um ponto $\boldsymbol{x}$:

$$\hat{f}_1(\boldsymbol{x}) = 7{,}0, \quad \hat{f}_2(\boldsymbol{x}) = 12{,}0, \quad \hat{f}_3(\boldsymbol{x}) = 14{,}0$$

Calcule o MSE médio dos modelos individuais e compare com o MSE do modelo agregado $f_A(\boldsymbol{x})$.

Resolução do Exemplo 1

a) Prova Matemática pela Desigualdade de Jensen (Breiman, 1996a): A função de perda quadrática $g(u) = (y-u)^2$ tem segunda derivada $g''(u) = 2 > 0$, sendo estritamente convexa. Pela **Desigualdade de Jensen**, para qualquer variável aleatória U e função convexa g:

$$E[g(U)] \geq g(E[U])$$

Definindo $U = \hat{f}(\boldsymbol{x} \mid \mathcal{D})$ e aplicando $g(u) = (y-u)^2$:

$$E_{\mathcal{D}}\left[\left(y - \hat{f}(\boldsymbol{x} \mid \mathcal{D})\right)^2\right] \geq \left(y - E_{\mathcal{D}}[\hat{f}(\boldsymbol{x} \mid \mathcal{D})]\right)^2 = (y - f_A(\boldsymbol{x}))^2$$

Tomando a esperança em relação a y:

$$E_{\mathcal{D}}[\text{MSE}(\hat{f})] \geq \text{MSE}(f_A) \quad \Longleftrightarrow \quad \text{MSE}(\mathbf{f_A}) \leq \mathbf{E}_{\mathcal{D}}[\text{MSE}(\hat{\mathbf{f}})] \quad \blacksquare$$

b) Exemplo Numérico Passo a Passo:

1. **Erros quadráticos dos modelos individuais ($y = 10{,}0$):**

$$(y - \hat{f}_1)^2 = (10{,}0 - 7{,}0)^2 = (3{,}0)^2 = 9{,}0$$
$$(y - \hat{f}_2)^2 = (10{,}0 - 12{,}0)^2 = (-2{,}0)^2 = 4{,}0$$
$$(y - \hat{f}_3)^2 = (10{,}0 - 14{,}0)^2 = (-4{,}0)^2 = 16{,}0$$

   MSE médio dos modelos individuais:

$$\text{MSE}_{\text{médio}} = \frac{9{,}0 + 4{,}0 + 16{,}0}{3} = \frac{29{,}0}{3} \approx \mathbf{9{,}6667}$$

2. **Predição e MSE do Modelo Agregado (f_A):**

$$f_A(\boldsymbol{x}) = \frac{\hat{f}_1 + \hat{f}_2 + \hat{f}_3}{3} = \frac{7{,}0 + 12{,}0 + 14{,}0}{3} = \frac{33{,}0}{3} = 11{,}0$$
$$\text{MSE}(f_A) = (y - f_A)^2 = (10{,}0 - 11{,}0)^2 = (-1{,}0)^2 = \mathbf{1{,}0000}$$

3. **Comparação:** $\text{MSE}(f_A) = 1{,}0000 < 9{,}6667 = \text{MSE}_{\text{médio}}$. A agregação reduziu o erro quadrático em **89,66**%!

Exemplo 3 (Dedução do Piso de Variância e Tabela de B)

Considere um comitê Bagging formado por B estimadores, onde cada árvore possui variância individual $\sigma^2 = 4{,}0$ e correlação par a par $\rho = 0{,}25$.

a) Escreva a fórmula geral da variância do ensemble correlacionado $\text{Var}(\hat{f}_{\text{bag}})$.

b) Identifique a decomposição da variância entre a componente redutível e o piso assintótico insuperável ($\rho\sigma^2$).

c) Calcule a variância do ensemble para $B \in \{1, 5, 20, 100, \infty\}$.

Resolução do Exemplo 1

a) Fórmula Geral da Variância Correlacionada: Expandindo a variância da média de B variáveis aleatórias com covariância $\text{Cov}(X_i, X_j) = \rho\sigma^2$:

$$\text{Var}(\hat{f}_{\text{bag}}) = \text{Var}\left(\frac{1}{B}\sum_{i=1}^{B}\hat{f}_i\right) = \frac{1}{B^2}\left[\sum_{i=1}^{B}\text{Var}(\hat{f}_i) + \sum_{i\neq j}\text{Cov}(\hat{f}_i, \hat{f}_j)\right]$$

Como existem B termos de variância σ^2 e $B(B-1)$ termos de covariância $\rho\sigma^2$:

$$\text{Var}(\hat{f}_{\text{bag}}) = \frac{1}{B^2}\left[B\sigma^2 + B(B-1)\rho\sigma^2\right] = \rho\sigma^{\mathbf{2}} + \frac{\mathbf{1}-\rho}{\mathbf{B}}\sigma^{\mathbf{2}}$$

b) Decomposição e Piso Assintótico ($\sigma^2 = 4{,}0, \rho = 0{,}25$):

- **Piso de Variância Assintótico ($B \to \infty$):** Piso $= \rho\sigma^2 = 0{,}25 \times 4{,}0 = \mathbf{1{,}00}$.
- **Termo Redutível pelo Comitê:** $(1-\rho)\sigma^2 = (1-0{,}25) \times 4{,}0 = \mathbf{3{,}00}$.
- Equação numérica: $\text{Var}(B) = 1{,}00 + \frac{3{,}00}{B}$.

c) Tabela de Variância para Diferentes Valores de B:

- Para $B = 1$: $\text{Var}(1) = 1{,}00 + \frac{3{,}00}{1} = \mathbf{4{,}00}$ (Variância da árvore única).
- Para $B = 5$: $\text{Var}(5) = 1{,}00 + \frac{3{,}00}{5} = 1{,}00 + 0{,}60 = \mathbf{1{,}60}$.
- Para $B = 20$: $\text{Var}(20) = 1{,}00 + \frac{3{,}00}{20} = 1{,}00 + 0{,}15 = \mathbf{1{,}15}$.
- Para $B = 100$: $\text{Var}(100) = 1{,}00 + \frac{3{,}00}{100} = 1{,}00 + 0{,}03 = \mathbf{1{,}03}$.
- Para $B \to \infty$: $\lim_{B\to\infty}\text{Var}(B) = 1{,}00 + 0 = \mathbf{1{,}00}$.

Exemplo 4 (Comparativo Hard Voting vs. Soft Voting)

Considere um comitê Bagging de $B = 3$ árvores avaliando 3 amostras de teste (S_1, S_2, S_3) para classificação binária $y \in \{0, 1\}$. A tabela a seguir exibe a probabilidade de pertencer à Classe 1 estimada por cada árvore ($P^{(b)}(y = 1 \mid \boldsymbol{x})$):

Tabela 1: Probabilidades $P(y = 1)$ estimadas pelas $B = 3$ árvores

Amostra	Árvore 1 (T_1)	Árvore 2 (T_2)	Árvore 3 (T_3)
S_1	0,90	0,40	0,40
S_2	0,10	0,80	0,70
S_3	0,20	0,30	0,40

a) Determine a predição de classe individual de cada árvore adotando o limiar padrão 0,50 e obtenha a decisão final do ensemble por **Hard Voting (Votação Majoritária)**.

b) Calcule a probabilidade média do ensemble para a Classe 1 e obtenha a decisão final por **Soft Voting (Média de Probabilidades)**.

c) Identifique para qual amostra ocorre divergência entre os métodos e explique o motivo teórico.

Resolução do Exemplo 1

a) Processamento por Hard Voting (Limiar 0,50):

- **Amostra S_1:** $T_1 \to 1$ ($0{,}90 \geq 0{,}50$); $T_2 \to 0$ ($0{,}40 < 0{,}50$); $T_3 \to 0$ ($0{,}40 < 0{,}50$). Votos: $\{1:1, 0:2\} \implies \hat{\mathbf{y}}_{\text{hard}}(\mathbf{S_1}) = \mathbf{0}$.
- **Amostra S_2:** $T_1 \to 0$ ($0{,}10 < 0{,}50$); $T_2 \to 1$ ($0{,}80 \geq 0{,}50$); $T_3 \to 1$ ($0{,}70 \geq 0{,}50$). Votos: $\{1:2, 0:1\} \implies \hat{\mathbf{y}}_{\text{hard}}(\mathbf{S_2}) = \mathbf{1}$.
- **Amostra S_3:** $T_1 \to 0$; $T_2 \to 0$; $T_3 \to 0$. Votos: $\{1:0, 0:3\} \implies \hat{\mathbf{y}}_{\text{hard}}(\mathbf{S_3}) = \mathbf{0}$.

b) Processamento por Soft Voting (Média de Probabilidades):

- **Amostra S_1:** $P_{\text{méd}} = \frac{0{,}90+0{,}40+0{,}40}{3} = \frac{1{,}70}{3} \approx 0{,}5667 \geq 0{,}50 \implies \hat{\mathbf{y}}_{\text{soft}}(\mathbf{S_1}) = \mathbf{1}$.
- **Amostra S_2:** $P_{\text{méd}} = \frac{0{,}10+0{,}80+0{,}70}{3} = \frac{1{,}60}{3} \approx 0{,}5333 \geq 0{,}50 \implies \hat{\mathbf{y}}_{\text{soft}}(\mathbf{S_2}) = \mathbf{1}$.
- **Amostra S_3:** $P_{\text{méd}} = \frac{0{,}20+0{,}30+0{,}40}{3} = \frac{0{,}90}{3} = 0{,}3000 < 0{,}50 \implies \hat{\mathbf{y}}_{\text{soft}}(\mathbf{S_3}) = \mathbf{0}$.

c) Análise de Divergência: A divergência ocorre na **Amostra** S_1 ($\hat{y}_{\text{hard}} = 0$ vs. $\hat{y}_{\text{soft}} = 1$). O motivo teórico é que o *Hard Voting* ignora o grau de convicção das árvores, tratando o voto fraco de T_2 e T_3 (ambos com 40% para a classe 1, perto do limite) com o mesmo peso do voto forte de T_1 (90%). O *Soft Voting* preserva a alta certeza de T_1, invertendo a decisão corretamente.

Exemplo 5 (Roteamento OOB e Acurácia do Comitê)

Considere um dataset de $N = 5$ amostras $x^{(1)}, \ldots, x^{(5)}$ com rótulos reais $y = [0, 0, 1, 1, 1]$. Um comitê Bagging de $B = 3$ árvores foi treinado sobre os seguintes lotes bootstrap:

- Lote $\mathcal{D}^{(1)}$ (para T_1): $\{x^{(1)}, x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}\}$
- Lote $\mathcal{D}^{(2)}$ (para T_2): $\{x^{(2)}, x^{(3)}, x^{(4)}, x^{(5)}, x^{(5)}\}$
- Lote $\mathcal{D}^{(3)}$ (para T_3): $\{x^{(1)}, x^{(2)}, x^{(2)}, x^{(5)}, x^{(5)}\}$

As predições individuais das árvores sobre suas amostras OOB foram:

- Árvore T_1: $T_1(x^{(5)}) = 1$
- Árvore T_2: $T_2(x^{(1)}) = 0$
- Árvore T_3: $T_3(x^{(3)}) = 1$ e $T_3(x^{(4)}) = 0$

a) Identifique o conjunto de árvores OOB para cada uma das 5 amostras.

b) Monte a Matriz de Predição Out-of-Bag e obtenha a predição OOB agregada para cada amostra avaliável.

c) Calcule a acurácia global Out-of-Bag (Acc_{OOB}) do comitê.

Resolução do Exemplo 1

a) Identificação das Árvores OOB por Amostra:

- $x^{(1)}$: Ausente em $\mathcal{D}^{(2)} \implies \mathcal{S}_1 = \{T_2\}$.
- $x^{(2)}$: Presente em todos os 3 lotes $\implies \mathcal{S}_2 = \emptyset$ (Não avaliável em OOB).
- $x^{(3)}$: Ausente em $\mathcal{D}^{(3)} \implies \mathcal{S}_3 = \{T_3\}$.
- $x^{(4)}$: Ausente em $\mathcal{D}^{(3)} \implies \mathcal{S}_4 = \{T_3\}$.
- $x^{(5)}$: Ausente em $\mathcal{D}^{(1)} \implies \mathcal{S}_5 = \{T_1\}$.

b) Matriz de Validação OOB:

Tabela 2: Matriz de Avaliação Out-of-Bag

Amostra	**Alvo y**	**Árvores OOB ($\mathcal{S}_i$)**	**Predições OOB**	**Voto Agregado**	**Resultado**
$x^{(1)}$	0	$\{T_2\}$	$T_2(x^{(1)}) = 0$	0	**ACERTO**
$x^{(2)}$	0	$\emptyset$	—	—	(Ignorada)
$x^{(3)}$	1	$\{T_3\}$	$T_3(x^{(3)}) = 1$	1	**ACERTO**
$x^{(4)}$	1	$\{T_3\}$	$T_3(x^{(4)}) = 0$	0	**ERRO**
$x^{(5)}$	1	$\{T_1\}$	$T_1(x^{(5)}) = 1$	1	**ACERTO**

c) Cálculo da Acurácia OOB: Amostras avaliáveis em OOB: 4 amostras ($x^{(1)}, x^{(3)}, x^{(4)}, x^{(5)}$). Total de acertos: 3 ($x^{(1)}, x^{(3)}, x^{(5)}$).

$$\text{Acc}_{\text{OOB}} = \frac{\mathbf{3}}{\mathbf{4}} = \mathbf{0{,}7500} \quad (\mathbf{75{,}0}\%)$$

Exercício 1: Probabilidade OOB para N = 6

Considere um dataset de treino $\mathcal{D}$ com $N = 6$ amostras.

a) Calcule a probabilidade exata de uma amostra $x^{(i)}$ ser *Out-of-Bag* (OOB) em um lote bootstrap com $N = 6$.

b) Determine a porcentagem esperada de amostras de treino únicas presentes no lote bootstrap.

c) Compare o valor exato para $N = 6$ com o limite assintótico $1/e \approx 36{,}79\%$ e calcule o erro relativo percentual.

Exercício 2: Agregação de B = 4 Modelos

Um problema de regressão possui valor real $y = 20{,}0$. Quatro estimadores treinados em lotes bootstrap fornecem as seguintes predições pontuais:

$$\hat{f}_1 = 14{,}0, \quad \hat{f}_2 = 18{,}0, \quad \hat{f}_3 = 24{,}0, \quad \hat{f}_4 = 28{,}0$$

a) Calcule o Erro Quadrático Médio (MSE) de cada modelo individualmente.

b) Calcule a média dos erros quadráticos dos estimadores individuais ($\text{MSE}_{\text{médio}}$).

c) Calcule a predição agregada do comitê Bagging (f_A) e o seu respectivo MSE(f_A).

d) Verifique a Desigualdade de Jensen e determine a redução percentual de erro obtida.

Exercício 3: Determinação do Número Mínimo de Árvores

Um sistema de Random Forest possui árvores individuais com variância $\sigma^2 = 9{,}0$ e correlação par a par descorrelacionada de $\rho = 0{,}20$.

a) Calcule o piso assintótico de variância ($\rho\sigma^2$) e a variância máxima redutível.

b) Determine o número mínimo de árvores B necessário para que o ensemble consiga atingir pelo menos 95% **do ganho máximo de redução de variância** possível.

Exercício 4: Votação com B = 4 Árvores

Um comitê de $B = 4$ árvores gera a seguinte matriz de probabilidades $P(y = 1 \mid \boldsymbol{x})$ para 3 amostras (A_1, A_2, A_3):

Tabela 3: Matriz de Probabilidades para $B = 4$ Árvores

Amostra	T_1	T_2	T_3	T_4
A_1	0,95	0,40	0,40	0,45
A_2	0,20	0,70	0,80	0,90
A_3	0,10	0,15	0,85	0,20

Determine as predições finais para cada amostra sob **Hard Voting** e sob **Soft Voting**, identificando onde ocorrem divergências.

Exercício 5: Cálculo OOB para N = 6 Amostras

Considere um dataset de $N = 6$ amostras $x^{(1)}, \ldots, x^{(6)}$ com rótulos $y = [0, 0, 0, 1, 1, 1]$ e um comitê Bagging de $B = 3$ árvores treinadas nos seguintes lotes:

- Lote $\mathcal{D}^{(1)}$ (para T_1): $\{x^{(1)}, x^{(1)}, x^{(2)}, x^{(4)}, x^{(5)}, x^{(5)}\} \implies$ OOB: $\{x^{(3)}, x^{(6)}\}$
- Lote $\mathcal{D}^{(2)}$ (para T_2): $\{x^{(2)}, x^{(3)}, x^{(3)}, x^{(5)}, x^{(6)}, x^{(6)}\} \implies$ OOB: $\{x^{(1)}, x^{(4)}\}$
- Lote $\mathcal{D}^{(3)}$ (para T_3): $\{x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}, x^{(4)}, x^{(6)}\} \implies$ OOB: $\{x^{(5)}\}$

As predições individuais OOB foram: $T_1(x^{(3)}) = 0$, $T_1(x^{(6)}) = 1$, $T_2(x^{(1)}) = 0$, $T_2(x^{(4)}) = 1$, $T_3(x^{(5)}) = 0$.

a) Monte a matriz OOB e determine o voto OOB para cada amostra avaliável.

b) Calcule a acurácia global Out-of-Bag (Acc_{OOB}) do modelo.