Aprendizado Não Supervisionado: K-Means e Avaliação de Clusters

Modelos Descritivos, Agrupamento Particional de Lloyd e Validação Intrínseca

Prof. Rodrigo

Instituto Federal de São Paulo - IFSP Campus Guarulhos
Disciplina de Aprendizado de Máquina

Semestre Letivo

Roteiro da Aula teórica

Fundamentação Teórica

1. **Mudança de Paradigma:** Modelos Preditivos vs. Modelos Descritivos e a Matriz Não Rotulada X.
2. **Taxonomia da IA:** As 3 famílias não supervisionadas e os tipos de *Clustering*.
3. **Espaço Métrico e Escala:** Distância Euclidiana e por que padronizar com `StandardScaler`.
4. **Algoritmo de Lloyd-Forgy:** Os 4 passos do K-Means, Diagrama de Voronoi, Função Objetivo (WCSS/Inércia) e Prova Analítica da Média μ_k.
5. **Teste de Mesa e Inicialização:** Cálculo manual ilustrado, mínimos locais e **K-Means++**.
6. **Decomposição da Variância e Cotovelo:** TSS = WCSS + BCSS, armadilha de $K = n$ e *Elbow Method*.
7. **Coeficiente de Silhueta:** Coesão $a(i)$, Separação $b(i)$, Teste de Mesa, Diagrama de Facas e Índice Rand Ajustado (ARI).
8. **Limitações e Engenharia:** As 3 patologias geométricas do K-Means e `.predict()` vs. `.transform()`.

A Mudança de Paradigma

Conceito Fundamental

- **Aprendizado Supervisionado → Indução de Modelos Preditivos:** Existe um "professor" externo que fornece o rótulo correto y_i para cada exemplo $\mathbf{x}_i$. O algoritmo ajusta parâmetros para aproximar $f(\mathbf{x}_i) \approx y_i$ e prever o alvo y de novas observações.
- **Aprendizado Não Supervisionado → Indução de Modelos Descritivos:** O "professor" é eliminado! O algoritmo recebe **apenas observações brutas $\mathbf{x}_i$ sem nenhum rótulo** y_i e deve formular hipóteses sobre a estrutura intrínseca, agrupamentos naturais e regularidades dos dados.

Tarefa Preditiva (Supervisionada): `fit(X, y)`



Tarefa Descritiva (Não Supervisionada): `fit(X)`



O Que Muda na Estrutura dos Dados? A Ausência do Vetor Alvo $\mathbf{y}$

Representação Vetorial no Espaço $\mathbb{R}^p$

- No Aprendizado Não Supervisionado, nossa base de dados $\mathcal{D} = \{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n\}$ contém n instâncias (linhas) descritas por p atributos preditores/descritivos (colunas):

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$$

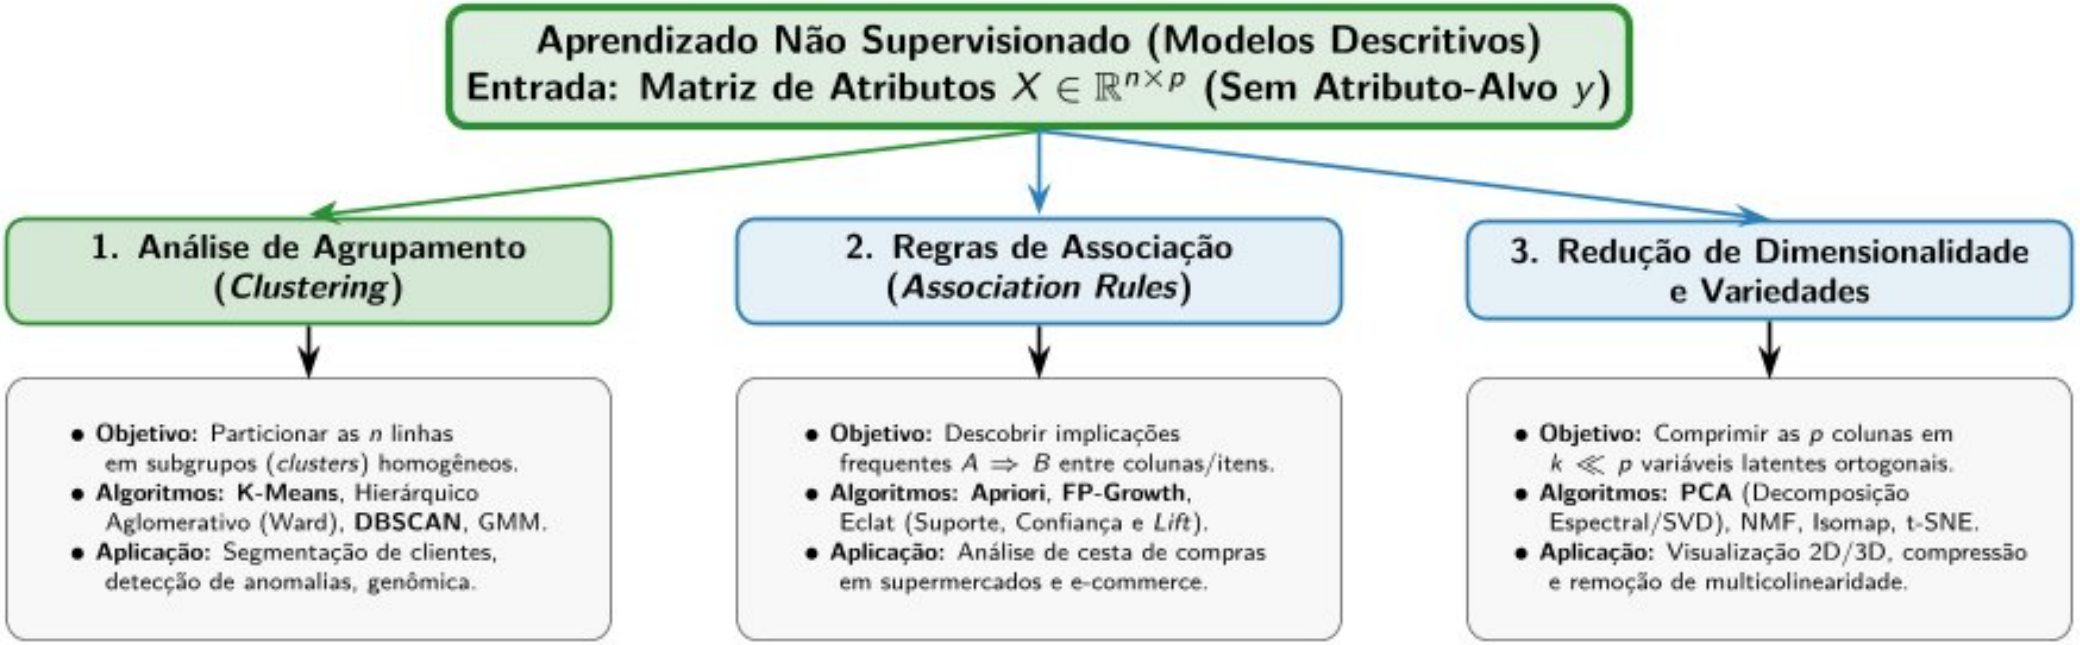
- Cada linha $\mathbf{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ip})$ é um ponto geométrico no espaço p-dimensional.
- **Por que isso é tão comum na indústria?** Dados brutos não rotulados são gerados automaticamente (logs, compras, sensores), enquanto rotular dados exige especialistas humanos caros e lentos!

Exemplo: Clientes de um Shopping

Idade	Renda	Gasto	Perfil (y)
23	85k	92	~~VIP~~ → ?
54	22k	18	~~Econômico~~ → ?
31	88k	89	~~VIP~~ → ?

- **Entrada do Algoritmo:** Apenas as colunas Idade, Renda e Gasto.
- **Saída Descoberta:** O algoritmo percebe sozinho que os clientes 1 e 3 são muito próximos no espaço $\mathbb{R}^3$ e cria o **Cluster 0**!

Taxonomia das Tarefas Descritivas no Aprendizado Não Supervisionado



Conexão com o Aprendizado Semissupervisionado

Quando possuímos milhões de exemplos sem rótulo e apenas algumas dezenas rotulados, aplicamos primeiro o **Agrupamento** para organizar os grupos naturais e propagamos o rótulo humano de 1 representante para todos os membros do mesmo cluster!

Fundamentos de Análise de Agrupamento (*Cluster Analysis*)

O Duplo Critério Geométrico de Qualidade

Sem um vetor de gabarito **y**, como definimos se uma partição em grupos é boa? Através de dois critérios simultâneos:

1. **Alta Coesão Interna (Homogeneidade Intra-Cluster):** Instâncias alocadas no mesmo cluster devem estar muito próximas entre si (baixa dispersão interna).
2. **Alta Separação Externa (Isolamento Inter-Cluster):** Instâncias alocadas em clusters distintos devem estar muito afastadas umas das outras.

Famílias de Algoritmos de Agrupamento

- **Agrupamento Particional (K-Means):** Divide as n observações diretamente em K subconjuntos disjuntos otimizando uma função objetivo global.
- **Agrupamento Hierárquico:** Constrói uma árvore de fusões/divisões sucessivas (*Dendrograma*).
- **Baseado em Densidade (DBSCAN):** Define clusters como regiões densas separadas por regiões esparsas de ruído.
- **Rígido (*Hard*) vs. Nebuloso (*Soft/Fuzzy*):** No rígido, cada ponto pertence a um único grupo; no suave, possui graus de pertinência/distância a todos os grupos.

Como Medir "Semelhança" Entre Pontos? A Métrica Euclidiana (L_2)

Medidas de Distância

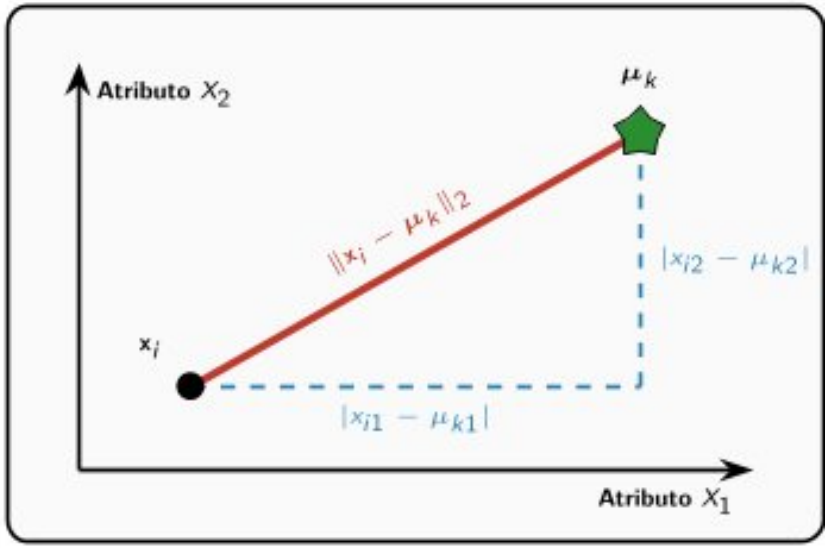
Para agrupar objetos "semelhantes", todo algoritmo de *Clustering* precisa de uma **medida quantitativa de dissimilaridade (distância)** entre dois vetores $\mathbf{x}_i, \mathbf{x}_l \in \mathbb{R}^p$.

- O **K-Means** utiliza exclusivamente a **Distância Euclidiana (L_2)** (e seu quadrado):

$$d(\mathbf{x}_i, \mathbf{x}_l) = \|\mathbf{x}_i - \mathbf{x}_l\|_2 = \sqrt{\sum_{j=1}^{p} (x_{ij} - x_{lj})^2}$$

$$d^2(\mathbf{x}_i, \mathbf{x}_l) = \|\mathbf{x}_i - \mathbf{x}_l\|_2^2 = \sum_{j=1}^{p} (x_{ij} - x_{lj})^2$$

- **Nota Computational:** Como a função raiz quadrada é crescente para valores não negativos, minimizar a distância d equivale a minimizar a distância quadrática d^2 (poupando o custo de calcular $\sqrt{\cdot}$)!

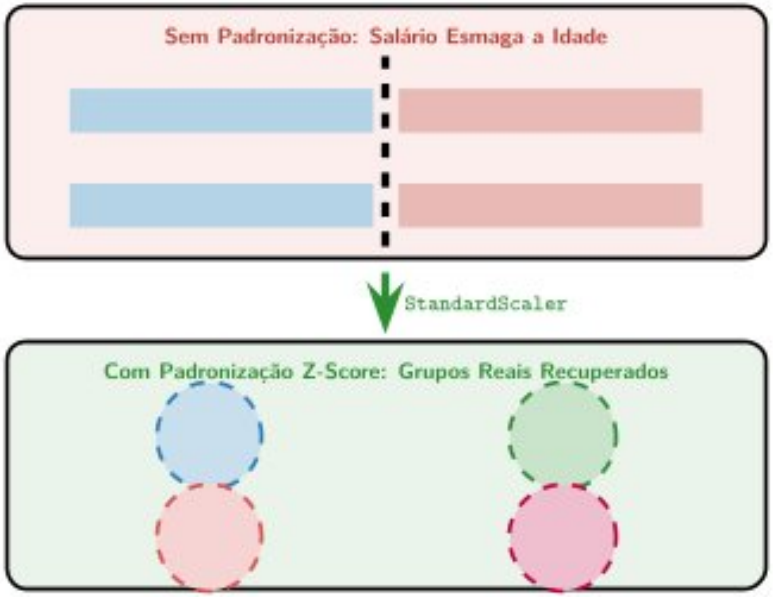


Pré-Requisito Obrigatório: Padronização de Escala (StandardScaler)

O Perigo de Unidades de Medida Discrepantes

Considere agrupar clientes por **Idade (anos)** e **Salário Anual (R$)**:

- Uma diferença de 30 anos na Idade gera no quadrado euclidiano: $(50 - 20)^2 = \mathbf{900}$.
- Uma diferença de R$ 10.000 no Salário gera no quadrado euclidiano: $(60.000 - 50.000)^2 = \mathbf{100.000.000}$!
- **Consequência:** O atributo de maior magnitude numérica domina 99.999% da distância euclidiana e o K-Means ignora completamente a coluna Idade!



Solução: Padronização Z-Score (StandardScaler)

Transformamos cada atributo j para ter **média** 0 **e desvio-padrão** 1:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

O Algoritmo K-Means: Particionamento Baseado em Protótipos (Centroides)

Definição Formal de Partição e Centroide

Proposto por Stuart Lloyd (1957/1982) e J. MacQueen (1967), o **K-Means** divide o conjunto de dados $\mathcal{D} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$ em K subconjuntos (clusters) $C_1, C_2, \ldots, C_K$ que formam uma **partição exaustiva e mutuamente exclusiva**:

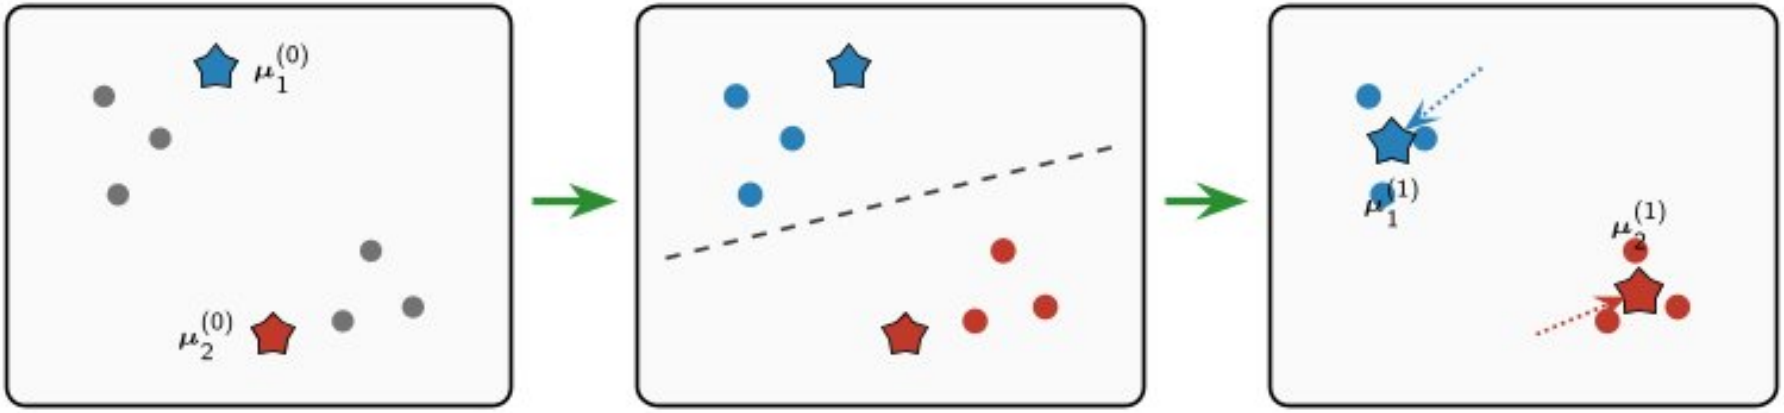
1. Cada instância pertence a pelo menos um grupo: $\bigcup_{k=1}^{K} C_k = \mathcal{D}$;
2. Nenhum ponto pertence a dois grupos ao mesmo tempo: $C_k \cap C_l = \emptyset \quad (\forall k \neq l)$.

Cada cluster C_k é representado por um **protótipo central** denominado **centroide ($\mu_k \in \mathbb{R}^p$)**, que corresponde ao centro de gravidade (vetor média) dos pontos pertencentes a C_k.

Importante: Centroide vs. Medoide!

- O **centroide** μ_k é uma coordenada matemática calculada pela média aritmética dos pontos do grupo.
- Portanto, o centroide μ_k **não precisa coincidir com nenhum ponto real** da base de dados (ele pode cair no espaço vazio no centro da nuvem de pontos!).
- *(Quando exigimos que o centro seja obrigatoriamente um ponto real da base, o protótipo chama-se **Medoide**, usado no algoritmo K-Medoids/PAM).*

As 4 Etapas Iterativas do Algoritmo K-Means (Ciclo de Lloyd-Forgy)



1. Inicialização (K Sementes) 2. Atribuição (Menor Distância) 3 e 4. Recálculo de μ_k e Repetição

Resumo Algorítmico das 4 Etapas

(1) Inicialização: Posicionar K centroides iniciais $\boldsymbol{\mu}_1^{(0)}, \ldots, \boldsymbol{\mu}_K^{(0)}$.
(2) Atribuição: Alocar cada $\mathbf{x}_i$ ao grupo do centroide mais próximo.
(3) Atualização: Mover cada $\boldsymbol{\mu}_k$ para a média aritmética dos pontos do seu grupo.
(4) Parada: Repetir 2 e 3 até que nenhum ponto mude de grupo (ou $\|\boldsymbol{\mu}_k^{(t)} - \boldsymbol{\mu}_k^{(t-1)}\| < \text{tol}$).

Geometria das Fronteiras do K-Means: O Diagrama de Voronoi

Por que toda fronteira do K-Means é uma Reta/Hiperplano?

Um ponto $\mathbf{x} \in \mathbb{R}^p$ está na fronteira entre os centroides $\boldsymbol{\mu}_a$ e $\boldsymbol{\mu}_b$ quando suas distâncias quadráticas são iguais:

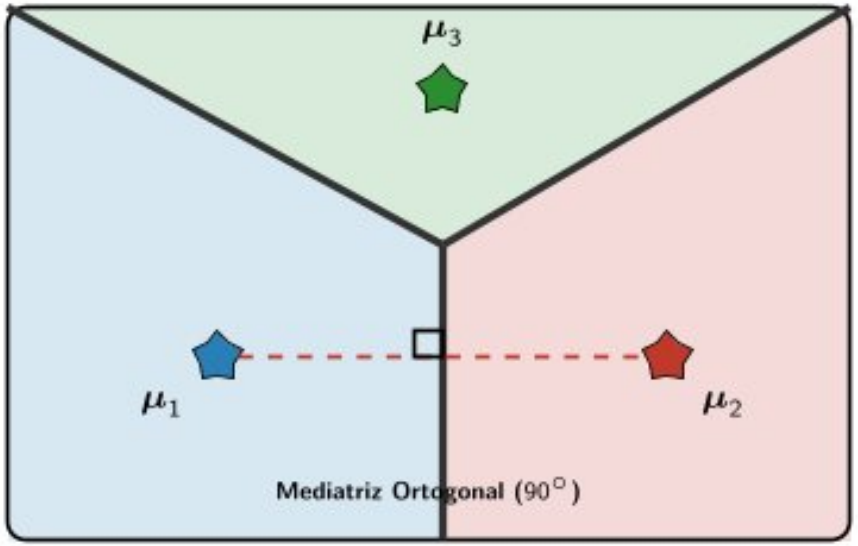
$$\|\mathbf{x} - \boldsymbol{\mu}_a\|_2^2 = \|\mathbf{x} - \boldsymbol{\mu}_b\|_2^2$$

Expandindo o produto escalar $\|\mathbf{x} - \boldsymbol{\mu}\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{x}^T\boldsymbol{\mu} + \|\boldsymbol{\mu}\|^2$:

$$\cancel{\|\mathbf{x}\|^2} - 2\mathbf{x}^T\boldsymbol{\mu}_a + \|\boldsymbol{\mu}_a\|^2 = \cancel{\|\mathbf{x}\|^2} - 2\mathbf{x}^T\boldsymbol{\mu}_b + \|\boldsymbol{\mu}_b\|^2$$

$$2(\boldsymbol{\mu}_b - \boldsymbol{\mu}_a)^T\mathbf{x} + \left(\|\boldsymbol{\mu}_a\|^2 - \|\boldsymbol{\mu}_b\|^2\right) = 0$$

O termo quadrático $\|\mathbf{x}\|^2$ se cancela! Logo, a fronteira é sempre uma **reta mediatriz (hiperplano linear)** ortogonal (90°) ao segmento que une $\boldsymbol{\mu}_a$ e $\boldsymbol{\mu}_b$, dividindo o espaço em polígonos convexos chamados **Células de Voronoi**!



A Função Objetivo do K-Means (Inércia / WCSS) e a Prova da Média

O K-Means busca minimizar a função custo J denominada **Inércia**, **WCSS** (*Within-Cluster Sum of Squares*) ou **SSE** (*Sum of Squared Errors*, atributo `inertia_` no Scikit-Learn):

$$J(C_1, \ldots, C_K, \boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K) = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2 = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \sum_{j=1}^{p} (x_{ij} - \mu_{kj})^2$$

Otimização no Passo de Atribuição

Fixados os centroides $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K$, cada termo $\|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2$ é independente. Logo, a soma total J diminui se alocarmos cada ponto $\mathbf{x}_i$ ao centroide mais próximo:

$$c^{(i)} = \arg \min_{k \in \{1,\ldots,K\}} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2$$

Prova: Por que a Média μ_k Minimiza J?

Fixado o grupo C_k, derivamos $J_k = \sum_{\mathbf{x}_i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)^2$ em relação a $\boldsymbol{\mu}_k$ e igualamos a zero:

$$\frac{\partial J_k}{\partial \boldsymbol{\mu}_k} = -2 \sum_{\mathbf{x}_i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k) = \mathbf{0} \implies \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i - |C_k| \boldsymbol{\mu}_k = \mathbf{0}$$

$$\implies \boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i \quad \text{(Média Aritmética!)}$$

Teste de Mesa Completo do K-Means (Parte 1: Cálculos Passo a Passo)

Iteração 1 – Passo de Atribuição

Base ($n = 4$): $\mathbf{x}_1 = (1,1)$, $\mathbf{x}_2 = (1,3)$, $\mathbf{x}_3 = (5,4)$, $\mathbf{x}_4 = (5,6)$.
Centroides Iniciais ($K = 2$): $\boldsymbol{\mu}_1^{(0)} = (1,1)$ e $\boldsymbol{\mu}_2^{(0)} = (5,4)$.

- **Distâncias Quadráticas**
  $d^2(\mathbf{x}_i, \boldsymbol{\mu}_k) = (x_{i1} - \mu_{k1})^2 + (x_{i2} - \mu_{k2})^2$:
  - $\mathbf{x}_1(1,1)$: $d^2(\boldsymbol{\mu}_1) = \mathbf{0} < d^2(\boldsymbol{\mu}_2) = 16 + 9 = 25 \Rightarrow \mathbf{C_1}$
  - $\mathbf{x}_2(1,3)$:
    $d^2(\boldsymbol{\mu}_1) = 0 + 4 = \mathbf{4} < d^2(\boldsymbol{\mu}_2) = 16 + 1 = 17 \Rightarrow \mathbf{C_1}$
  - $\mathbf{x}_3(5,4)$: $d^2(\boldsymbol{\mu}_1) = 25 > d^2(\boldsymbol{\mu}_2) = \mathbf{0} \Rightarrow \mathbf{C_2}$
  - $\mathbf{x}_4(5,6)$:
    $d^2(\boldsymbol{\mu}_1) = 16 + 25 = 41 > d^2(\boldsymbol{\mu}_2) = 0 + 4 = \mathbf{4} \Rightarrow \mathbf{C_2}$
- **Clusters Formados:** $C_1 = \{\mathbf{x}_1, \mathbf{x}_2\}$ e $C_2 = \{\mathbf{x}_3, \mathbf{x}_4\}$.
- **Inércia Inicial ($J^{(0)}$):**

$$\text{WCSS}^{(0)} = 0 + 4 + 0 + 4 = \mathbf{8.0}$$

Iteração 1 – Passo de Atualização

- **Recálculo dos Centroides pela Média Aritmética:**

$$\boldsymbol{\mu}_1^{(1)} = \frac{\mathbf{x}_1 + \mathbf{x}_2}{2} = \left(\frac{1+1}{2}, \frac{1+3}{2}\right) = (\mathbf{1}, \mathbf{2})$$

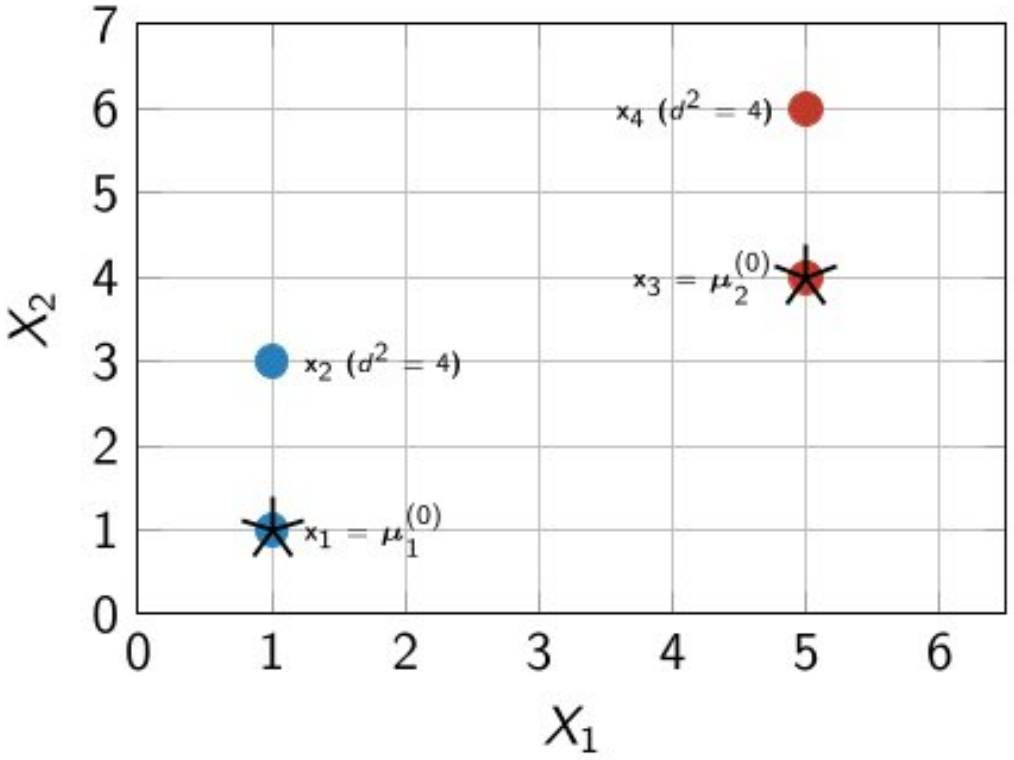
$$\boldsymbol{\mu}_2^{(1)} = \frac{\mathbf{x}_3 + \mathbf{x}_4}{2} = \left(\frac{5+5}{2}, \frac{4+6}{2}\right) = (\mathbf{5}, \mathbf{5})$$

- **Recálculo da Inércia ($J^{(1)}$) com os Novos Centroides:**
  - Em C_1:
    $\|\mathbf{x}_1(1,1) - (1,2)\|^2 = \mathbf{1}$;
    $\|\mathbf{x}_2(1,3) - (1,2)\|^2 = \mathbf{1}$.
  - Em C_2:
    $\|\mathbf{x}_3(5,4) - (5,5)\|^2 = \mathbf{1}$;
    $\|\mathbf{x}_4(5,6) - (5,5)\|^2 = \mathbf{1}$.

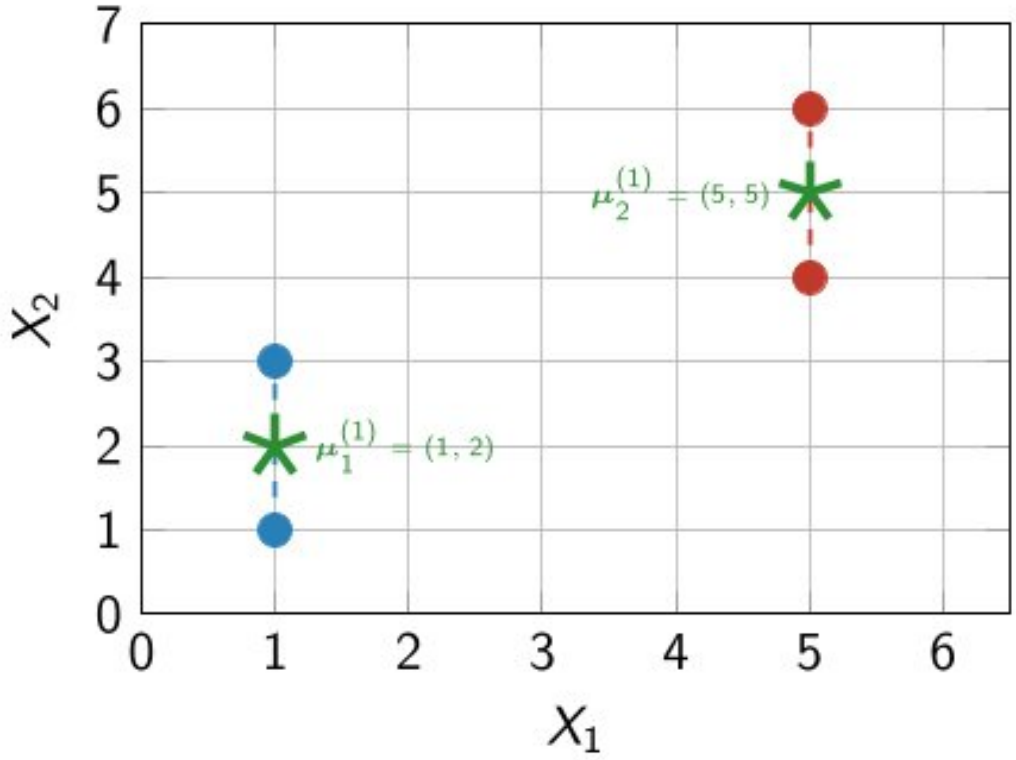
$\text{WCSS}^{(1)} = 1+1+1+1 = \mathbf{4.0}$ (Caiu 50%!)

Teste de Mesa Completo do K-Means (Parte 2: Visualização no Plano $\mathbb{R}^2$)

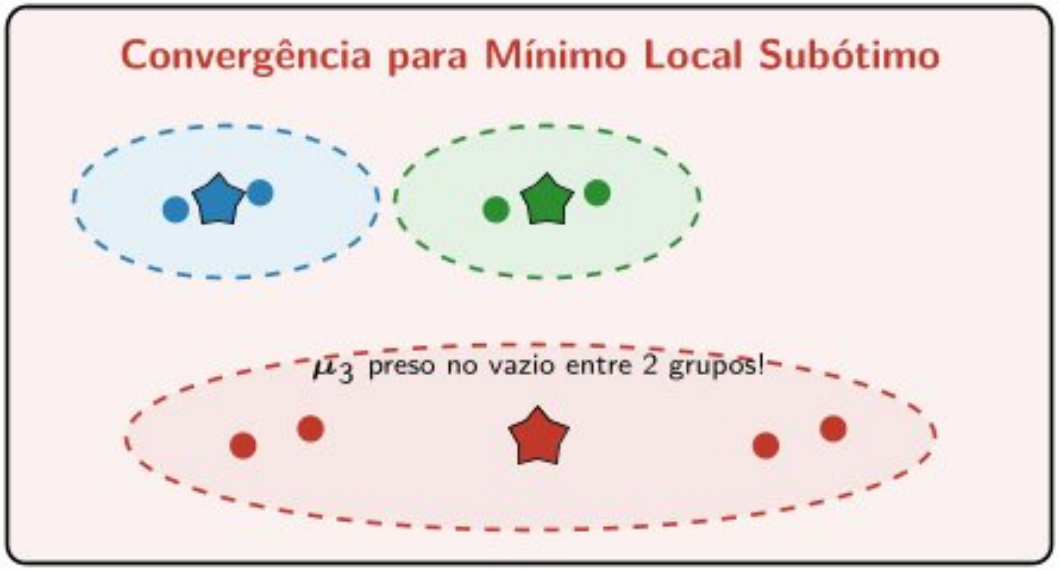
Antes da Atualização ($\mathbf{WCSS}^{(0)} = 8.0$)



Após a Atualização ($\mathbf{WCSS}^{(1)} = 4.0$)



Por que o Sorteio Aleatório Puro Pode Falhar? Ótimos Locais Ruins



Diagnóstico do Problema Combinatório

- Encontrar o mínimo global exato da função de Inércia J em $\mathbb{R}^p$ é um problema **NP-difícil**.
- O algoritmo de Lloyd é um método guloso de descida local: se no sorteio aleatório (`init='random'`) dois centroides caírem dentro da mesma nuvem densa, eles dividirão esse cluster ao meio e deixarão um único centroide solitário para engolir dois clusters distantes!
- **Além disso:** Se um centroide for inicializado muito longe de todos os pontos, pode surgir um **cluster vazio** ($|C_k| = 0$).

A Melhor Solução: Inicialização **K-Means++** e `n_init`

Como o K-Means++ Espalha os Centroides Iniciais?

Proposto por Arthur & Vassilvitskii (2007) e padrão no Scikit-Learn (`init='k-means++'`):

1. Sorteia o 1º centroide $\boldsymbol{\mu}_1^{(0)}$ uniformemente ao acaso dentre os pontos da base X.
2. Para cada ponto $\mathbf{x}_i$, calcula a menor distância quadrática $D(\mathbf{x}_i)^2$ até o centroide mais próximo já escolhido.
3. Sorteia o próximo centroide com probabilidade proporcional a $D(\mathbf{x}_i)^2$:

$$P(\text{sortear } \mathbf{x}_i) = \frac{D(\mathbf{x}_i)^2}{\sum_{j=1}^{n} D(\mathbf{x}_j)^2}$$

4. Repete os passos 2 e 3 até escolher os K centroides!

Teste de Mesa do Sorteio K-Means++

Suponha que o 1º centroide escolhido foi $\boldsymbol{\mu}_1 = \mathbf{x}_1$ e restam três candidatos $\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ com distâncias até $\boldsymbol{\mu}_1$ iguais a $D(\mathbf{x}_2) = 1$, $D(\mathbf{x}_3) = 2$ e $D(\mathbf{x}_4) = 5$:

- Quadrados: $D^2 = [1^2, 2^2, 5^2] = [1, 4, 25]$.
- Soma total: $\sum D^2 = 1 + 4 + 25 = \mathbf{30}$.
- **Probabilidades de sorteio do 2º centroide:**
  - $P(\mathbf{x}_2) = 1/30 = \mathbf{3.3\%}$ (perto de $\boldsymbol{\mu}_1$);
  - $P(\mathbf{x}_3) = 4/30 = \mathbf{13.3\%}$;
  - $P(\mathbf{x}_4) = 25/30 = \mathbf{83.3\%}$ (muito distante!).

Combinado com `n_init=10` (10 execuções completas retornando a de menor Inércia), praticamente elimina ótimos locais ruins!

Decomposição da Variância no Agrupamento: TSS = WCSS + BCSS

Identidade Fundamental de Soma de Quadrados

Seja $\bar{\mathbf{x}}$ a média global de todos os dados. A dispersão total do conjunto (**TSS** – *Total Sum of Squares*) decompõe-se exatamente em duas parcelas:

$$\underbrace{\sum_{i=1}^{n} \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2}_{\text{TSS (Constante Fixa)}} = \underbrace{\sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2}_{\text{WCSS / Inércia (Coesão)}} + \underbrace{\sum_{k=1}^{K} |C_k| \|\boldsymbol{\mu}_k - \bar{\mathbf{x}}\|^2}_{\text{BCSS (Separação)}}$$

- Como o TSS é constante para a base X, **minimizar a Inércia (WCSS) equivale matematicamente a maximizar a variância entre grupos (BCSS)** para um K fixo!

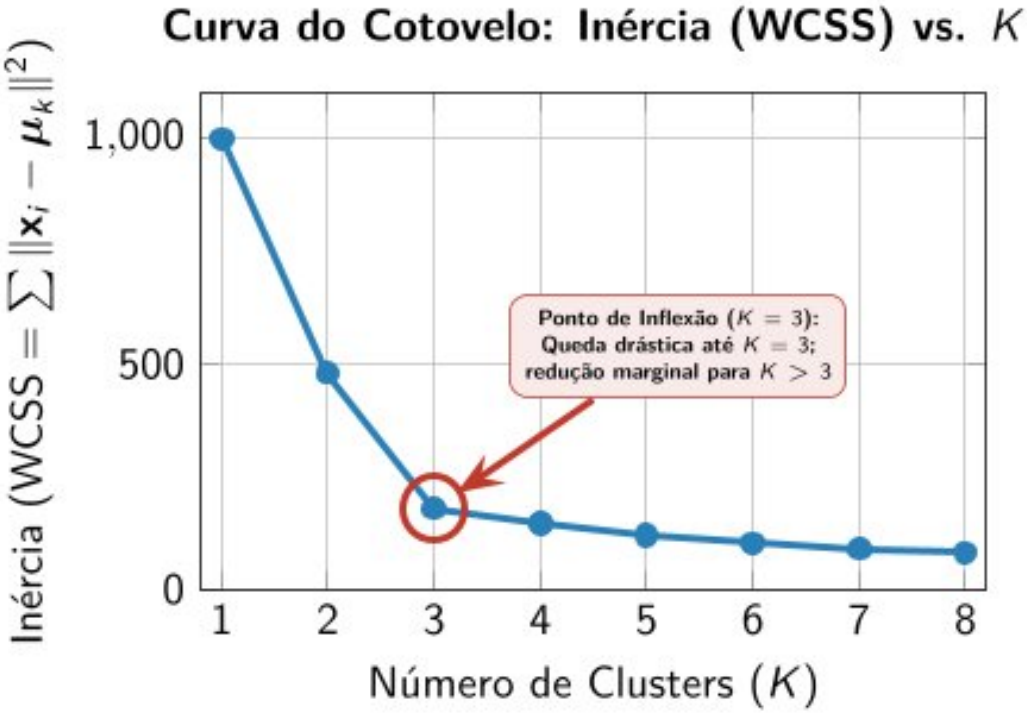
A Armadilha de Escolher K pela Menor Inércia!

- Embora para um K fixo minimizar a WCSS seja ótimo, **não podemos comparar modelos com diferentes valores de K escolhendo o de menor WCSS**!
- **Por quê?** Sempre que aumentamos $K \to K+1$, adicionamos um novo centroide e a Inércia WCSS(K) **cai monotonicamente**.
- No caso extremo em que $K = n$ (um cluster para cada ponto), temos $\mathbf{x}_i = \boldsymbol{\mu}_i \implies \text{WCSS}(n) = \mathbf{0.0}$, destruindo completamente o poder de agrupamento!

Determinando o Hiperparâmetro K: O Método do Cotovelo (*Elbow Method*)

Como Funciona a Heurística do Cotovelo?

1. Executamos o K-Means para uma sequência de valores candidatos $K \in \{1, 2, 3, \ldots, K_{\max}\}$ e registramos a Inércia WCSS(K).
2. **Regime de Subagrupamento ($K < K_{\text{real}}$):** Clusters naturais distantes estão fundidos; incrementar K separa grupos verdadeiros e provoca uma **queda abrupta** na Inércia.
3. **Regime de Sobreagrupamento ($K > K_{\text{real}}$):** Os grupos reais já foram isolados; incrementar K apenas subdivide nuvens coesas, gerando um **ganho marginal pequeno e quase linear**.
4. O **ponto de inflexão ("cotovelo")** identifica o K ideal!



Validação Intrínseca: O Coeficiente de Silhueta (Rousseeuw, 1987)

- Para superar a subjetividade visual do Método do Cotovelo, o **Coeficiente de Silhueta** mede simultaneamente a **Coesão Intra-Cluster** e a **Separação Inter-Cluster** para cada amostra $\mathbf{x}_i$:

As 3 Equações da Silhueta para $\mathbf{x}_i \in C_A$

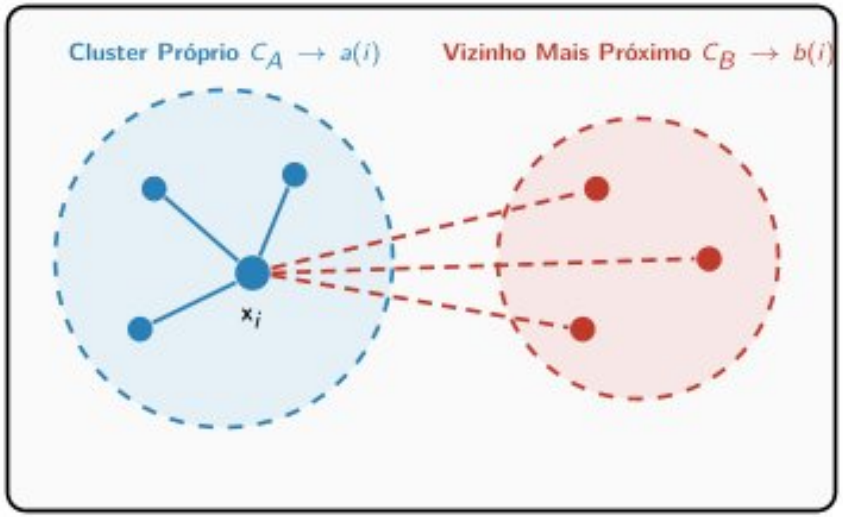
1. **Distância Média Intra-Cluster $a(i)$ (Falta de Coesão):** Distância média de $\mathbf{x}_i$ a todos os outros pontos do **seu próprio grupo** C_A (quanto **menor** $a(i)$, mais coeso!):

$$a(i) = \frac{1}{|C_A| - 1} \sum_{\mathbf{x}_j \in C_A,\, j \neq i} d(\mathbf{x}_i, \mathbf{x}_j)$$

2. **Distância Média ao Cluster Vizinho $b(i)$ (Separação):** Menor distância média de $\mathbf{x}_i$ a todos os pontos de qualquer outro grupo $C_B \neq C_A$ (quanto **maior** $b(i)$, mais bem separado!):

$$b(i) = \min_{B \neq A} \left\{ \frac{1}{|C_B|} \sum_{\mathbf{x}_j \in C_B} d(\mathbf{x}_i, \mathbf{x}_j) \right\}$$

3. **Silhueta de $\mathbf{x}_i$:** $\quad s(i) = \dfrac{b(i) - a(i)}{\max\{a(i),\, b(i)\}} \in [-1, +1]$



Interpretando e Calculando o Coeficiente de Silhueta Passo a Passo

Escala de Interpretação de $s(i) \in [-1, +1]$

- **s(i) $\to +1$ (Excelente):** Ocorre quando $a(i) \ll b(i)$. A instância está muito próxima dos seus colegas de grupo e muito longe do grupo vizinho.
- **s(i) ≈ 0 (Zona de Fronteira):** Ocorre quando $a(i) \approx b(i)$. A instância está sobre a fronteira de decisão entre dois clusters.
- **s(i) < 0 (Alocação Errada!):** Ocorre quando $a(i) > b(i)$. A instância está, em média, mais próxima dos elementos de outro cluster do que do seu próprio grupo!

Nota Técnica: O Coeficiente de Silhueta exige $2 \leq K \leq n - 1$ (para $K = 1$ não existe grupo vizinho para calcular $b(i)$!).

Teste de Mesa Completo da Silhueta

Considere uma partição em $K = 3$ grupos (C_1, C_2, C_3) e a instância $\mathbf{x}_1 \in C_1$:

1. **Coesão $a(1)$:** As distâncias de $\mathbf{x}_1$ para os outros 2 pontos de C_1 são 1.5 e 2.5:

$$a(1) = \frac{1.5 + 2.5}{2} = \mathbf{2.0}$$

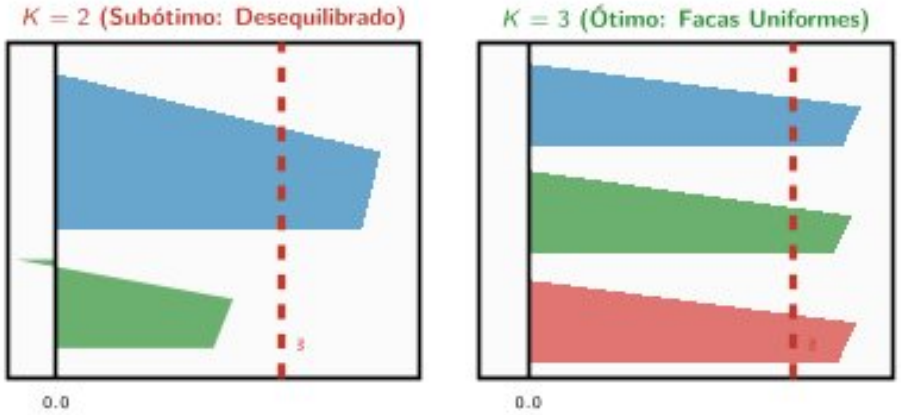
2. **Separação $b(1)$:** A distância média de $\mathbf{x}_1$ aos pontos de C_2 é **8.0**, e aos pontos de C_3 é **12.0**. O vizinho mais próximo é C_2:

$$b(1) = \min\{8.0,\ 12.0\} = \mathbf{8.0}$$

3. **Cálculo de $s(1)$:**

$$s(1) = \frac{8.0 - 2.0}{\max\{2.0,\ 8.0\}} = \frac{6.0}{8.0} = +\mathbf{0.75}$$

Análise Visual pelo Diagrama de Silhueta e Validação Extrínseca (ARI)



Leitura do Diagrama de Silhueta

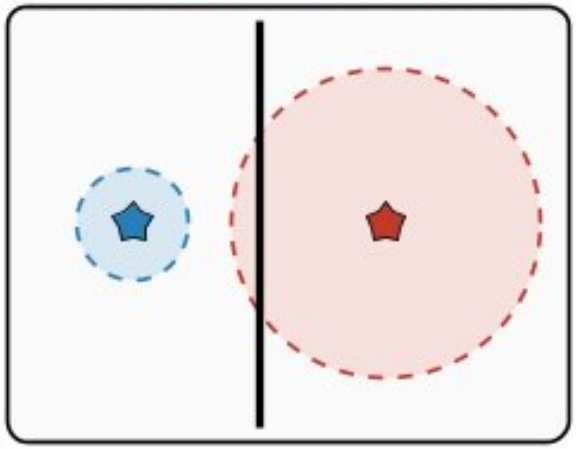
- **Espessura vertical da faca:** Tamanho $|C_k|$ do grupo.
- **Comprimento horizontal:** Coeficientes $s(i)$ ordenados.
- **Regra de Decisão:** Escolhemos o K onde todas as facas ultrapassam a linha tracejada vermelha da média global $\bar{s}$, com espessuras equilibradas e sem valores negativos!

Validação Extrínseca: Índice Rand Ajustado

Quando avaliamos um agrupamento contra um gabarito externo conhecido y_{real} (ex.: base Iris), usamos `adjusted_rand_score(y_real, labels)`, que mede a concordância par-a-par descontando o acaso (ARI $= 1.0$: concordância perfeita; ARI $= 0.0$: aleatório), invariante ao número atribuído a cada cluster!

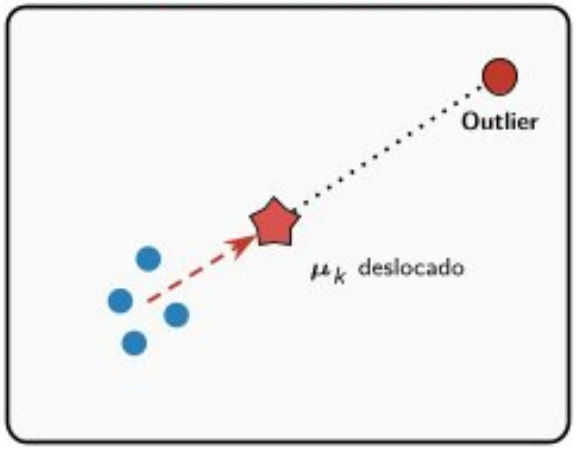
Diagnóstico Visual: As 3 Patologias Geométricas do K-Means

1. Raios/Variâncias Discrepantes



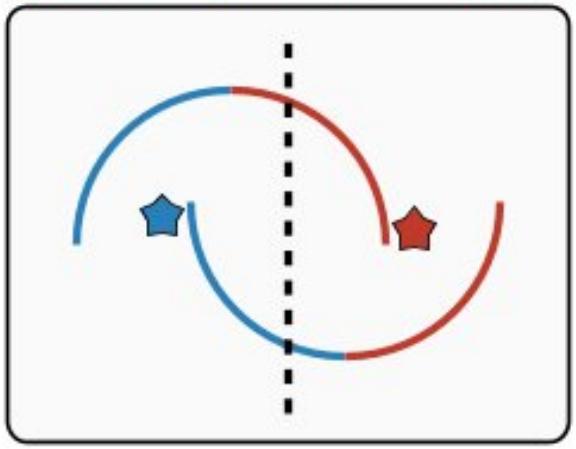
A mediatriz invade o grupo espalhado!

2. Sensibilidade a *Outliers*



Um único *outlier* arrasta a média μ_k!

3. Variedades Não Convexas (*Moons*)



Fronteira linear de Voronoi corta as luas!

Viés Indutivo do K-Means e Alternativas

O viés indutivo do K-Means pressupõe grupos **esféricos (isotrópicos), convexos, sem *outliers* e de variâncias semelhantes**. Quando os grupos possuem elipses alongadas, usamos **Mistura de Gaussianas (GMM)**; quando possuem formatos não convexos arbitrários e ruído, usamos **DBSCAN** (Aula 17)!

O K-Means na Engenharia de Atributos: `.predict(X)` vs. `.transform(X)`

Dois Modos de Projeção no Scikit-Learn

Após treinar `kmeans.fit(X)`, podemos projetar cada observação $\mathbf{x}_i \in \mathbb{R}^p$ de duas maneiras:

1. `kmeans.predict(X)` (***Hard Clustering***): Retorna o índice inteiro $c^{(i)} \in \{0, 1, \ldots, K-1\}$ do centroide mais próximo.
2. `kmeans.transform(X)` (***Cluster-Distance Space***): Retorna um vetor contínuo $\mathbf{z}_i \in \mathbb{R}^K$ contendo as **distâncias euclidianas de $\mathbf{x}_i$ a todos os K centroides**:

$$\mathbf{z}_i = [\|\mathbf{x}_i - \boldsymbol{\mu}_1\|_2,\ \|\mathbf{x}_i - \boldsymbol{\mu}_2\|_2,\ \ldots,\ \|\mathbf{x}_i - \boldsymbol{\mu}_K\|_2]$$

Uso em Pipelines Supervisionados (Géron)

- O método `.transform(X)` converte o K-Means em um **extrator não linear de características (bases radiais)**!
- Podemos encadear `Pipeline([('scaler', StandardScaler()), ('kmeans', KMeans(n_clusters=10)), ('clf', LogisticRegression())])`, permitindo que um classificador linear aprenda fronteiras complexas baseadas na proximidade aos 10 protótipos!

Referências Bibliográficas

Leituras Recomendadas

- **FACELI, Katti; LORENA, Ana Carolina; GAMA, João; CARVALHO, André C. P. L. F.** *Inteligência Artificial: uma abordagem de aprendizado de máquina*. Rio de Janeiro: LTC, 2011.
- **IZBICKI, Rafael; SANTOS, Tiago Mendonça dos.** *Aprendizado de Máquina: uma abordagem estatística*. 2020.
- **MORETTIN, Pedro A.; SINGER, Julio M.** *Estatística e Ciência de Dados*. Rio de Janeiro: LTC, 2022.
- **LUGER, George F.** *Inteligência Artificial*. 6. ed. Porto Alegre: Bookman, 2013.
- **GÉRON, Aurélien.** *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow*. Rio de Janeiro: Alta Books, 2021.

Bons estudos a todos!