Lista de Exercícios
Aprendizado Não Supervisionado
Algoritmo K-Means, K-Means++, Cotovelo e Silhueta

Disciplina: Aprendizado de Máquina

Semestre Letivo

Exemplo 1: Ciclo de Lloyd-Forgy (Atribuição, Atualização e Inércia WCSS)

Considere um conjunto de dados não rotulado com $n = 4$ observações no plano $\mathbb{R}^2$:

$$\mathbf{x}_1 = (1, 1), \quad \mathbf{x}_2 = (1, 3), \quad \mathbf{x}_3 = (5, 4), \quad \mathbf{x}_4 = (5, 6)$$

Deseja-se agrupar esses pontos em $K = 2$ clusters utilizando o algoritmo K-Means. Suponha que os centroides iniciais foram posicionados em $\boldsymbol{\mu}_1^{(0)} = (1, 1)$ e $\boldsymbol{\mu}_2^{(0)} = (5, 4)$.

a) Execute o **Passo de Atribuição**, determinando os grupos C_1 e C_2 e a Inércia inicial $\text{WCSS}^{(0)}$.
b) Execute o **Passo de Atualização**, calculando os novos centroides $\boldsymbol{\mu}_1^{(1)}$ e $\boldsymbol{\mu}_2^{(1)}$.
c) Calcule a nova Inércia $\text{WCSS}^{(1)}$ após a atualização dos centroides e verifique se o algoritmo convergiu.

Resolução do Exemplo 1

a) Passo de Atribuição e Inércia Inicial ($\text{WCSS}^{(0)}$):
Calculamos a distância euclidiana ao quadrado $d^2(\mathbf{x}_i, \boldsymbol{\mu}_k) = (x_{i1} - \mu_{k1})^2 + (x_{i2} - \mu_{k2})^2$ de cada ponto aos dois centroides iniciais $\boldsymbol{\mu}_1^{(0)} = (1, 1)$ e $\boldsymbol{\mu}_2^{(0)} = (5, 4)$:

- Ponto $\mathbf{x}_1(1, 1)$: $d^2(\mathbf{x}_1, \boldsymbol{\mu}_1^{(0)}) = (1-1)^2+(1-1)^2 = \mathbf{0}$; $d^2(\mathbf{x}_1, \boldsymbol{\mu}_2^{(0)}) = (1-5)^2+(1-4)^2 = 16 + 9 = 25$. Como $0 < 25 \implies \mathbf{x}_1 \in C_1$.
- Ponto $\mathbf{x}_2(1, 3)$: $d^2(\mathbf{x}_2, \boldsymbol{\mu}_1^{(0)}) = (1-1)^2+(3-1)^2 = \mathbf{4}$; $d^2(\mathbf{x}_2, \boldsymbol{\mu}_2^{(0)}) = (1-5)^2+(3-4)^2 = 16 + 1 = 17$. Como $4 < 17 \implies \mathbf{x}_2 \in C_1$.
- Ponto $\mathbf{x}_3(5, 4)$: $d^2(\mathbf{x}_3, \boldsymbol{\mu}_1^{(0)}) = (5-1)^2 + (4-1)^2 = 25$; $d^2(\mathbf{x}_3, \boldsymbol{\mu}_2^{(0)}) = (5-5)^2 + (4-4)^2 = \mathbf{0}$. Como $0 < 25 \implies \mathbf{x}_3 \in C_2$.
- Ponto $\mathbf{x}_4(5, 6)$: $d^2(\mathbf{x}_4, \boldsymbol{\mu}_1^{(0)}) = (5-1)^2 + (6-1)^2 = 41$; $d^2(\mathbf{x}_4, \boldsymbol{\mu}_2^{(0)}) = (5-5)^2 + (6-4)^2 = \mathbf{4}$. Como $4 < 41 \implies \mathbf{x}_4 \in C_2$.

Portanto, $C_1 = \{\mathbf{x}_1, \mathbf{x}_2\}$ e $C_2 = \{\mathbf{x}_3, \mathbf{x}_4\}$. Somando as menores distâncias quadráticas:

$$\text{WCSS}^{(0)} = 0 + 4 + 0 + 4 = \mathbf{8.0}$$

b) Passo de Atualização dos Centroides ($\boldsymbol{\mu}_k^{(1)}$):
Cada novo centroide é a média aritmética coordenada a coordenada dos pontos do seu grupo:

$$\boldsymbol{\mu}_1^{(1)} = \frac{\mathbf{x}_1 + \mathbf{x}_2}{2} = \left(\frac{1+1}{2}, \frac{1+3}{2}\right) = (\mathbf{1}, \mathbf{2})$$

$$\boldsymbol{\mu}_2^{(1)} = \frac{\mathbf{x}_3 + \mathbf{x}_4}{2} = \left(\frac{5+5}{2}, \frac{4+6}{2}\right) = (\mathbf{5}, \mathbf{5})$$

c) Nova Inércia (WCSS$^{(1)}$) e Verificação de Convergência:
Calculando os desvios quadráticos em relação aos novos centroides $\boldsymbol{\mu}_1^{(1)} = (1, 2)$ e $\boldsymbol{\mu}_2^{(1)} = (5, 5)$:

- Em C_1: $d^2(\mathbf{x}_1, \boldsymbol{\mu}_1^{(1)}) = (1-1)^2 + (1-2)^2 = 1$; $\quad d^2(\mathbf{x}_2, \boldsymbol{\mu}_1^{(1)}) = (1-1)^2 + (3-2)^2 = 1$.
- Em C_2: $d^2(\mathbf{x}_3, \boldsymbol{\mu}_2^{(1)}) = (5-5)^2 + (4-5)^2 = 1$; $\quad d^2(\mathbf{x}_4, \boldsymbol{\mu}_2^{(1)}) = (5-5)^2 + (6-5)^2 = 1$.

$$\text{WCSS}^{(1)} = 1 + 1 + 1 + 1 = \mathbf{4.0}$$

A Inércia caiu de 8.0 para 4.0 (redução de 50%). Como na próxima atribuição nenhum ponto muda de grupo, o algoritmo **atingiu a convergência**!

Exemplo 2: Distorção de Escala, Padronização Z-Score e `inverse_transform`

Uma fintech deseja agrupar três clientes descritos por $X_1 =$ Idade (anos) e $X_2 =$ Renda Anual (R$):

Cliente $A = (25 \text{ anos}, \text{R\$ } 30.000)$, Cliente $B = (55 \text{ anos}, \text{R\$ } 32.000)$, Cliente $C = (27 \text{ anos}, \text{R\$ } 60.000)$

a) Calcule a distância quadrática bruta $d^2(A, B)$ sem padronização e mostre qual variável domina o cálculo.
b) Sabendo que a coluna Idade possui média $\bar{x}_1 = 40$ anos e desvio-padrão $s_1 = 15$ anos, e a coluna Renda possui média $\bar{x}_2 = \text{R\$ } 45.000$ e desvio-padrão $s_2 = \text{R\$ } 15.000$, padronize as coordenadas do Cliente A usando o Z-Score.
c) Se após o treinamento do K-Means um centroide padronizado resultou em $\boldsymbol{\mu}_z = (-0.80,\ +1.20)$, quais são suas coordenadas reais em Anos e Reais (`inverse_transform`)?

Resolução do Exemplo 2

a) Distorção na Distância Bruta sem Padronização:

$$d^2(A, B) = \underbrace{(25-55)^2}_{\text{Idade: } (-30)^2 = \mathbf{900}} + \underbrace{(30.000-32.000)^2}_{\text{Renda: } (-2.000)^2 = \mathbf{4.000.000}} = 4.000.900$$

Embora A e B tenham 30 anos de diferença de idade e apenas R$ 2.000 de diferença salarial, a parcela da Renda (4 milhões) representa 99.98% da distância quadrática, anulando a influência da Idade!

b) Padronização Z-Score ($z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$) para o Cliente $A(25,\ 30.000)$:

$$z_{A1} = \frac{25 - 40}{15} = \frac{-15}{15} = \mathbf{-1.00}, \qquad z_{A2} = \frac{30.000 - 45.000}{15.000} = \frac{-15.000}{15.000} = \mathbf{-1.00}$$

No espaço padronizado, o Cliente A é representado por $\mathbf{z}_A = (-1.00,\ -1.00)$.

c) Reversão para a Escala Original de Negócio ($x_{kj} = z_{kj} \cdot s_j + \bar{x}_j$):
Para o centroide padronizado $\boldsymbol{\mu}_z = (-0.80,\ +1.20)$:

$$\mu_{\text{Idade}} = (-0.80 \times 15) + 40 = -12 + 40 = \mathbf{28.0} \text{ anos}$$

$$\mu_{\text{Renda}} = (+1.20 \times 15.000) + 45.000 = 18.000 + 45.000 = \text{R\$ } \mathbf{63.000}$$

Interpretabilidade comercial: perfil de *Jovens de Alta Renda* (28 anos e renda média de R$ 63 mil).

Exemplo 3: Inicialização Inteligente com o Algoritmo K-Means++

Considere $n = 4$ pontos unidimensionais sobre a reta real: $x_1 = 0$, $x_2 = 1$, $x_3 = 2$ e $x_4 = 6$. Na inicialização **K-Means++** para $K = 2$ clusters, suponha que o primeiro centroide sorteado foi $\mu_1^{(0)} = x_1 = 0$. Calcule a distribuição de probabilidade exata $P(\text{escolher } x_i)$ para o sorteio do segundo centroide $\mu_2^{(0)}$.

Resolução do Exemplo 3

1. **Cálculo das menores distâncias $D(x_i) = |x_i - \mu_1^{(0)}|$ e seus quadrados $D(x_i)^2$:**

   - $x_1 = 0 \implies D(x_1) = |0 - 0| = 0 \implies D(x_1)^2 = \mathbf{0}$
   - $x_2 = 1 \implies D(x_2) = |1 - 0| = 1 \implies D(x_2)^2 = \mathbf{1}$
   - $x_3 = 2 \implies D(x_3) = |2 - 0| = 2 \implies D(x_3)^2 = \mathbf{4}$
   - $x_4 = 6 \implies D(x_4) = |6 - 0| = 6 \implies D(x_4)^2 = \mathbf{36}$

2. **Soma total dos quadrados das distâncias:**

$$\sum_{j=1}^{4} D(x_j)^2 = 0 + 1 + 4 + 36 = \mathbf{41}$$

3. **Probabilidade de sorteio de cada ponto ($P(x_i) = \frac{D(x_i)^2}{\sum D(x_j)^2}$):**

$$P(x_1) = \frac{0}{41} = \mathbf{0.0}\%, \quad P(x_2) = \frac{1}{41} \approx \mathbf{2.44}\%, \quad P(x_3) = \frac{4}{41} \approx \mathbf{9.76}\%, \quad P(x_4) = \frac{36}{41} \approx \mathbf{87.80}\%$$

   Conclusão: O ponto distante $x_4 = 6$ tem **87.80**% de probabilidade de ser sorteado como a segunda semente, evitando que dois centroides nasçam colados no grupo $\{0, 1, 2\}$!

Exemplo 4: Cálculo do Coeficiente de Silhueta e Diagnóstico de Alocação

Após rodar um algoritmo de agrupamento com $K = 3$ grupos (C_1, C_2, C_3), avaliamos duas amostras específicas $\mathbf{x}_1 \in C_1$ e $\mathbf{x}_2 \in C_1$:

- Para a amostra $\mathbf{x}_1 \in C_1$: suas distâncias aos outros 2 membros de C_1 são 1.5 e 2.5. Sua distância média aos membros de C_2 é 8.0 e aos membros de C_3 é 12.0.
- Para a amostra $\mathbf{x}_2 \in C_1$: sua distância média aos demais membros de C_1 é $a(2) = 6.0$. Sua distância média aos membros de C_2 é 3.0 e aos membros de C_3 é 10.0.

Calcule os coeficientes de silhueta $s(1)$ e $s(2)$ e interprete a qualidade do agrupamento de cada amostra.

Resolução do Exemplo 4

a) Amostra $\mathbf{x}_1 \in C_1$:

- Coesão intra-cluster: $a(1) = \frac{1.5+2.5}{2} = \mathbf{2.0}$.
- Separação ao vizinho mais próximo: $b(1) = \min\{8.0,\ 12.0\} = \mathbf{8.0}$ (o cluster vizinho mais próximo é C_2).
- Coeficiente de Silhueta:

$$s(1) = \frac{b(1) - a(1)}{\max\{a(1),\, b(1)\}} = \frac{8.0 - 2.0}{\max\{2.0,\, 8.0\}} = \frac{6.0}{8.0} = +\mathbf{0.75}$$

- **Diagnóstico:** Como $s(1) = +0.75$ é positivo e próximo de $+1.0$, $\mathbf{x}_1$ está fortemente coeso em C_1 e bem separado de C_2.

b) Amostra $\mathbf{x}_2 \in C_1$:

- Coesão intra-cluster: $a(2) = \mathbf{6.0}$.
- Separação ao vizinho mais próximo: $b(2) = \min\{3.0,\ 10.0\} = \mathbf{3.0}$ (distância média ao vizinho C_2).
- Coeficiente de Silhueta:

$$s(2) = \frac{b(2) - a(2)}{\max\{a(2),\, b(2)\}} = \frac{3.0 - 6.0}{\max\{6.0,\, 3.0\}} = \frac{-3.0}{6.0} = \mathbf{-0.50}$$

- **Diagnóstico:** Como $s(2) = -0.50 < 0$, a amostra $\mathbf{x}_2$ está mais próxima dos elementos do cluster vizinho C_2 ($b = 3.0$) do que do seu próprio grupo C_1 ($a = 6.0$), indicando **alocação incorreta**!

Exemplo 5: Decomposição TSS = WCSS+BCSS e Método do Cotovelo

Uma base de dados possui Soma Total de Quadrados TSS = 1000.0. Ao executarmos o K-Means variando K de 1 a 5, obtivemos os seguintes valores de Inércia (WCSS):

$$\text{WCSS}(1) = 1000, \quad \text{WCSS}(2) = 480, \quad \text{WCSS}(3) = 180, \quad \text{WCSS}(4) = 155, \quad \text{WCSS}(5) = 135$$

a) Calcule a Soma de Quadrados Entre Grupos (BCSS) e a proporção de variância explicada (BCSS/TSS) para $K = 3$.
b) Calcule as quedas marginais $\Delta\text{WCSS}(K) = \text{WCSS}(K-1) - \text{WCSS}(K)$ e justifique analiticamente qual é o K ideal segundo o Método do Cotovelo.

Resolução do Exemplo 5

a) Cálculo de BCSS e Variância Explicada em $K = 3$: Pela identidade TSS = WCSS + BCSS:

$$\text{BCSS}(3) = \text{TSS} - \text{WCSS}(3) = 1000 - 180 = \mathbf{820.0}$$

$$\text{Variância Explicada} = \frac{\text{BCSS}(3)}{\text{TSS}} = \frac{820}{1000} = 0.820 = \mathbf{82.0}\%$$

b) Análise das Quedas Marginais (ΔWCSS) para o Método do Cotovelo:

- De $K = 1 \to 2$: $\Delta\text{WCSS}(2) = 1000 - 480 = \mathbf{520}$ (queda muito forte)
- De $K = 2 \to 3$: $\Delta\text{WCSS}(3) = 480 - 180 = \mathbf{300}$ (queda forte)
- De $K = 3 \to 4$: $\Delta\text{WCSS}(4) = 180 - 155 = \mathbf{25}$ (queda brusca no ganho marginal!)
- De $K = 4 \to 5$: $\Delta\text{WCSS}(5) = 155 - 135 = \mathbf{20}$ (ganho marginal residual)

Conclusão: O ponto de inflexão (cotovelo) ocorre exatamente em $\mathbf{K = 3}$, pois a redução de Inércia cai de 300 unidades (em $K = 3$) para apenas 25 unidades (em $K = 4$).

Exercício 1: Iteração de Lloyd-Forgy e WCSS

Considere um conjunto de dados com $n = 4$ pontos no plano cartesiano $\mathbb{R}^2$:

$$\mathbf{x}_1 = (2, 2), \quad \mathbf{x}_2 = (2, 6), \quad \mathbf{x}_3 = (8, 4), \quad \mathbf{x}_4 = (8, 8)$$

Deseja-se particionar os dados em $K = 2$ grupos via K-Means partindo dos centroides iniciais $\boldsymbol{\mu}_1^{(0)} = (2, 2)$ e $\boldsymbol{\mu}_2^{(0)} = (8, 4)$.

a) Calcule as distâncias euclidianas ao quadrado $d^2(\mathbf{x}_i, \boldsymbol{\mu}_k^{(0)})$ de cada ponto aos dois centroides iniciais, determine os conjuntos C_1 e C_2 e calcule a Inércia inicial $\text{WCSS}^{(0)}$.
b) Execute o Passo de Atualização calculando as coordenadas dos novos centroides $\boldsymbol{\mu}_1^{(1)}$ e $\boldsymbol{\mu}_2^{(1)}$.
c) Calcule a nova Inércia $\text{WCSS}^{(1)}$ após mover os centroides e informe o percentual de redução da Inércia.

Exercício 2: Padronização Z-Score e `inverse_transform`

Um e-commerce coletou duas variáveis de seus consumidores: X_1 = Tempo de Cadastro (meses), com média amostral $\bar{x}_1 = 20$ meses e desvio-padrão $s_1 = 10$ meses; e X_2 = Faturamento Anual de Compras (R$), com média $\bar{x}_2 = \text{R\$ } 5.000$ e desvio-padrão $s_2 = \text{R\$ } 2.000$.

a) Calcule as coordenadas padronizadas (Z-Score) para o consumidor $\mathbf{x}_A = (35 \text{ meses, R\$ } 2.000)$.
b) Após ajustar o K-Means na matriz padronizada, os dois centroides encontrados foram $\boldsymbol{\mu}_{1,\text{z}} = (-1.0,\ -0.5)$ e $\boldsymbol{\mu}_{2,\text{z}} = (+1.2,\ +1.5)$. Aplique a transformação inversa (`inverse_transform`) para obter as coordenadas de ambos os centroides nas unidades originais (Meses e Reais).
c) Qual é a distância euclidiana no espaço padronizado ($\mathbf{z}$) do consumidor $\mathbf{x}_A$ até cada um dos dois centroides ($\boldsymbol{\mu}_{1,\text{z}}$ e $\boldsymbol{\mu}_{2,\text{z}}$) – correspondente à saída do método `kmeans.transform([z_A])`?

Exercício 3: Sorteio Ponderado do K-Means++

Considere $n = 4$ pontos no plano $\mathbb{R}^2$:

$$\mathbf{x}_1 = (0, 0), \quad \mathbf{x}_2 = (0, 2), \quad \mathbf{x}_3 = (3, 0), \quad \mathbf{x}_4 = (3, 4)$$

Durante a inicialização **K-Means++**, a primeira semente sorteada foi $\boldsymbol{\mu}_1^{(0)} = \mathbf{x}_1 = (0, 0)$.

a) Calcule a distância quadrática $D(\mathbf{x}_i)^2 = \|\mathbf{x}_i - \boldsymbol{\mu}_1^{(0)}\|_2^2$ para cada um dos quatro pontos.
b) Calcule a probabilidade exata (em fração e em porcentagem) de cada ponto ser sorteado como o segundo centroide $\boldsymbol{\mu}_2^{(0)}$.

Exercício 4: Coeficiente de Silhueta no Plano

Considere um agrupamento já finalizado com $K = 2$ clusters no plano $\mathbb{R}^2$:

- **Cluster 1 (C_1):** contém os pontos $A = (0, 0)$ e $B = (0, 3)$.
- **Cluster 2 (C_2):** contém os pontos $C = (4, 0)$ e $D = (4, 3)$.

Utilizando a distância euclidiana exata $d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2}$:

a) Para o ponto $A(0, 0) \in C_1$, calcule a distância média intra-cluster $a(A)$ (distância até B).
b) Para o mesmo ponto $A(0, 0)$, calcule as distâncias $d(A, C)$ e $d(A, D)$ e obtenha a distância média ao cluster vizinho $b(A)$.
c) Calcule o Coeficiente de Silhueta $s(A)$ e interprete o resultado.

Exercício 5: Escolha Combinada por Cotovelo e Silhueta

Um cientista de dados executou o K-Means para $K \in \{1, 2, 3, 4, 5, 6\}$ em uma base com dispersão total TSS = 500.0, obtendo a tabela abaixo:

Número de Clusters (K)	$K = 1$	$K = 2$	$K = 3$	$K = 4$	$K = 5$	$K = 6$
Inércia – WCSS	500.0	290.0	190.0	80.0	72.0	66.0
Silhueta Média Global ($\bar{s}$)	—	0.48	0.56	0.74	0.61	0.52

a) Por que a célula da Silhueta Média Global está vazia (não definida) para $K = 1$?

b) Analisando conjuntamente as quedas marginais da Inércia (ΔWCSS) e a Silhueta Média Global ($\bar{s}$), qual é o número ideal de clusters K desta base de dados? Justifique.

c) Para o K ótimo escolhido no item anterior, quanto vale a Soma de Quadrados Entre Grupos (BCSS) e o percentual de variância explicada pelo agrupamento?