Lista de Exercícios
Técnicas de Agrupamento
Hierárquico, DBSCAN, Apriori e FP-Growth

Disciplina: Aprendizado de Máquina

Semestre Letivo

Exemplo 1: Agrupamento Hierárquico Aglomerativo e Ligações (*Linkage*)

Considere $n = 4$ observações unidimensionais: $A = 1,\ B = 2,\ C = 6,\ D = 10$, utilizando a distância absoluta $d(x, y) = |x - y|$.

a) Construa a matriz de distâncias inicial $D^{(0)}$ (4×4) e identifique o primeiro par de elementos a ser fundido e a altura h_1 dessa fusão.
b) Calcule a distância do novo grupo formado no item (a) até o elemento $C(6)$ segundo três critérios:
   (i) Ligação Simples (*Single*);
   (ii) Ligação Completa (*Complete*);
   (iii) Ligação Média (*Average*).
c) Conclua todas as fusões utilizando a **Ligação Completa** (max) e informe os clusters resultantes ao cortar o dendrograma na altura horizontal $h = 4.5$.

Resolução do Exemplo 1

a) Matriz de Distâncias Inicial $D^{(0)}$ e 1ª Fusão:
Calculando $d(x, y) = |x - y|$ para todos os pares:

$D^{(0)} =$

	$A(1)$	$B(2)$	$C(6)$	$D(10)$
$A(1)$	0.0	**1.0**	5.0	9.0
$B(2)$	**1.0**	0.0	4.0	8.0
$C(6)$	5.0	4.0	0.0	4.0
$D(10)$	9.0	8.0	4.0	0.0

A menor distância não nula da matriz é $d(A, B) = \mathbf{1.0}$. Portanto, o primeiro par fundido é o grupo $\mathbf{G_{AB}} = \{\mathbf{A}, \mathbf{B}\}$ na altura $\mathbf{h_1 = 1.0}$.

b) Distância entre $G_{AB} = \{A, B\}$ e $C(6)$ nos Três Critérios de Ligação:
Sabendo que $d(A, C) = |1 - 6| = 5.0$ e $d(B, C) = |2 - 6| = 4.0$:

- **(i) Ligação Simples** (min)**:** $D_{\text{single}}(G_{AB}, C) = \min\{5.0,\ 4.0\} = \mathbf{4.0}$.
- **(ii) Ligação Completa** (max)**:** $D_{\text{complete}}(G_{AB}, C) = \max\{5.0,\ 4.0\} = \mathbf{5.0}$.
- **(iii) Ligação Média (UPGMA):** $D_{\text{avg}}(G_{AB}, C) = \frac{5.0+4.0}{2\times1} = \mathbf{4.5}$.

c) Sequência Completa pela Ligação Completa (max) **e Corte em $h = 4.5$:**

- Atualizando a matriz $D^{(1)}$ (3×3) pela Ligação Completa: $D_{\text{complete}}(G_{AB}, C) = 5.0$, $D_{\text{complete}}(G_{AB}, D) = \max(9, 8) = 9.0$ e $d(C, D) = \mathbf{4.0}$.

- **2ª Fusão:** Menor distância em $D^{(1)}$ é $d(C,D) = \mathbf{4.0}$. Fundimos $\mathbf{G_{CD}} = \{\mathbf{C}, \mathbf{D}\}$ na altura $\mathbf{h_2} = \mathbf{4.0}$.
- **3ª Fusão:** Restam G_{AB} e G_{CD}, que se unem na altura máxima $\mathbf{h_3} = \max_{x \in G_{AB}, y \in G_{CD}} d(x,y) = d(A,D) = \mathbf{9.0}$.
- **Corte em $h = 4.5$:** Como $h_1 = 1.0 < 4.5$ e $h_2 = 4.0 < 4.5$, mas $h_3 = 9.0 > 4.5$, a última fusão não ocorre. Obtemos $\mathbf{K = 2}$ clusters: $\mathbf{G_1} = \{\mathbf{A}, \mathbf{B}\}$ e $\mathbf{G_2} = \{\mathbf{C}, \mathbf{D}\}$!

Exemplo 2: Métricas de Regras de Associação e a Armadilha da Confiança

Em um supermercado com $N = 100$ transações registradas:

- 60 transações contêm {Cerveja};
- 75 transações contêm {Pão};
- 45 transações contêm simultaneamente {Cerveja, Pão}.

Avalie a regra de associação R : {Cerveja} $\implies$ {Pão} calculando seu **Suporte**, sua **Confiança**, seu ***Lift*** e sua **Convicção**, e interprete se a compra de Cerveja realmente impulsiona a compra de Pão.

Resolução do Exemplo 2

1. **Suportes Individuais e Conjunto:**

$$\text{Suporte(Cerveja)} = \frac{60}{100} = \mathbf{0.60}, \quad \text{Suporte(Pão)} = \frac{75}{100} = \mathbf{0.75},$$

$$\text{Suporte(Cerveja} \cup \text{Pão)} = \frac{45}{100} = \mathbf{0.45}$$

   Logo, o suporte da regra é Suporte(Cerveja $\implies$ Pão) = $\mathbf{0.45}$ (45%).

2. **Confiança da Regra:**

$$\text{Confiança(Cerveja} \implies \text{Pão)} = \frac{\text{Suporte(Cerveja} \cup \text{Pão)}}{\text{Suporte(Cerveja)}} = \frac{0.45}{0.60} = \mathbf{0.75}\ (75.0\%)$$

3. ***Lift* (Alavancagem) e Convicção:**

$$\text{Lift(Cerveja} \implies \text{Pão)} = \frac{\text{Confiança(Cerveja} \implies \text{Pão)}}{\text{Suporte(Pão)}} = \frac{0.75}{0.75} = \mathbf{1.00}$$

$$\text{Convicção(Cerveja} \implies \text{Pão)} = \frac{1 - \text{Suporte(Pão)}}{1 - \text{Confiança(Cerveja} \implies \text{Pão)}} = \frac{1 - 0.75}{1 - 0.75} = \frac{0.25}{0.25} = \mathbf{1.0}$$

4. **Interpretação(Armadilha da Confiança):**
   Embora a Confiança de 75% pareça alta à primeira vista, o Lift = 1.0 (e Convicção = 1.0) revela que **Cerveja e Pão são estatisticamente independentes**! A probabilidade de um cliente qualquer levar Pão já era de 75% na loja inteira; comprar Cerveja não alterou em nada essa probabilidade!

Exemplo 3: Funcionamento Interno do Algoritmo Apriori

Considere a base de transações abaixo ($N = 5$ compras) com os itens $\{A, B, C, D, E\}$ e um suporte mínimo de **min_sup** = **60**% (ou seja, contagem mínima de **3** ocorrências em 5 compras):

$$T_1 : \{A, B, C, D\}, \quad T_2 : \{A, B, E\}, \quad T_3 : \{A, B, C\}, \quad T_4 : \{B, C, D\}, \quad T_5 : \{A, B, C, E\}$$

Execute o algoritmo **Apriori** passo a passo na mão:

a) Construa a tabela de candidatos de tamanho 1 (C_1), aplique o corte de suporte (≥ 3) e explicite L_1.
b) Gere os pares candidatos $C_2 = L_1 \bowtie L_1$, conte os suportes na 2ª varredura e explicite L_2.
c) Gere as trincas candidatas C_3 a partir de L_2, aplique a **Poda Apriori** e determine L_3.

Resolução do Exemplo 3

a) Iteração $k = 1$ (1ª Varredura do Banco: $C_1 \to L_1$):
Contamos em quantas transações cada item aparece:

- $\{A\}$: aparece em $T_1, T_2, T_3, T_5 \implies$ Contagem = $\mathbf{4} \geq 3$ (**Aprovado em** L_1)
- $\{B\}$: aparece em $T_1, T_2, T_3, T_4, T_5 \implies$ Contagem = $\mathbf{5} \geq 3$ (**Aprovado em** L_1)
- $\{C\}$: aparece em $T_1, T_3, T_4, T_5 \implies$ Contagem = $\mathbf{4} \geq 3$ (**Aprovado em** L_1)
- ~~$\{D\}$~~: aparece apenas em $T_1, T_4 \implies$ Contagem = $2 < 3$ (**Podado!**)
- ~~$\{E\}$~~: aparece apenas em $T_2, T_5 \implies$ Contagem = $2 < 3$ (**Podado!**)

Portanto, o conjunto de 1-itemsets frequentes é $\mathbf{L_1} = \{\{\mathbf{A}\} : \mathbf{4},\ \{\mathbf{B}\} : \mathbf{5},\ \{\mathbf{C}\} : \mathbf{4}\}$. *(Pelo Princípio Apriori, os itens D e E jamais serão testados nos níveis seguintes!).*

b) Iteração $k = 2$ (Geração de $C_2 = L_1 \bowtie L_1$ e 2ª Varredura $\to L_2$):
Combinando os 3 itens de L_1 dois a dois, geramos $\binom{3}{2} = 3$ pares candidatos em C_2 e contamos suas frequências no banco:

- $\{A, B\}$: aparece em $T_1, T_2, T_3, T_5 \implies$ Contagem = $\mathbf{4} \geq 3$ (**Aprovado em** L_2)
- $\{A, C\}$: aparece em $T_1, T_3, T_5 \implies$ Contagem = $\mathbf{3} \geq 3$ (**Aprovado em** L_2)
- $\{B, C\}$: aparece em $T_1, T_3, T_4, T_5 \implies$ Contagem = $\mathbf{4} \geq 3$ (**Aprovado em** L_2)

Todos os 3 pares atingiram o limiar: $\mathbf{L_2} = \{\{\mathbf{A}, \mathbf{B}\} : \mathbf{4},\ \{\mathbf{A}, \mathbf{C}\} : \mathbf{3},\ \{\mathbf{B}, \mathbf{C}\} : \mathbf{4}\}$.

c) Iteração $k = 3$ (Geração de C_3, Verificação de Poda e 3ª Varredura $\to L_3$):

- Unindo $\{A, B\}$ e $\{A, C\}$, formamos a trinca candidata $C_3 = \{\{A, B, C\}\}$.
- **Teste de Poda Apriori:** Todos os subconjuntos de tamanho 2 de $\{A, B, C\}$ ($\{A, B\}, \{A, C\}$ e $\{B, C\}$) estão presentes em L_2? **Sim!** Logo, $\{A, B, C\}$ não é podado e vai para a 3ª varredura.
- **3ª Varredura:** $\{A, B, C\}$ aparece junto em T_1, T_3 e $T_5 \implies$ Contagem = $\mathbf{3} \geq 3$!
- Portanto, $\mathbf{L_3} = \{\{\mathbf{A}, \mathbf{B}, \mathbf{C}\} : \mathbf{3}\}$. Como só há 1 elemento em L_3, $C_4 = \emptyset$ e o algoritmo encerra!

Exemplo 4: Agrupamento por Densidade (DBSCAN – Core, Borda e Ruído)

Considere $n = 5$ pontos no plano $\mathbb{R}^2$:

$$P_1 = (0, 0), \quad P_2 = (1, 0), \quad P_3 = (0, 1), \quad P_4 = (2, 0), \quad P_5 = (6, 6)$$

Executando o algoritmo **DBSCAN** com raio $\boldsymbol{\varepsilon = 1.5}$ (distância Euclidiana) e **MinPts** $= \mathbf{3}$:

a) Determine o conjunto de vizinhança $N_{1.5}(P_i)$ e a cardinalidade $|N_{1.5}(P_i)|$ para cada um dos 5 pontos.
b) Classifique cada ponto em **Ponto Central (*Core*)**, **Ponto de Borda (*Border*)** ou **Ruído (*Noise*, rótulo −1)** e indique os clusters finais formados.

Resolução do Exemplo 4

a) Cálculo das Vizinhanças $N_{1.5}(P_i) = \{P_j \mid \|P_i - P_j\|_2 \leq 1.5\}$**:**

- **Para** $P_1(0,0)$**:** $d(P_1,P_1) = 0$, $d(P_1,P_2) = 1.0 \leq 1.5$, $d(P_1,P_3) = 1.0 \leq 1.5$, $d(P_1,P_4) = 2.0 > 1.5$.

$$\implies N_{1.5}(P_1) = \{P_1, P_2, P_3\} \implies |\mathbf{N_{1.5}(P_1)}| = \mathbf{3}$$

- **Para** $P_2(1,0)$**:** $d(P_2,P_1) = 1.0$, $d(P_2,P_2) = 0$, $d(P_2,P_3) = \sqrt{1^2+1^2} = \sqrt{2} \approx 1.41 \leq 1.5$, $d(P_2,P_4) = 1.0 \leq 1.5$.

$$\implies N_{1.5}(P_2) = \{P_1, P_2, P_3, P_4\} \implies |\mathbf{N_{1.5}(P_2)}| = \mathbf{4}$$

- **Para** $P_3(0,1)$**:** $d(P_3,P_1) = 1.0$, $d(P_3,P_2) \approx 1.41 \leq 1.5$, $d(P_3,P_3) = 0$, $d(P_3,P_4) = \sqrt{4+1} = \sqrt{5} \approx 2.24 > 1.5$.

$$\implies N_{1.5}(P_3) = \{P_1, P_2, P_3\} \implies |\mathbf{N_{1.5}(P_3)}| = \mathbf{3}$$

- **Para** $P_4(2,0)$**:** Apenas $P_2(1,0)$ está a distância ≤ 1.5 ($d(P_4,P_2) = 1.0$).

$$\implies N_{1.5}(P_4) = \{P_2, P_4\} \implies |\mathbf{N_{1.5}(P_4)}| = \mathbf{2}$$

- **Para** $P_5(6,6)$**:** Distância a qualquer outro ponto é > 5.0.

$$\implies N_{1.5}(P_5) = \{P_5\} \implies |\mathbf{N_{1.5}(P_5)}| = \mathbf{1}$$

b) Classificação Estrutural (MinPts = 3) e Clusters Finais:

- **Pontos Centrais (*Core Points*,** $|N_\varepsilon| \geq 3$**):** $\mathbf{P_1}, \mathbf{P_2}$ e $\mathbf{P_3}$.
- **Ponto de Borda (*Border Point*):** $\mathbf{P_4}$ (possui $|N_\varepsilon(P_4)| = 2 < 3$, mas pertence à vizinhança do Ponto Central P_2).
- **Ponto de Ruído (*Noise*, rótulo `-1`):** $\mathbf{P_5}$ ($|N_\varepsilon(P_5)| = 1 < 3$ e não pertence à vizinhança de nenhum Ponto Central).
- **Agrupamento Final:** Um único cluster $\mathbf{C_0} = \{\mathbf{P_1}, \mathbf{P_2}, \mathbf{P_3}, \mathbf{P_4}\}$ e conjunto de ruído $\{\mathbf{P_5}\}$.

Exemplo 5: Algoritmo FP-Growth (FP-Tree e Árvore Condicional)

Considere as 5 transações abaixo ($N = 5$) e suporte mínimo igual a **3** ocorrências (60%):

$$T_1 : \{E, K, M, N, O, Y\}, \quad T_2 : \{D, E, K, N, O, Y\}, \quad T_3 : \{A, E, K, M\}, \quad T_4 : \{C, K, M, U, Y\},$$
$$T_5 : \{C, E, I, K, O\}$$

Execute o algoritmo **FP-Growth** passo a passo:

a) Faça a 1ª varredura para contar a frequência de cada item, descarte os itens com suporte < 3, monte a lista ordenada decrescente L e reescreva as 5 transações filtradas e ordenadas segundo L.
b) Desenhe a **Árvore FP-Tree** final resultante da inserção das 5 transações reordenadas.
c) Construa a tabela de mineração *Bottom-Up* contendo a **Base de Padrões Condicionais (*Conditional Pattern Base*)**, a **Árvore FP Condicional (*Conditional FP-Tree*)** e os conjuntos frequentes gerados para cada item sufixo.

Resolução do Exemplo 5

a) 1ª Varredura, Lista Ordenada L e Transações Reordenadas:
Contando cada item nas 5 transações: $K : 5$, $E : 4$, $O : 4$, $M : 3$, $Y : 3$, enquanto os itens $C : 2, N : 2, A : 1, D : 1, I : 1, U : 1$ possuem contagem < 3 e são eliminados. Ordenando em

ordem decrescente de frequência, obtemos:

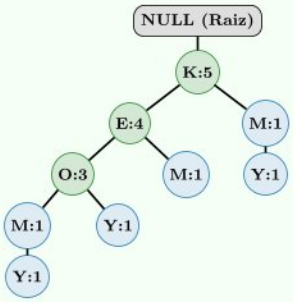
$$\mathbf{L} = \{\mathbf{K:5},\ \mathbf{E:4},\ \mathbf{O:4},\ \mathbf{M:3},\ \mathbf{Y:3}\}$$

Filtrando e ordenando cada transação na sequência exata de L ($K \to E \to O \to M \to Y$):

- $T_1 : \{E, K, M, \cancel{N}, O, Y\} \longrightarrow \{\mathbf{K}, \mathbf{E}, \mathbf{O}, \mathbf{M}, \mathbf{Y}\}$
- $T_2 : \{\cancel{D}, E, K, \cancel{N}, O, Y\} \longrightarrow \{\mathbf{K}, \mathbf{E}, \mathbf{O}, \mathbf{Y}\}$
- $T_3 : \{\cancel{A}, E, K, M\} \longrightarrow \{\mathbf{K}, \mathbf{E}, \mathbf{M}\}$
- $T_4 : \{\cancel{C}, K, M, \cancel{U}, Y\} \longrightarrow \{\mathbf{K}, \mathbf{M}, \mathbf{Y}\}$
- $T_5 : \{\cancel{C}, E, \cancel{I}, K, O\} \longrightarrow \{\mathbf{K}, \mathbf{E}, \mathbf{O}\}$

b) Construção da Árvore FP-Tree após inserir T_1, T_2, T_3, T_4 e T_5:

- T_1 cria o ramo principal NULL $\to K:1 \to E:1 \to O:1 \to M:1 \to Y:1$.
- T_2 incrementa $K:2 \to E:2 \to O:2$ e abre um novo nó filho $Y:1$ abaixo de $O:2$.
- T_3 incrementa $K:3 \to E:3$ e abre um novo nó filho $M:1$ abaixo de $E:3$.
- T_4 incrementa $K:4$ e abre um novo ramo $M:1 \to Y:1$ abaixo de $K:4$.
- T_5 percorre o ramo existente incrementando $K:5 \to E:4 \to O:3$.



c) Mineração *Bottom-Up*: Base de Padrões Condicionais e Árvore FP Condicional (≥ 3):

Percorrendo do item menos frequente (Y) até o topo (K):

Item	Base de Padrões Condicionais (Prefixos)	Soma nos Prefixos e Corte (≥ 3)	Conjuntos Frequentes Gerados
Y	$\{K, E, O, M:1\}, \{K, E, O:1\}, \{K, M:1\}$	$K:3, \cancel{E:2}, \cancel{O:2}, \cancel{M:2} \to \{\mathbf{K:3}\}$	$\{\mathbf{K, Y:3}\}$
M	$\{K, E, O:1\}, \{K, E:1\}, \{K:1\}$	$K:3, \cancel{E:2}, \cancel{O:1} \to \{\mathbf{K:3}\}$	$\{\mathbf{K, M:3}\}$
O	$\{K, E:3\}$	$K:3, E:3 \to \{\mathbf{K:3, E:3}\}$	$\{\mathbf{K, O:3}\}, \{\mathbf{E, O:3}\}, \{\mathbf{K, E, O:3}\}$
E	$\{K:4\}$	$K:4 \to \{\mathbf{K:4}\}$	$\{\mathbf{K, E:4}\}$
K	$\emptyset$ (Raiz)	$\emptyset$	$\{\mathbf{K:5}\}$ (1-itemset)

Exercício 1: Agrupamento Hierárquico e Ligações

Considere um conjunto de dados com $n = 4$ observações unidimensionais:

$$P_1 = 2, \quad P_2 = 5, \quad P_3 = 14, \quad P_4 = 16$$

utilizando a distância absoluta $d(x, y) = |x - y|$.

a) Monte a matriz de distâncias inicial $D^{(0)}$ (4×4) e indique qual é o primeiro par de pontos a ser fundido e a altura h_1 dessa 1ª fusão.
b) Qual é o segundo par de pontos a ser fundido e a altura h_2 dessa 2ª fusão?
c) Calcule a altura h_3 da fusão final entre os dois grupos formados nos itens (a) e (b) segundo: (i) a **Ligação Simples (*Single*)**; (ii) a **Ligação Completa (*Complete*)**; e (iii) a **Ligação Média (*Average*)**.

Exercício 2: DBSCAN: Core, Borda e Ruído

Considere $n = 5$ pontos unidimensionais sobre a reta real:

$$A = 1.0, \quad B = 2.0, \quad C = 3.0, \quad D = 4.5, \quad E = 9.0$$

Executando o algoritmo **DBSCAN** com raio $\boldsymbol{\varepsilon = 1.5}$ $(d(x, y) = |x - y|)$ e **MinPts = 3**:

a) Liste o conjunto de vizinhança $N_{1.5}(x_i)$ e a contagem de vizinhos $|N_{1.5}(x_i)|$ para cada um dos 5 pontos (A, B, C, D, E).
b) Classifique cada um dos 5 pontos em **Ponto Central (*Core*)**, **Ponto de Borda (*Border*)** ou **Ruído (*Noise*, rótulo `-1`)** e escreva os elementos do cluster formado.

Exercício 3: Suporte, Confiança, *Lift* e Convicção

Em uma plataforma de comércio eletrônico com $N = 200$ pedidos:

- 80 pedidos contêm {Notebook};
- 100 pedidos contêm {Mouse};
- 60 pedidos contêm ambos os produtos {Notebook, Mouse}.

Para a regra de associação R : {Notebook} $\implies$ {Mouse}:

a) Calcule o **Suporte** e a **Confiança** da regra.
b) Calcule o ***Lift*** e a **Convicção** da regra e conclua se a associação entre Notebook e Mouse é positiva, neutra ou negativa.

Exercício 4: Execução Passo a Passo do Algoritmo Apriori

Considere o banco transacional de uma padaria com $N = 5$ compras abaixo e suporte mínimo de **min_sup = 60%** (contagem mínima de **3** ocorrências em 5 compras):

$$T_1 : \{\text{Pão, Leite, Café}\}, \quad T_2 : \{\text{Pão, Manteiga, Leite, Ovos}\}, \quad T_3 : \{\text{Pão, Manteiga, Leite}\}$$

$$T_4 : \{\text{Pão, Manteiga, Café}\}, \quad T_5 : \{\text{Manteiga, Leite, Bolo}\}$$

Execute o algoritmo **Apriori** passo a passo na mão:

a) Realize a 1ª varredura (C_1), elimine os produtos com contagem < 3 e escreva o conjunto L_1.
b) Gere todos os pares candidatos C_2 a partir de L_1, conte suas ocorrências no banco e escreva o conjunto de pares frequentes L_2.
c) Verifique se é possível formar a trinca candidata $C_3 = \{\{\text{Pão, Manteiga, Leite}\}\}$ sem violar a Poda Apriori e, em caso afirmativo, verifique se ela sobrevive em L_3.

Exercício 5: Construção da FP-Tree e Mineração no FP-Growth

Utilizando a mesma base de $N = 5$ compras da padaria do Exercício Proposto 4 com suporte mínimo igual a **3** ocorrências (Pão = **P**, Manteiga = **M**, Leite = **L**, Café = **C**, Ovos = **O**, Bolo = **B**):

$$T_1 : \{P, L, C\}, \quad T_2 : \{P, M, L, O\}, \quad T_3 : \{P, M, L\}, \quad T_4 : \{P, M, C\}, \quad T_5 : \{M, L, B\}$$

Execute o algoritmo **FP-Growth** completo na mão:

a) Construa a lista ordenada decrescente de itens frequentes L (adotando a ordem $P \to M \to L$ em caso de empate) e reescreva as 5 transações filtradas e ordenadas segundo L.
b) Desenhe passo a passo a **Árvore FP-Tree** final após a inserção de T_1, T_2, T_3, T_4 e T_5.
c) Construa a tabela de mineração *Bottom-Up* (para os itens L, M e P) mostrando a **Base de Padrões Condicionais**, a **Árvore FP Condicional** (≥ 3) e os conjuntos frequentes encontrados.